全部竞品：产品、收费模式与定价

沐仞科技内部竞品资料 | 10 家 | 2026-10-21 整理

范围。 共 10 家，沿用 10-14《竞品功能清单》的 9 家，再加上 Fireworks：

- 国内：DeepSeek 官方 API（作价格锚）、硅基流动、PPIO 派欧云、无问芯穹
- 海外：OpenRouter、Together AI、Fireworks AI、Crusoe、Soluna、Emerald AI

口径。

- **日期：** 价格是 2026-10-14 至 10-21 在官网价目页上看到的。无问芯穹的价格不公开，用的是网页存档，日期见各表。
- **币种：** 人民币和美元分开列，不做汇率换算。
- **单位：** “M”指百万 Token。
- **标记：** 我自己算出来的数字标【算】，分析判断标【判断】。

0. 一页总览

公司	定位	主要产品	怎么收钱	价格公开吗	收入规模与结构
DeepSeek 官方	模型厂自营 API	2 个模型（Flash、V4 Pro）	按 Token；**工作日高峰全价，其余时段 5 折**；搜索/抓取按次收费	公开	—
硅基流动	国内独立 Token 平台	公有云 API、预留实例、私有化 MaaS / 网关 / 一体机、“Token 工厂”联合运营、国际站	按 Token、按张、按秒；预留实例月租；私有化收许可 + 实施 + 维保；联合运营按服务量分成	Token 价和预留实例价都公开	2025 年 5,533 万元：公有云 52.9%，本地部署 47.1%（招股书）
PPIO 派欧云	国内独立云（边缘云起家）	模型 API、企业 Token Plan、Agent 沙箱 / 托管、私有化；GPU 云**标注即将下线**	按 Token；企业月度订阅包；批量 5 折	Token 价公开；Token Plan 只写”低至 4.5 折”	2025 年 7.7 亿元：边缘云 84.5%，AI 云 15.5%，毛利率 9.4%（招股书，媒体转述）
无问芯穹	国内 AI 基础设施，只服务企业	大模型 API、编码套餐、ComfyUI 托管、GPU 算力、智能体平台、私有化与项目	按 Token；并发包月；按秒；GPU 卡时或包月；积分；项目合同	大部分不公开（需登录，只对企业）	2024 年营收超过 8,500 万元（清华材料，非审计）
OpenRouter	海外模型聚合路由	一个接口接 500+ 模型、80+ 供应商	按各供应商的价格计费，**另收平台费 5.5%（Business 档 8%）**；自带 Key（BYOK）超出额度后收 5%	公开	—
Together AI	海外开源模型 AI 云	推理 API、批量、预留吞吐、专属推理、GPU 集群、沙箱、存储、微调	按 Token、按 GPU 小时、按 vCPU 小时、按 GiB；全部预付	公开	上季度年度订单额超过 11.5 亿美元；第三方估计 GPU 出租占大头
Fireworks AI	海外开源模型推理 + 训练	推理 API（四档速度/区域）、按需 GPU 部署、预留吞吐、自带云部署、训练	按 Token、按 GPU 秒、按训练 Token；自助预付	公开	年化收入超过 10 亿美元
Crusoe	海外能源型 AI 云	GPU 云、托管推理、专属部署、数据中心	按 GPU 小时、按 Token；长约找销售	公开	—
Soluna	海外绿电数据中心（上市公司）	数据托管、自营挖矿、电网需求响应、AI 算力（筹建中）	托管费、挖矿收益、需求响应补偿	不公开	2026 年一季度 940 万美元：托管 669 万、挖矿 217 万、需求响应 54 万
Emerald AI	海外”算电协同”软件	Emerald Conductor：让数据中心负荷随电网灵活调节	未公开	不公开	—

最后两家（Soluna、Emerald）不卖 Token，下面的价格对照不包括它们。

1. 同一模型在各家的 Token 价格

1.1 国内（元/M Token，输入 / 输出；括号里是缓存命中价）

模型	DeepSeek 官方	硅基流动（国内站）	PPIO	无问芯穹
DeepSeek V4 Pro（0813）	高峰 9 / 27（0.30） 其余时段 4.5 / 13.5（0.15）	12 / 24（1）	9 / 27（3）	不公开；每晚 22:00–次日 08:00 按半价
DeepSeek V4.1 Flash	高峰 2 / 8（0.04） 其余时段 1 / 4（0.02）	—	2 / 8（0.04）	不公开
DeepSeek V4 Flash（0731 及旧版）	已下线，按 V4.1 Flash 计费	3 / 9（0.30） 凌晨 2–8 点 1.5 / 4.5（0.15）	3 / 9（1）	不公开；22:00–08:00 半价
GLM-5.3	—	8 / 28（2）	8 / 28（2）	不公开
GLM-5.3 Flash	—	0.8 / 2.8（0.23）	0.8 / 2.8（0.23）	不公开
Kimi K2.6	—	6.5 / 27（1.1）	6.5 / 27（1.1）	不公开
Kimi K3	—	国内站未列	20 / 100（2）	不公开
Qwen3.8 Max（2.4T 参数）	—	国内站未列	12 / 36（1.5）	不公开
2025-05 的老价（参照）	—	—	—	存档价：R1 4 / 16，V3 2 / 8

1.2 海外（美元/M Token，输入 / 输出）

模型	DeepSeek 官方	硅基流动国际站	Together	Fireworks	Crusoe
DeepSeek V4 Pro（0813）	高峰 1.32 / 3.96 其余时段 0.66 / 1.98	1.32 / 3.96（最新版 1.50 / 3.135）	1.32 / 3.96	不提供按量调用	1.74 / 3.48
DeepSeek V4.1 Flash	高峰 0.30 / 1.20 其余时段 0.15 / 0.60	0.15 / 0.60	0.30 / 1.20	0.30 / 1.20（10-01 从 0.22 / 0.66 上调）	V4 Flash 0.14 / 0.28
GLM-5.3	—	1.40 / 4.40	1.40 / 4.40	1.40 / 4.40	1.40 / 4.40
GLM-5.3 Flash	—	0.15 / 0.50	0.15 / 0.50	0.15 / 0.50	0.15 / 0.50
Kimi K3	—	2.70 / 13.50	3.00 / 15.00	3.00 / 15.00	—
Qwen3.8 Max（2.4T 参数）	—	2.00 / 6.00	2.00 / 6.00	2.00 / 6.00	—
MiniMax M3	—	0.30 / 1.20	0.30 / 1.20	0.30 / 1.20	—

OpenRouter 不定价：按所选供应商的价格计费，再加平台费。

【判断】

1. **同一个模型，各家几乎同价。** GLM-5.3 在硅基和 PPIO 都是 8 / 28 元，在海外四家都是 1.40 / 4.40 美元。价格基本由模型厂的标价决定，平台之间不拼单价。
2. **最低锚点是 DeepSeek 官方的非高峰价。** DeepSeek 只在工作日 9–12 点、14–18 点收全价，其余时段（含周末、节假日）全部 5 折。所以 V4 Pro 的实际最低价是 4.5 / 13.5 元，V4.1 Flash 是 1 / 4 元。平台想比官方便宜，只能比这个价更低。
3. **价格不一样的地方集中在三处：**
   - 硅基流动把 V4 Pro 定成输入贵、输出便宜（12 / 24）；
   - Kimi K3 在硅基国际站便宜一成；
   - Crusoe 的 DeepSeek 价和别家不同。

2. GPU 算力价格（每卡每小时）

GPU	Crusoe	Together GPU 集群	Together 专属推理	Fireworks 按需部署	无问芯穹 AIStudio	PPIO
H100 80GB	4.50 美元	可抢占 1.99 按需 3.99	5.49 美元	8.00 美元	8 卡包月 11 万元， 折合约 18.8 元/卡时	GPU 云**即将下线**

GPU	Crusoe	Together GPU 集群	Together 专属推理	Fireworks 按需部署	无问芯穹 AIStudio	PPIO
		预留 3.69 / 3.45 / 3.19（3–30 天 / 31–90 天 / 91–180 天）			【算】	
H200 141GB	5.40 美元	可抢占 2.99，按需 5.99，预留 4.99 / 4.15 / 3.99	联系销售	8.00 美元	—	—
B200 180GB	8.50 美元	可抢占 4.09，按需 8.19，预留 7.99 / 7.79 / 6.79	8.99 美元	13.00 美元	—	—
B300 288GB	9.90 美元	按需 9.99 美元	联系销售	15.00 美元	—	—
A100 80GB	SXM 2.30 / PCIe 2.00 美元	—	—	—	刊例 17.46 元，折后 8.72 元（“敬请期待”，不能自助下单）；8 卡包月 6.7 万元 ≈ 11.5 元/卡时【算】	—
RTX 4090	—	—	—	—	刊例 3.15 元，折后 2.09 元；8 卡包月 1.2 万元	—

- 托管类部署（Crusoe 专属部署 6.30–13.80 美元、Together 专属推理、Fireworks 按需部署）都比裸 GPU 贵，差价是平台的推理优化和运维费。
- 包月折合卡时价：月价 ÷（8 卡 × 730 小时）。
- 无问芯穹的数据来自 2026-02 网页存档。

3. 各家收费细节

3.1 DeepSeek 官方（价格锚）

- **只有两个模型：**
  - deepseek-flash（V4.1-Flash-1017）：高峰输入 2 元（缓存命中 0.04）、输出 8 元；其余时段 1 / 4 元。
  - deepseek-v4-pro（V4-Pro-0813）：高峰输入 9 元（缓存命中 0.30）、输出 27 元；其余时段 4.5 / 13.5 元。
  - 美元价：Flash 0.30 / 1.20，V4 Pro 1.32 / 3.96，非高峰同样 5 折。
- **高峰时段：** 北京时间工作日 9–12 点、14–18 点；其余时间（含周末、法定节假日全天）按 5 折计费。
- **搜索、抓取：** 各 5 元 / 千次成功请求。通过 Claude Code、Codex 等工具调用的部分，11 月 1 日起开始收费。
- **扣费：** 先扣赠送余额，再扣充值余额。
- **并发上限：** Flash 2,500，V4 Pro 500。

3.2 硅基流动

- **公有云按量计费（国内站）：**
  - 对话模型按 Token 计价，部分模型按上下文长度分档。例如 Qwen3.5-122B：128k 以内 0.8 / 6.4 元，128k 以上 2 / 16 元。
  - 生图 0.1–0.3 元/张，视频 2 元/个，语音按字符或按秒计费。
  - 有一批永久免费的小模型（如 Hunyuan-MT-7B、星辰 Xing4.0-29B、bge 系列）。
- **分时价，有两种：**
  - DeepSeek-V4-Flash 凌晨 2–8 点半价。
  - Hunyuan-A13B 在 9–18 点按 1 / 4 元，其余时段 0.8 / 3.2 元。
- **国际站：** 按美元计价，送 1 美元，可后付费；也在 OpenRouter 上作为供应商提供服务。
- **账户规则：**
  - 按累计消费分用量等级 L0–L5，等级决定限流。
  - 2026-05 起必须实名才能用；赠送余额统一改为代金券发放。
- **预留实例（公开月价，按”组”租）：**

规格	模型	月价	折合单价（元/M）*	吞吐（TPM）
高性能	GLM-5.1	772,200 元	3.575	1,000 万
高性能	Kimi-K2.6	772,200 元	8.938	400 万
高性能	DeepSeek-V3.2	772,200 元	2.86	1,250 万

规格	模型	月价	折合单价（元/M）*	吞吐（TPM）
高性能	MiniMax-M2.5	386,100 元	3.575	500 万
标准版	Kimi-K2.6 / MiniMax-M2.5 / DeepSeek-V3.2	486,000 元	4.25 / 2.50 / 2.08	530 万 / 900 万 / 1,080 万

*官方按”每月 30 天、利用率 50%“折算；部署交付 1–7 个工作日，附 SLA。

- **私有化 MaaS、网关、一体机：** 收许可费 + 实施费 + 维保费，可订阅也可买断。这块 2025 年毛利率 82.5%（招股书）。
- **AI 算力运营（“Token 工厂”）：** 面向 IDC、区域智算中心和有闲置 GPU 的企业，硅基出推理引擎和运营，按实际服务量和对方分成。

3.3 PPIO 派欧云

- **按量计费：** 价格页公开到每个模型，例如：
  - DeepSeek V4 Pro 9 / 27 元（缓存 3），V4.1 Flash 2 / 8 元；
  - GLM-5.3 8 / 28 元，Kimi K3 20 / 100 元，Qwen3.8 Max 12 / 36 元，MiniMax M2.7 2.1 / 8.4 元。
  - 部分模型单独对”写入缓存”计价，部分模型按上下文长度阶梯计费。
  - 批量推理限时 5 折（部分模型）。
- **企业 Token Plan：**
  - 怎么买：充值一笔，按”实际用量 × 模型抵扣系数”扣减。月度订阅包当月有效、不结转；可另买加量包，有效期 3 个月。
  - 价格：模型价”低至 4.5 折”，官方称比按量最多省 55%。
  - 团队管理：最多 200 个席位，可按成员设预算，API Key 可设额度、限定模型和 IP 白名单，有调用日志和成本看板。
  - 服务承诺：模型可用性 SLA 最高 99.5%。
  - 购买方式：可在线订阅，也可找销售定制。
- **其他产品：**
  - Agent 沙箱 / 托管：价格页没有列价。
  - GPU 云（容器实例、Serverless GPU、Spot）：导航标注”即将下线”。
  - 私有化部署：报价咨询。

3.4 无问芯穹（详见同日《无问芯穹_产品与收费定价》）

- **大模型 API 服务等级：**
  - 基础：每分钟 12 次请求，2026-03-30 起也收费。
  - 高级：每分钟 1,200 次，可在控制台自助升级。
  - 企业：找销售。
- **大模型 API 价格：** 2025-11 起只在控制台显示。
  - 2026-06：命中缓存的部分按优惠价收。
  - 2026-08：两个 DeepSeek V4 模型每晚 22:00–次日 08:00 半价。
- **包并发：** 按模型买并发槽位、按月付费，找销售，价格不公开。
- **编码套餐：** Lite 40 元/月、Pro 200 元/月，按请求次数计额度。文档已下线。
- **ComfyUI 托管（公开）：**
  - 按秒计费：每秒 0.0028–0.0076 元。
  - 包并发：每个并发每月 1,600–3,580 元。
- **GPU：** 见第 2 节。存储：共享存储 0.0006 元/GiB/小时，云盘 0.007 元/GiB/日。
- **智能体平台：** 积分制，1 元 = 100 积分，充值不退。
- **服务对象：** 2026-07 起只服务企业，不接受个人注册。

3.5 OpenRouter

	免费档	Standard	Business	Enterprise
平台费	—	5.5%	8%	可谈折扣
可用模型	25+ 个免费模型，每天 50 次	500+ 个模型，80+ 家供应商	同左	同左
自带 Key（BYOK）	—	每月 2.5 万美元标价用量内免平台费，超出收 5%	同左	定制
付款方式	—	信用卡、加密货币等	同左	可开票，有合同 SLA
从该档起新增的功能	—	自动路由、预算、缓存、管理 API	欧盟 / 美国境内路由、高级通知	单点登录（SSO）、托管策略、合同 SLA

OpenRouter 自己不卖算力，赚的是平台费。各模型价格就是所选供应商的价格；沐仞如果作为供应商接入，就和硅基流动、Together 在同一个页面上比价。

3.6 Together AI

- **Serverless 推理：** 按 Token 计价，例见 1.2；批量调用 5 折。
- **预留吞吐（Provisioned Throughput）：** 按 Token 计价的预留容量，SLA 99%，起订 1 个月。
- **专属推理：** H100 5.49、B200 8.99 美元/卡时。
- **GPU 集群：** 分可抢占、按需、按天数阶梯预留三种，见第 2 节；181 天以上找销售。
- **其他：**
  - 沙箱 0.0446 美元/vCPU 小时，代码解释器 0.03 美元/会话；
  - 托管存储 0.16 美元/GiB/月；
  - 微调按训练 Token 计价。
- **付款规则：**
  - 全部预付，首次至少充 15 美元；2026-04 取消了用户分级。
  - 创业公司加速器：按融资阶段发 1.5 万 / 3 万 / 5 万美元额度，附现场工程师工时。

3.7 Fireworks AI

- **Serverless 按速度和区域分四档：**
  - Standard：基础价。
  - Priority：多数模型约为基础价的 1.25 倍（个别 1.5 倍）。
  - Fast：基础价的 1.5 倍。
  - US-only（只在美国处理）：基础价的 1.5 倍。
  - 以 Kimi K3 为例：Standard 3 / 15，Priority 3.75 / 18.75，Fast 和 US-only 都是 4.50 / 22.50 美元。
  - 批量调用 5 折。
- **按需 GPU 部署：** 按秒计费，H100 / H200 8 美元/小时、B200 13 美元、B300 15 美元、GB300 20 美元；锁定单一区域加价 50%。
- **预留和私有部署：** 预留吞吐按每分钟美元计价，附 SLA；可部署到客户自己的云（BYOC），合同定价。
- **训练：**
  - SFT / DPO 按训练 Token 计价，每百万 0.5–40 美元。
  - 专属训练按 GPU 小时计价。
  - 微调后的模型按基础模型同价提供推理。
- **账户规则：**
  - 自助用户按累计消费 50 / 500 / 5,000 美元解锁 Tier 1–4。
  - 2026-07 起自助用户一律预付。
  - 创业公司计划送额度；Fire Pass 包周订阅已停止接受新订阅。

3.8 Crusoe

- **GPU 按需价：** 第 2 节列的就是。长约和最低价找销售。
- **CPU、存储、网络：**
  - CPU 0.04 美元/vCPU 小时；
  - 存储 0.06–0.10 美元/GiB/月；
  - 网络进出流量免费；
  - 托管 Kubernetes 0.10 美元/集群小时。
- **托管推理：**
  - Serverless 按 Token 计价，例见 1.2。另有 GPT-OSS 120B 0.05 / 0.25 美元等。
  - 专属部署：H100 6.30、H200 7.50、B200 10.20、B300 13.80 美元/卡时。
  - 预留吞吐：承诺越长越便宜。
  - 微调：每百万 Token 0.40–10 美元。
- **数据中心：** 大型园区建设和长期容量合同，合同制，不公开报价。

3.9 Soluna（以电定址的数据中心）

- **2026 年一季度收入：** 总计 940 万美元。
  - 数据托管 669 万，按项目计毛利率 36–41%；
  - 自营挖矿 217 万；
  - 电网需求响应 54 万；
  - AI 算力 0。
- **整体毛利：** 约 20%【算】。
- **托管怎么定价：** 未公开。
- **第二季度：** 收入 1,510 万美元，其中托管 1,270 万（第三方转述季报）。
- **在建：** AI 园区 Kati 2、Dorothy 3，各规划 300 MW 以上。

3.10 Emerald AI

- **产品：** Emerald Conductor，一个软件平台，用来让数据中心的用电负荷随电网需要灵活调节。
- **客户：** 数据中心开发运营方、电网公司、AI 公司和云厂商。
- **怎么收费：** 官网没有写，未查到公开资料。

4. 收费机制横向对照

机制	DeepSeek	硅基流动	PPIO	无问芯穹	OpenRouter	Together	Fireworks	Crusoe
免费 / 赠金	赠送余额	免费小模型、代金券（需实名）；国际站送 1 美元	未见注册赠金；有初创加速代金券	已取消	25+ 个免费模型	不送；加速器额度	创业计划额度	无
付费方式	预充值	预充值	预充值	预充值，每小时扣费	预充值 + 平台费	全部预付	自助预付	按小时
分级 / 档位	—	L0–L5 用量等级	按量 / Token Plan	基础 / 高级 / 企业	免费 / Standard / Business / Enterprise	—	Tier 1–4 + 四档速度	自助 / 销售
分时价	**工作日高峰全价，其余 5 折**	V4-Flash 凌晨 2–8 点半价；混元白天贵	无	V4 两个型号 22–08 半价	无	无	无	无
批量折扣	无	有批量 API，未见折扣价	限时 5 折	—	无	5 折	5 折	无
缓存价	有	有	有（含写入）	有（价格不公开）	跟随供应商	有	有	有
预留容量 / 包并发	无	预留实例 38.6–77.2 万元/组/月	Token Plan（SLA 99.5%）	包并发，不公开	无	预留吞吐（SLA 99%）	预留吞吐、BYOC	预留吞吐
订阅制	无	无	月度订阅包	编码套餐（已下线）	无	无	Fire Pass（停售）	无
GPU 出租	无	弹性 GPU 测试中	**即将下线**	卡时或包月	无	主营	按秒部署	主营
私有化 / 项目	无	许可 + 实施 + 维保	报价咨询	项目制	无	企业平台	BYOC	数据中心合同

5. 对沐仞的启示【判断】

1. **公开价打折扣，要先算清底线。**
   - 沐仞现行口径是"公开价 4 折起"。如果"公开价"指 DeepSeek 官方高峰价，V4 Pro 打 4 折是 3.6 / 10.8 元。
   - 这比官方非高峰价（4.5 / 13.5）还低 20%【算】，也低于 PPIO Token Plan 的"低至 4.5 折"。
   - 同行的单价基本由模型厂标价决定，硅基和 PPIO 的公有云业务毛利都是负的或个位数。这个折扣能否长期兑现，取决于电站侧的成本优势有多大。
2. **峰谷定价已有人在做，但没人按电价做。**
   - DeepSeek：工作日白天高峰全价，其余 5 折。
   - 硅基：凌晨半价，混元白天加价。
   - 无问：夜间半价，只限两个型号。
   - 这三家都是按用户需求的高峰低谷定价，没有一家把价格和电价、绿电出力挂钩。沐仞可以把价格时段对齐电站出力和电价曲线，并在账单上写明产地。这是现在还没人占的位置。
3. **企业产品的通行形态是"月度预购 + 团队管理 + SLA"。**
   - PPIO Token Plan：月包、4.5 折、200 席位、成员预算。
   - 硅基预留实例：公开月价，折合 2–9 元/M。
   - Together / Fireworks 预留吞吐：附 SLA。
   - 沐仞"企业先试用后签约开户"之后，可以接一个月度 Token 包或预留产能产品，并公开起步价。
4. **免费拉新在收紧。** Together、Fireworks、无问、硅基都改成了预付、实名或取消赠送，PPIO 只给初创计划发代金券。沐仞的试用额度应该定额、需要认证，并绑定案例回报。
5. **GPU 出租的价格带已经很清楚，PPIO 正在退出。**
   - 海外 H100：可抢占 1.99 美元到按需 4.50 美元/卡时；托管部署 5.49–8 美元。
   - 国内：无问 8 卡 H100 包月折合约 18.8 元/卡时。
   - 沐仞一体机如果对外出租算力，可以拿这组数对标；但从 PPIO 退出、硅基公有云亏损看，裸算力出租的利润很薄。
6. **能源背景没有换来更低的 Token 价。**
   - Crusoe 的 GLM-5.3 价格和别家一样，都是 1.40 / 4.40 美元。
   - Crusoe 和 Soluna 赚钱靠卖算力、托管和长约，不靠 Token 降价。
   - 沐仞的绿电优势要转成价格，需要说清是哪部分成本更低，以及低多少。

6. 待核实

项目	情况
无问芯穹现行模型单价、包并发价格	需要企业账号登录控制台
PPIO Token Plan 起购金额、各模型抵扣系数；Agent 沙箱价格；GPU 云下线时间	价格页未列
硅基流动用量等级 L0–L5 的具体门槛	本次未重新核对
Together 收入结构、Crusoe 和 Soluna 托管的具体单价	未公开；Together 只有第三方估算
Emerald AI 怎么收费	未公开
价格时效	各平台调价频繁（Fireworks 10-01、DeepSeek 刚改型号），引用前要重新抓取