硅基流动、Together AI、Fireworks AI：扩张时间线、赚钱方式与营销打法

沐仞科技内部竞品调研 | 与《无问芯穹》2026-10-14 版同一框架

0. 先看结论

一张表看四家（含上一份的无问芯穹作参照）

	硅基流动	Together AI	Fireworks AI	无问芯穹（参照）
成立	2023-08，北京	2022-06，旧金山	2022，加州	2023-05，上海
核心生意	Token API 加本地部署软件，2026 年起加"Token 工厂"联合运营	GPU 集群出租加开源模型推理 API，覆盖训练到推理全周期	开源模型推理，加上用客户自有数据训练专用模型	异构算力云、Token API、政府和国资算力平台
最新估值	投后 77.4 亿元（B+ 轮，2026-06）	投后 83 亿美元（C 轮，2026-07）	投后 175 亿美元（D 轮，2026-07）	上市前约 143 亿元
收入口径	2025 年 5,533 万元（审计）	上季度年度 bookings 超过 11.5 亿美元；年化收入 12 亿美元	年化收入超过 10 亿美元，同比约 5 倍	2024 年超过 8,500 万元（清华材料，非审计）
估值约为收入的几倍	约 140 倍（对 2025 年收入）	约 7 倍（对年化收入）	约 17.5 倍（对 ARR）	不可比
毛利	总体 −24.0%；公有云 −119.0%；本地部署 82.5%	约 45%	约 50%【媒·The Information 转述】；CEO 称 30–40%（节目摘要）	未披露
盈亏	2025 年净亏损 3.45 亿元	未披露	未披露	未披露
股权融资合计	约 19.5 亿元，7 轮	约 13.3 亿美元，5 轮	约 18.3 亿美元，4 轮	43 亿元
算力从哪来	以短租第三方为主，正转长约；2026-06 签 60 个月、总价 34.91 亿元的算力协议	租赁加伙伴共建（Hypertec、IBM、HUMAIN）；C 轮另有新投资人在表外承担 500 MW 以上的算力投资	不自有，从 20 多家云租用（Oracle、AWS、Crusoe、微软、AMD）	长租第三方，三份长约合计 7.35 亿元
上市	2026-06-30 按港交所 18C 章递表，尚未聆讯	未见 S-1	未见	据传已秘密递表港交所
和沐仞的关系	**国内正面对手**：API、联合运营分润、出海三条线都重叠；同时是**电站侧算力的潜在买家**	**海外替代品**：沐仞出海卖中国模型，客户的另一个选择就是它	**海外替代品**：同上；它的算力供应商里有能源型云 Crusoe	国内对手兼潜在买家

你的几个问题，三家各自的答案

- **产品线怎么扩张的?**
  - 硅基流动：开源加速工具 → 公有云 API → 企业专属实例和私有化 → 海外 → 联合运营"Token 工厂"。
  - Together：开源研究 → API → GPU 集群 → 训练和评测 → 收购代码沙箱与数据工具 → AI Factory。
  - Fireworks：推理 API → 专用部署 → 训练闭环 → 多云 → 抢企业的 AI 编程预算（第 2、3、4 节有泳道图）。
- **主要怎么赚钱?**
  - 硅基流动：2025 年收入一半来自公有云（按 Token 计费和专属实例），一半来自本地部署软件。只有本地部署赚钱。
  - Together：第三方估算大头是 GPU 集群出租，API 约占三到四成。
  - Fireworks：按 Token 计费、按 GPU 秒计费、预留容量和训练。
- **赚的钱多吗?**
  - 硅基流动：小。2025 年收入 5,533 万元，净亏 3.45 亿元。
  - Together 和 Fireworks：年化收入都已超过 10 亿美元，但都没有公开利润。
- **是不是纯靠融资?**
  - 硅基流动：基本是。经营现金流 −1.72 亿元，靠 7 轮融资维持。
  - Together 和 Fireworks：收入已经是真钱，但扩张算力仍然靠融资和表外资本。
- **为什么能融这么多?**
  - Fireworks：16 个月内 ARR 从 1 亿美元涨到超过 10 亿美元。
  - Together：研究品牌，加上算力和电力的规模化能力。
  - 硅基流动：咨询机构给的"独立生态第一"排名、国产芯片适配，加上大量产业资本入股（阿里、华为哈勃、美团、晶科能源、联通、携程等）。
- **Marketing 怎么做?** 四家有一套共同打法：新模型首发、接入编码工具、上聚合渠道、从免费转向预付、分档定价、用研究成果做营销。各家的不同点在第 5 节。

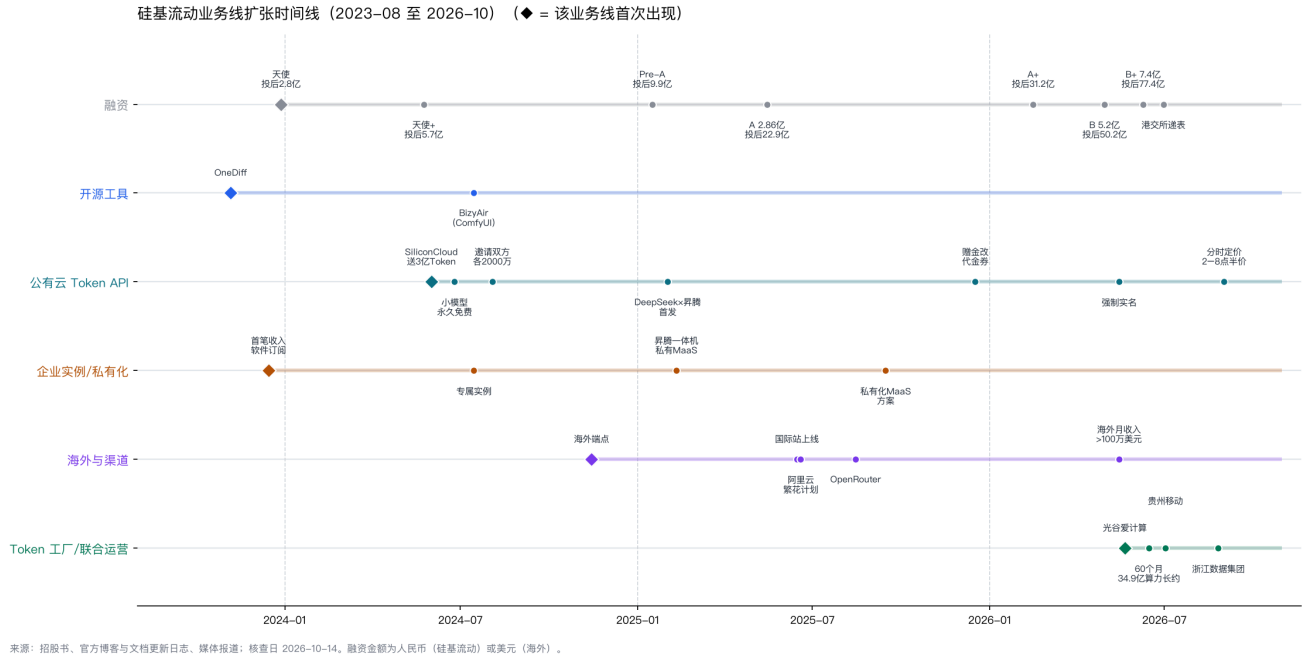
1. 和沐仞的关系：国内一个正面对手，海外两个替代品

1. **硅基流动的"Token 工厂 / AI 算力运营服务"和沐仞的模式直接撞上。**
   - 2026-05-21 起，它连续与光谷爱计算、贵州移动、京算、浙江省数据集团签约。做法是把推理引擎和编排能力卖给算力持有方，再按服务量分成。
   - 沐仞 BP 的做法是"资产方投资一体机、沐仞运营分润"，结构相同。区别在于对方找的是已经有 GPU 的智算中心和运营商，沐仞找的是电站。
   - 沐仞要赶在硅基流动之前签下能源方，否则电站侧的"算力运营权"也会被它这类平台拿走。

2. **硅基流动也是电站侧算力的潜在买家。** 2026 年 6 月，它与一家第三方签了 60 个月、总服务费 34.91 亿元的算力服务协议，约是它 2025 年收入的 63 倍。这说明它在大规模锁定算力；无问芯穹此前也向金开新能伊吾买过算力。
3. **硅基流动的出海线是沐仞出海最直接的对手。**
   - 国际站 2025-06 上线，2025-08 上了 OpenRouter。
   - 海外收入 2025 年只占 3.7%，但 2026-05 海外单月收入首次超过 100 万美元。
4. **Together 和 Fireworks 是海外 Token 市场的头部，也是沐仞海外客户的替代选项。**
   - 两家主力销售的都是中国开源模型。Together 的 C 轮材料点名了 DeepSeek、Kimi、MiniMax、GLM；Fireworks 首推的 serverless 模型里多数是中国模型。
   - 两家卖中国模型时都强调"美国托管、零数据留存"，Fireworks 的美国专属版贵 1.5 倍。
   - 沐仞在"美国托管"上竞争不了。更现实的客户是不在意或更偏好亚洲节点的客户：出海中企、东南亚客户、对价格敏感的批量任务。这和沐仞自述海外订单八成以上来自新加坡等地的结构一致。
5. **海外的分工更清楚：能源型云 → 推理平台 → 应用。**
   - Fireworks 的大规模 GPU 跑在 Crusoe 上（Crusoe 是以能源为切入点的云）。Together 早在 2023 年就和 Crusoe 合作过油田伴生火炬气发电的 GPU。
   - 这验证了"能源方做算力供给、平台做 Token"的分工。但出于数据驻留和出口管制的原因，美国平台基本不会用中国境内的算力。沐仞在国内的供给对象仍是硅基流动和无问芯穹这类平台。

2. 硅基流动

2.1 扩张时间线



硅基流动业务线泳道图。◆ 为该业务线首次出现。

日期	事件	业务线
2023-08-29	公司成立。创始人袁进辉此前创办的 OneFlow 已被收购，这是二次创业	公司
2023-11	OneDiff 扩散模型推理加速开源，分社区版和企业版	开源工具
2023-12	首笔收入，来自软件订阅	本地部署
2024-05/06	SiliconCloud 按 Token 计费的 API 上线；06-01 公测，送 3 亿 Token	公有云
2024-06-25 后	OpenAI 停止对华服务，它随即宣布 Qwen2-7B 等小模型"永久免费"，新用户送 2,000 万 Token	公有云获客
2024-07	专属实例上线；BizyAir（ComfyUI 云节点）上线；成为沉浸式翻译首个官方接入的大模型云	企业、AIGC、生态
2024-08-03	邀请活动：双方各得 2,000 万 Token，不设上限	获客
2025-02-01	与华为云在昇腾上联合首发 DeepSeek-R1/V3，约 10 小时后被迫限流	公有云、国产芯片
2025-02-10	推出企业级四种模式：昇腾专属实例（16 卡 9 万元/月）、算力纳管、私有版 MaaS、昇腾 910B 一体机	私有化
2025-06	国际站上线并做品牌焕新；同月加入阿里云"繁花计划"，API 接入阿里云百炼	海外、渠道
2025-08	成为"头部 AI 模型路由平台"的供应方，OpenRouter 上现列 42 个模型	海外渠道
2025-12	赠送余额改为代金券	获客收紧
2026-04	单日 Token 峰值首次超过 1 万亿；注册用户超过 1,000 万	规模
2026-05-15	未实名账户不能再使用平台	合规
2026-05 至 08	Token 工厂联合运营陆续签约：光谷爱计算、贵州移动、京算、浙江省数据集团	联合运营

日期	事件	业务线
2026-06	签 60 个月、34.91 亿元的算力协议；以 4,450 万元收购北京一流科技（OneFlow）的知识产权；B+ 轮融资后投后 77.4 亿元	供给、资本
2026-06-30	按港交所 18C 章递表	资本
2026-09-01	DeepSeek-V4-Flash 改为分时定价，北京时间 2–8 点约半价	定价

扩张逻辑

1. 先用 OneFlow / OneDiff 积累的推理加速能力证明”快”，再把引擎包装成按 Token 计费的 API。
2. 用免费小模型、赠金和邀请做开发者漏斗，再靠首发热门开源模型制造流量峰值。
3. 2025-02 的”DeepSeek × 昇腾”把卖点从”快、便宜”升级为”国产芯片能用”，由此打开政企本地部署市场。
4. 招股书自己的说法是先落地再扩张：公有云负责获客，私有化和专属实例负责变现。
5. 2026 年把定位抬升为”独立 Token 工厂”，从卖 Token 转向卖”Token 产能”，也就是联合运营加长约锁定算力。

2.2 怎么赚钱、赚多少（招股书，单位：千元）

项目	2024	2025
总收入	7,346	55,330
公有云（占比）	1,069（14.6%）	29,261（52.9%）
其中按 Token 计费 / 专属实例	455 / 614	14,300 / 15,000
本地部署（占比）	6,277（85.4%）	26,069（47.1%）
海外收入占比	6.3%	3.7%
毛利率：总体 / 公有云 / 本地部署	39.4% / −271.6% / 92.4%	−24.0% / −119.0% / 82.5%
算力资源成本（占销售成本）	2,614（58.7%）	59,627（86.9%）
销售及营销费用	6,392	83,743
其中免费代金券对应的算力成本	932	**54,213（占销售及营销费用 64.7%）**
研发费用	64,475	209,176
净亏损 / 经调整净亏损	−81,915 / −54,010	−345,491 / −187,077
经营现金流	−46,510	−172,402
期末现金	49,737	171,533，另有定期存款 100,000

客户与用量：

指标	2024	2025	2026（截至 04-30）
累计注册用户	127,133	9,197,439	10,282,431
按 Token 付费的客户	2,455	716,012	642,866（4 个月）
专属实例客户	7	49	20
本地部署客户	28	20	5
当期最后一个月的日均 Token	478 亿	1,631 亿	5,785 亿
前五大客户收入占比	85.0%	45.0%	—

- **代金券基本等于把收入送了出去。** 2025 年免费代金券对应的算力成本 5,421 万元，约等于当年总收入 5,533 万元。
- **大多数付费客户的消费很小。** 按 Token 计费的收入除以付费客户数，平均每人每年约 20 元。
- **真正赚钱的是本地部署。** 毛利率 82.5%，客户只有 20 家，2025 年平均每家 130 万元。

所以它是”公有云赔钱拉量，本地部署赚钱”。招股书称之后要”结构性减少”发券。

2.3 为什么能融到钱

轮次	协议日期	金额（亿元）	主要投资方	投后估值（亿元）
天使	2023-12-28	0.472	创新工场、耀途、奇绩创坛、王慧文	2.80
天使+	2024-05 至 2025-01	0.658	华为哈勃、360、智谱华章、美团	5.658
Pre-A	2025-01-16	0.715	南京绿涌、普华、耀途	9.85
A	2025-05 至 06	2.86	阿里、哈勃、创新工场	22.86
A+	2026-02 至 03	2.20	纪源、华控、巨人网络、国泰君安系、云天励飞	31.2
B	2026-04-30	5.20	纪源、金蝶、国开科技、万兴等 13 家	50.2
B+	2026-06-09	7.40	携程、**晶科能源（上饶碳和基金）**、壁仞、联通、商汤、中关村科学城、软通等约 22 家	**77.4**

当前持股：袁进辉 14.35%，员工持股平台 30.13%，合计控制 44.48% 的投票权；阿里 7.42%，哈勃 4.07%，创新工场 4.01%。媒体报道的”B 轮超 20 亿元”和”华创资本领投 Pre-A”都与招股书不符，以招股书为准。

估值不断上调的理由（招股书里程碑与竞争优势章节）：

- 业内首家在国产芯片上部署 DeepSeek R1/V3
- 上线海外服务
- Token 量过万亿，注册用户过千万
- 海外月收入超过 100 万美元
- 弗若斯特沙利文的排名：2025 年按 Token 吞吐量计，它是中国第四大 Token 供应平台，市场份额 1.5%，在”独立生态”里排第一。前三名未具名，按描述像火山引擎、阿里云、百度智能云。这份报告由公司支付 55 万元委托编制。

估值是收入的 140 倍，买的不是现在的收入。投资人买的是两样东西：一是”中立的 Token 中间层”在国产芯片和开源模型之间的卡位；二是产业资本各自的上下游需要——芯片（哈勃、壁仞、云天励飞）、应用（携程、金蝶、美团）、运营商（联通），以及能源（晶科能源）。光伏企业入股 Token 平台，对沐仞找能源产业资本是一个可以直接引用的先例。

2.4 Marketing 和销售

公司层的做法

打法	事实
注册赠金	2024-06 送 3 亿 Token，之后新用户送 2,000 万；国际站送 1 美元
邀请裂变	2024-08 起邀请双方各得 2,000 万 Token，不设上限；代金券通过注册、实名、邀请三种方式发
免费小模型	9B 以下部分开源模型免费（如 Qwen3-8B、GLM-4-9B）
首发	国内写”首发上线”；国际站发”Now Live”博客，加上”X vs Y”类对比 SEO 文章
第三方应用预置	近百款应用把它设为内置模型服务商（LangChain、Dify、Cherry Studio、TRAE 等）；69 篇接入教程；“生态共建计划”用代金券换教程、开源项目接入 PR 和 KOL 教学
口号演变	2024 年”更全面、更快、更便宜”、“部署成本降低 10000 倍” → 2025-06”加速 AGI 普惠人类” → 2026 年”独立生态 Token 供应平台”、“Token 工厂”
口碑与创始人	开发者圈称它”赛博菩萨”；创始人网名”老师木”，常被媒体引用
国际站活动	“Summer Rush”：按调用量排名，在 X 晒单、Discord 发头衔，奖品是代金券
高校与活动	10 余个支持项目，覆盖创业营、校园、黑客松、海外路演，累计 Token 资助约 140 万元

每条产品线怎么推

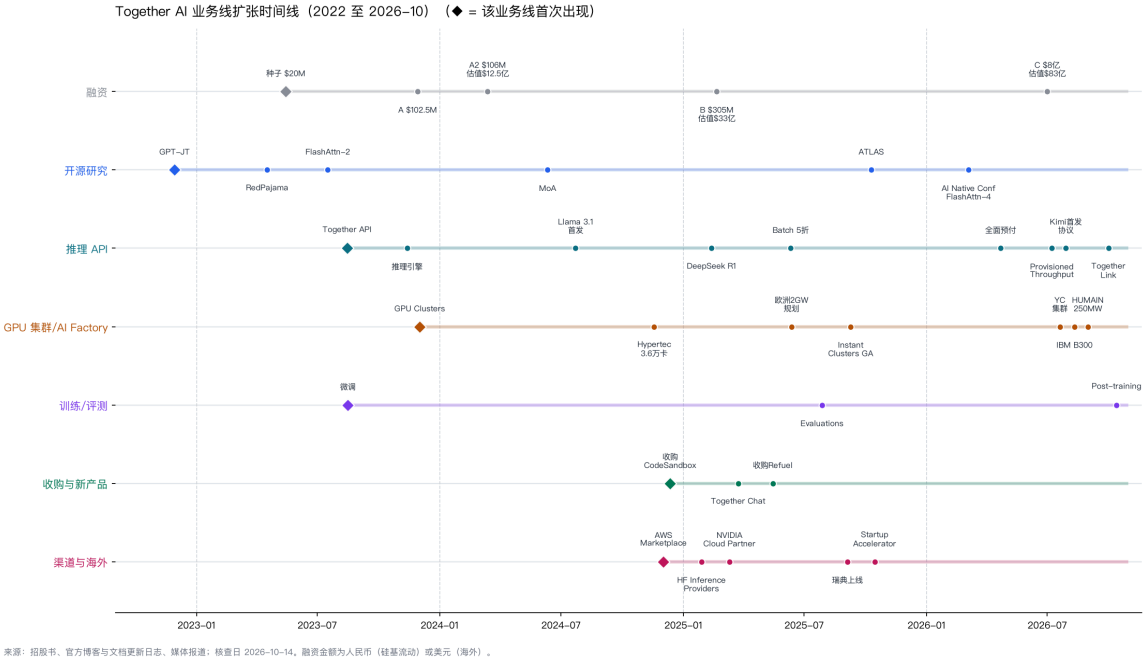
产品线	目标客户	获客动作
公有云按量计费	个人开发者、中小企业、AI 应用	赠金、邀请、免费小模型、首发、应用预置、教程
专属 / 预留实例	时延敏感的企业	公开报价并附性能参考（如 GLM-5.1 高性能规格 77.22 万元/组/月），从按量服务平滑升级
本地部署（私有 MaaS、一体机、AI 网关）	能源、金融、电信、政企	与昇腾、沐曦、摩尔线程绑定；客户证言。前五大客户多为系统集成商，说明大量走集成商渠道
Token 工厂联合运营	智算中心、运营商、国资数据集团	联合运营、按服务量分成、签约发布会
国际站	海外开发者	1 美元赠金、后付费、OpenRouter、X 和 Discord 活动、多语言 SEO、新模型先在海外上

销售体系

- **公有云自助**：注册 → 实名（2026-05 起强制）→ 预充值 → 生成 API Key。按月消费分用量等级，等级决定限流。
- **团队**：2025 年末全员 100 人，其中销售和市场 21 人，按业务线和客户层级划分。直销加渠道伙伴，没有传统经销商。
- **本地部署收费**：许可费 + 实施费 + 维保费，可订阅也可买断。
- **海外**：计划招聘海外销售和售后人员，并设本地分支。

3. Together AI

3.1 扩张时间线



Together AI 业务线泳道图。

日期	事件
2022-06	成立。创始人：Vipul Ved Prakash（CEO）、Ce Zhang、Chris Ré、Percy Liang
2022-11 至 2023-04	GPT-JT（去中心化训练）、OpenChatKit、RedPajama 1.2T 数据集，先在研究圈攒认知
2023-07-17	Tri Dao 加入任首席科学家，发布 FlashAttention-2
2023-08	Together API 上线（推理 + 一条命令微调）；12 月形成推理、微调、GPU 集群、定制模型四条产品线
2024-07	Inference Engine 2.0；Llama 3.1 首发合作方
2024-11-18	与 Hypertec 共建 3.6 万卡 GB200 集群
2024-12	上架 AWS Marketplace；收购 CodeSandbox，推出 Code Interpreter
2025-01 至 03	Hugging Face Inference Providers 首批 4 家之一；DeepSeek-R1 serverless 和 Reasoning Clusters 上线；成为 NVIDIA Cloud Partner；推出 Together Chat（免费用 R1，托管在北美）
2025-05-15	收购 Refuel.ai（数据结构化）
2025-06	Batch API 打 5 折；欧洲规划最多 2 GW、近 10 万张 GPU
2025-09 / 10	瑞典节点上线；Instant Clusters 正式可用；ATLAS 推测解码；Startup Accelerator 启动
2026-03	由 Pentagram 做品牌升级，改称"AI Native Cloud"；首届 AI Native Conf 发布 FlashAttention-4 和 RL API
2026-04-22	全面改为预付费，取消用户分级
2026-07	C 轮 8 亿美元，投后 83 亿美元（07-01）；Provisioned Throughput（按 Token 计价、99% SLA、1 个月起订）；与 YC 合作短期专属集群；与月之暗面（Moonshot）战略合作，从 Kimi K3 起其开源模型都在 Together 首发（07-29）
2026-08	与 IBM 签多年协议，在 IBM Cloud 建 B300 推理集群（合同 2.4 亿美元，Reuters）；与沙特 HUMAIN 合建 250 MW 数据中心
2026-10	Together Link：在 Claude Code、Codex 里换用开源模型；Post-training 支持自写训练循环

扩张逻辑

1. 先用研究攒信誉（RedPajama、FlashAttention），再推 API 开始收费。
2. 从 API 出发向两个方向延伸。向下做 GPU 集群和 AI Factory，用伙伴的电力和资本补算力；向旁边做微调、评测、RL 和 post-training，覆盖模型的全生命周期。
3. 推理产品按承诺强度排成阶梯：serverless → batch → provisioned throughput → 专用模型 → 预留集群 → AI Factory，把按量收入逐步变成合约收入。
4. 模型供给从以 Llama 为主转向以中国开源模型为主，并用与月之暗面的协议锁定首发权。

3.2 怎么赚钱、赚多少、靠不靠融资

时点	收入口径
2024-02	年化约 3,000 万美元
2025-02	年化超过 1 亿美元；公司称业务同比增长 6 倍
2025 年夏	年化超过 3 亿美元
2026-02/03	年化约 10 亿美元
2026 Q2	年度 bookings 超过 11.5 亿美元（bookings 不等于收入）；年化收入 12 亿美元

- **收入线**：

- serverless 按 Token 计费（Batch 打 5 折）
- Provisioned Throughput
- 专用推理（按 GPU 小时）
- GPU 集群：H100 可抢占 1.99 美元、按需 3.99 美元、181 天以上预留 3.19 美元/卡时
- 微调
- 沙箱
- 存储

公司从未披露各线占比。Sacra 估计 2026 年 API 占三到四成，**其余是 GPU 出租**。

- **毛利和盈亏**：毛利约 45%，盈亏未披露，没查到 GPU 抵押贷款。
- **算力和电力**：主要靠伙伴共建或租赁（Hypertec、IBM、Rumble 2.7 亿美元 B300 合同、HUMAIN）。C 轮说明写明，另有 500 MW 以上的算力承诺"由新投资人独立出资"。也就是说，算力扩张的重资产部分被放到了表外。
- **靠不靠融资**：收入是真的，量级已在 10 亿美元以上。但算力扩张同时靠股权（累计约 13.3 亿美元）和投资人的表外资本。是否盈利没有任何披露。

3.3 为什么能融到钱

日期	轮次	金额	估值	领投
2023-05	种子	2,000 万美元	—	Lux
2023-11	A	1.025 亿美元	—	Kleiner Perkins（NVIDIA 跟投）
2024-03	A2	1.06 亿美元	12.5 亿美元	Salesforce Ventures
2025-02	B	3.05 亿美元	33 亿美元	General Catalyst、Prosperity7
2026-07-01	C	8 亿美元	投后 83 亿美元	Aramco Ventures（经 Prosperity7）

投资人的理由（转述）：

- Salesforce Ventures：客户为 GPU 而来，因为工作流服务和研究而留下。
- General Catalyst：不到两年就有了财富 100 强客户。
- Prosperity7：AI 基础设施是未来十年最大的基建工程。
- Emergence：开源会成为企业扩张 AI 的默认选择。
- 施耐德电气旗下的 SE Ventures：AI 与能源基础设施正在融合。

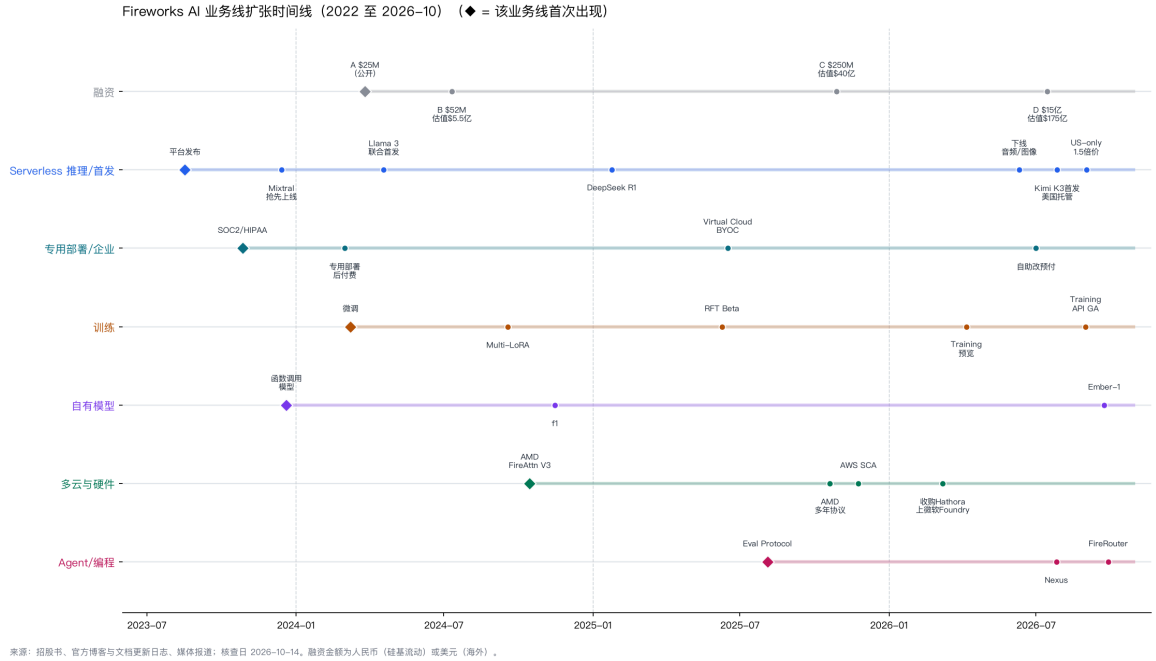
估值约为年化收入的 7 倍，明显低于 Fireworks。原因是它的收入里 GPU 出租占比高，毛利更像算力云。它的资本吸引力在于"研究 + 规模化算力和电力"：中东资本（Aramco、HUMAIN）愿意用表外资金和电力换它的平台能力。

3.4 Marketing 和销售

- **口号演变**：
  - 2023："去中心化的 AI 云"
  - 2023-08："开发者用开源 AI 构建的云服务"
  - 2023-12："最快的生成式 AI 云平台"
  - 2024-08："AI Acceleration Cloud"
  - 2026-03："AI Native Cloud"
- **研究就是营销**：首页常驻研究栏目，FlashAttention-4 和 ATLAS 挂在首页公告条上；ICML 2026 发了 9 篇论文并设展台；自办 AI Native Conf。
- **首发**：Llama 3.1 和 Llama 4 的首发合作方；2026 年起转为绑定中国实验室（月之暗面）。招聘里专门设了"美国模型实验室合作经理"，职责写明要拿首发。
- **成本对比内容**：DeepSWE 系列比较 Kimi K3、GLM-5.3、DeepSeek V4 与闭源模型的单题成本。Together Link 主打支出降一半以上，并公布了 OpenRouter 上的份额：截至 2026-09-30，DeepSeek V4.1 Flash 的 Token 有 40.8%、GLM 5.3 Flash 有 28.2%、Kimi K3 有 23.1% 由 Together 承接（公司自述，已核对原文）。
- **渠道**：AWS Marketplace（可抵扣 AWS 承诺消费）、Hugging Face Inference Providers、NVIDIA DGX Cloud Lepton、Vercel 集成、YC、OpenRouter。
- **免费额度改成加速器**：现在没有免费试用，首充至少 15 美元。额度改由 Startup Accelerator 按融资阶段分档发放：Build 档最高 1.5 万美元 + 3 小时现场工程师，Scale 档最高 3 万美元 + 6 小时，Grow 档最高 5 万美元 + 10 小时，并附联合推广（GTM）。
- **活动**：参加 GTC、AI Engineer World's Fair、NeurIPS 等；自办 Together Table 高管晚宴（针对重点客户的 ABM 打法）；和月之暗面合办 Kimi K3 线上发布会。
- **客户案例**：Cursor、Decagon（每轮成本是 gpt-5 mini 的 1/6）、ElevenLabs、Salesforce（延迟降一半）、Zoom、Washington Post 等。
- **销售体系**：
  - 预付自助，配合 Sales Development Engineer 把自助用户转成大单。
  - 战略客户经理（Strategic AE）带解决方案架构师、现场工程师和研究团队做 POC。
  - 预留集群按 3–30 天、31–90 天、91–180 天分档报价，181 天以上联系销售。它把"几周承诺期、不必签两年合约"当作卖点。
  - Greenhouse 上共 75 个岗位，其中有新加坡中文现场工程师、EMEA 销售。

4. Fireworks AI

4.1 扩张时间线



Fireworks AI 业务线泳道图。

日期	事件
2022	成立，7 位联合创始人，多数来自 Meta PyTorch 团队
2023-08-17	GenAI 平台发布：快速推理 API 加 LoRA 微调模型托管
2023-10 / 12	通过 SOC 2 Type II 和 HIPAA；Mixtral 官方发布前就已上线；函数调用模型 Alpha
2024-01 至 06	FireAttention 引擎；专用部署（按 GPU 秒计费）加后付费；微调；与 Meta 首发 Llama 3；H100 按需部署
2024-07-11	B 轮，叙事转向”compound AI”（复合 AI 系统）
2024-10 / 11	FireAttention V3 专为 AMD 优化；发布自有推理模型 f1
2025-01-24	DeepSeek R1 上线
2025-05 / 06	首届 DevDay；强化微调（RFT）Beta；Virtual Cloud（18 个以上区域、8 家云，支持客户自有云 BYOC）
2025-08 / 10 / 11	开源 Eval Protocol；启动创业公司计划；与 AMD 签多年协议；RFT 全面推出；与 AWS 签战略合作协议
2026-03	收购 Hathora（全球算力编排）；上线微软 Foundry
2026-06-10	下线音频推理和图像生成（主动收缩）
2026-07	D 轮 15.05 亿美元，投后 175 亿美元，ARR 超过 10 亿美元（07-15）；自助账户改预付（07-01）；推出 Nexus，抢企业的 AI 编程预算（07-26）；Kimi K3 首发，主打”美国托管、零数据留存”（07-27）
2026-08 / 09	Training API 正式可用；美国专属 serverless 按 1.5 倍收费；推出自有基准 SII 和自研模型 Ember-1；FireRouter 路由
2026-11-03（计划）	首届 Forge 大会，讲者包括黄仁勋

扩张逻辑

1. 先用推理规模换来客户和数据，再用训练把客户留在平台上（RFT、Training API、“拥有你自己的专用智能”）。
2. 用路由产品（Nexus、FireRouter）把竞争对手从其他推理平台换成闭源大模型厂商的账单。
3. 不自建机房，靠多云、AMD、收购 Hathora 和数据驻留选项来保证容量和合规。
4. 敢于收缩：下线音频和图像，serverless 上的旧模型成批下架，GPU 集中给热门模型。

4.2 怎么赚钱、赚多少、靠不靠融资

时点	数据
2025-07	年化收入超过 2 亿美元，毛利约 50%，目标 60%
2025-10-28	ARR 超过 2.8 亿美元；日处理超过 10 万亿 Token；超过 1 万家公司使用
2026-05-27	年化收入超过 8 亿美元
2026-07-15	ARR 超过 10 亿美元，同比约 5 倍；日处理超过 40 万亿 Token；称 95% 以上的 Token 来自客户专用化模型
2026-07	16 个月内 ARR 从 1 亿美元涨到超过 10 亿美元

- **收入线**：
  - serverless 按 Token 计费，分 Standard / Priority / Fast / US-only 四档，Batch 半价
  - 按需 GPU 按秒计费（H100 8 美元/小时、B200 13 美元/小时）
  - 预留吞吐（按美元/分钟购买，带 SLA）
  - BYOC

- 训练（按 Token 或 GPU 小时）

各线占比未披露。

- **客户集中度**：CNBC 报道 Cursor 一度贡献其一半以上的收入，CEO 称现在已经分散得多。
- **毛利**：约 50%，原因之一是要为需求高峰预留闲置 GPU（The Information 转述）。CEO 在 20VC 节目里称当前 30–40%，这条来自节目摘要，未核对原始音频。
- **盈亏**：未查到。
- **算力**：不自有 GPU，租用 20 多家（Oracle、AWS、Crusoe、微软、AMD 优选云等）。Crusoe 案例称能短时间交付数千个节点，Fireworks 的 GPU 规模一年增长 10 倍。
- **靠不靠融资**：收入和增长都是真的。但毛利只有三到五成，算力全靠租，D 轮的钱主要用来买 GPU 和扩算力。规模越大，越依赖资本市场给算力扩张续命。

4.3 为什么能融到钱

日期	轮次	金额	估值	领投
2022 投，2024-03 公开	A	2,500 万美元	—	Benchmark（红杉跟投）
2024-07-11	B	5,200 万美元	5.52 亿美元	红杉（NVIDIA、AMD 跟投）
2025-10-28	C	2.5 亿美元	投后 40 亿美元	Lightspeed、Index、Evantic
2026-07-15	D	15.05 亿美元	投后 175 亿美元	Atreides、Index、TCV
2026-09	新一轮洽谈	—	曾考虑 300 亿美元	The Information，未证实

投资人的理由（转述）：

- 红杉：市场从训练转向生产推理；看重 PyTorch 原班团队。
- Lightspeed：客户想”拥有”自己的 AI 栈。
- Index / Atreides：闭源模型和开源模型会并用，专用模型会成为企业的默认选择。
- Bessemer：押注”Token 经济”，训练和推理在同一平台上形成飞轮。

175 亿美元约为 ARR 的 17.5 倍。买的是三样东西：SaaS 史上少见的增速、“企业自有专用模型”这个比单纯卖 Token 更有黏性的叙事，以及 PyTorch 团队的工程声誉。

中文媒体关于其估值”1,000 亿 / 1,500 亿美元”的说法是把 Bloomberg 报道的 150 亿美元误译了。

4.4 Marketing 和销售

- **口号演变**：
  - 2023：“Fast, Affordable, Customizable”
  - 2024：“Generative AI tailored to you”、“compound AI”
  - 2025：“Fastest Inference for Generative AI”
  - 2025 年下半年：“Own your AI”
  - 2026-10 首页：“Own Your Specialized Intelligence”，标注”From the Creators of PyTorch”
- **创始人品牌**：CEO 林乔上过 Sequoia Training Data、Hanselminutes、20VC 等播客；首页展示 GTC 2026 上黄仁勋与她的对谈。
- **基准营销**：长期引用 Artificial Analysis 的测速；自建 Real-World Benchmarks（2025-07）和 SII 指数（2026-09）。
- **首发**：Mixtral 官方发布前就上线；与 Meta 联合首发 Llama 3 系列；DeepSeek、Qwen、Kimi、GLM、MiniMax 每次都发上线博文。Qwen 3.6 Plus 在阿里自有基础设施之外只通过 Fireworks 提供。
- **客户案例**：Cursor、Notion（延迟从 2 秒降到 350 毫秒）、Vercel（生成无错率 93%）、Harvey、Upwork、Sourcegraph 等。
- **开发者内容**：cookbooks；llms.txt 和 Docs MCP；“Claude Code pricing”这类 SEO 文章，比 Nexus 早三个月发布；博文里有一排按钮，一键把”Fireworks 是什么”预填进 ChatGPT、Claude 等去问。
- **免费额度**：创业公司计划（成立 5 年以内、融资超过 50 万美元、未到 D 轮），额度 1 年有效；小模型的 RFT 免费；赞助黑客松。
- **社区和活动**：Discord 约 1.3 万人，非企业客户的技术支持走 Discord；DevDay；Forge；赞助 HumanX。
- **渠道**：AWS 战略合作协议（含联合创业计划）、AWS 和 GCP Marketplace、微软 Foundry。伙伴页还列有 BCG、Deloitte 等咨询公司。
- **销售体系**：
  - 自助 Tier 1–4 分别在消费或充值 50 / 500 / 5,000 美元后解锁，更高额度联系销售。
  - 2026-07 起自助改预付，签合同的客户走后付。
  - 招聘页 83 个岗位：客户经理和销售管理 7 个（分 AI 原生团队和企业两条线，含 EMEA）、BDR 3 个、现场工程师 8 个（含新加坡、伦敦）、市场 6 个、合作 4 个（其中一个专门做”AI Factory 伙伴”）。

5. 横向对比：同模型价格、获客打法、融资叙事

5.1 中国开源模型在三家的价格（2026-10-14 抓取，美元/百万 Token，输入 / 输出）

模型	硅基流动国际站	Together	Fireworks
DeepSeek V4.1 Flash	0.15 / 0.60	0.30 / 1.20	0.30 / 1.20（10-01 由 0.22 / 0.66 上调）
DeepSeek V4 Pro（0813）	1.32 / 3.96（最新版 1.50 / 3.135）	1.32 / 3.96	未上 serverless
Kimi K3	2.70 / 13.50	3.00 / 15.00（文档另写 2.70 / 13.50）	3.00 / 15.00
GLM-5.3	1.40 / 4.40	1.40 / 4.40	1.40 / 4.40

模型	硅基流动国际站	Together	Fireworks
GLM-5.3-Flash	0.15 / 0.50	0.15 / 0.50	0.15 / 0.50
Qwen3.8-2.4T（Max）	2.00 / 6.00	2.00 / 6.00	2.00 / 6.00
MiniMax-M3	0.30 / 1.20	0.30 / 1.20	0.30 / 1.20

硅基流动国内站（人民币/百万 Token，输入 / 输出）：DeepSeek-V4-Flash 3 / 9（2–8 点 1.5 / 4.5），V4-Pro 12 / 24，GLM-5.3 8 / 28，Kimi K2.6 6.5 / 27。

- **价格不是这一行的差异点。** 三家同一模型同价，说明海外平台按同一个参考价定价。只有硅基流动在 DeepSeek V4.1 Flash 上便宜一半。
- **差异做在档位上。** 例如 Priority / Fast / US-only、Batch 半价、分时半价、带 SLA 的预留容量。
- **对沐仞的提醒。** 沐仞英文销售册写的"官方价 30–70%"，在这个价格带里会显得很激进。要先确认能否长期兑现，以及客户会不会因此怀疑质量。

5.2 获客打法对照

打法	硅基流动	Together	Fireworks	无问芯穹
免费拉新	大规模赠金和邀请，2025 年代金券算力成本 5,421 万元；之后收紧（实名、改发代金券）	已取消免费，改为按融资分档的加速器额度 + 现场工程师工时	创业公司计划、免费小模型 RFT、黑客松	2024 年送百亿 Token，2026-03 停止免费
计费方式	预充值	2026-04 全面预付	2026-07 自助改预付	企业客户为主
首发	国内首发 + 国际站"Now Live"	与月之暗面签首发协议	Meta、阿里 Qwen 独家等	主流新模型首发上架
编码工具接入	69 篇教程，近百款应用预置	Together Link 接入 Claude Code、Codex	Nexus、FireRouter，直接对准 Claude Code 账单	十余种编码工具教程
聚合渠道	OpenRouter、阿里云百炼	OpenRouter（多个模型份额第一）、HF、AWS	AWS、GCP、微软 Foundry	运营商、地方算力券平台
研究即营销	OneDiff 开源	FlashAttention、ATLAS、论文	FireAttention、自建 SII 基准	清华论文、FPGA 最佳论文
分档定价	分时半价、专属和预留实例	Batch 5 折、Provisioned Throughput	Standard / Priority / Fast / US-only、预留	闲时半价、包并发
线下	签约发布会、高校资助	自办大会、高管晚宴（ABM）	DevDay、Forge	每年 WAIC 旗舰日

6. 对沐仞的七点启示

1. **不要用"便宜"做主张。** 海外三家同模型同价，国内硅基和无问都已经在做分时或闲时半价。沐仞的"峰谷"要讲成"确定性 + 产地凭证"：哪个电站、哪个时段、多少度绿电，而不是"谷时便宜"。后者别家已经在卖。
2. **免费拉新要一开始就设闸门。** 硅基流动 2025 年送出的代金券算力成本约等于全年收入。2026 年四家都在收紧：预付、实名、取消免费。沐仞可以用"认证后定额券"加 Together 式的定向加速器额度，用额度换案例和 logo。
3. **卖承诺阶梯，而不只是卖 Token。** 可以照 Together 的 Provisioned Throughput（按 Token 计价、带 SLA、月起订）和 Fireworks 的分档，设计三档：
   - 绿电时段档
   - 预留产能档（带 SLA）
   - 出海合规档（海外节点、零数据留存）
4. **出海可以先当 OpenRouter 的供应方，但要有差异。** 硅基流动 2025-08 就上了 OpenRouter；Together 在 DeepSeek V4.1 Flash 上拿了 40.8% 的份额。新进入者要在亚洲时延、首发速度或价格上有一项明显领先，同时正面回答数据驻留问题。
5. **供给侧：先把电站锁住。** 四家都不自建机房，都在大规模长约锁算力（硅基 34.91 亿元 / 60 个月、无问 7.35 亿元、Together 表外 500 MW 以上、Fireworks 租 20 多家云）。这对电站侧算力是需求信号。但硅基的"Token 工厂联合运营"也在抢算力运营权，沐仞的窗口在于先签能源方。
6. **融资叙事：增速 + 稀缺卡位 + 产业资本。** Fireworks 讲 16 个月 10 倍；硅基流动讲"独立第一 + 国产芯片 + 产业资本合围"，其中晶科能源已入股。沐仞可以主打能源产业资本（光伏、风电、电网侧），把"电站侧词元产能"讲成能源企业的第二增长曲线。
7. **用研究和数据内容建立信任。** 四家都用技术成果做营销。沐仞可以做"每任务能耗 / 碳排放"和"峰谷成本"类的公开基准或季度报告，把绿电优势变成可量化、可引用的内容。