竞品产品线、定价、解决方案与销路

沐仞科技内部调研 | 四类玩家约 55 家 | 2026-11-02

> **注记**
>
> **怎么读这份报告**：第一部分是结论和对沐仞的建议，约 5 分钟读完；A–D 四组是调研的完整内容，按公司逐一列出产品线、收费方式与价格、解决方案、销路，每条事实都附来源链接（访问日期 2026-11-02）。来源分级：【官方】官网或公告，【媒】媒体报道，【三方】第三方文章，【未核实】只见于单一或二手来源，【算】由公开数字推算。各家几乎每月调价，对外引用价格前请重新核对。

一、结论与对沐仞的建议

一句话结论

单卖 Token 不赚钱；这个行业里赚钱的，是把客户锁进合同的产品：私有化、长约算力，以及和电站、国资的联合运营。 沐仞手里有别人没有的东西，就是电站旁的自有算力和可追溯的绿电，应该围绕它搭产品线，而不是拼 Token 单价。

调研范围

组别	范围	公司数	详细内容
A	国内 MaaS / Token / 推理云平台	13 家	A 组
B	海外推理 / 模型 API 平台与聚合器	12 家	B 组
C	能源与算力结合（国内外）	18 家	C 组
D	私有化一体机与企业智能体	约 14 家 + 9 个中标样本	D 组

四类玩家：卖什么、怎么收钱、谁在赚钱

1. 国内 Token 平台（硅基、PPIO、无问、火山、百炼、千帆、腾讯、七牛等）

- **同模型同价，价格锚是 DeepSeek 官方峰谷价**：V4 Pro 在火山、百度、PPIO 都是 9 / 27 元，阿里和硅基 12 / 24 元。
- **闲时折扣已是标配，但都按需求低谷定在夜里**：阿里 22–8 点低至 2 折；百度「夜享」21–8 点 2 折；七牛 18–8 点按 0.3 倍扣；硅基 2–8 点半价；无问 22–8 点半价。**没有一家按电站出力或电价定价，也没有一家在账单上写绿电来源。**
- **订阅从 Coding Plan 换成 Token Plan**，分个人档（28–600 元/月）和企业档：按席位（阿里 150–1,398 元/席/月）、按月预算（腾讯 5,000–20,000 元/月）、按额度包（PPIO 1,598 / 4,798 / 13,998 元/月）。
- **钱集中在大厂**：IDC 数据，2026 上半年中国 MaaS 市场 106.3 亿元，同比 +889%；私有化部署 28.8 亿元，同比 +108%。
- **独立平台卖 Token 在亏钱**：硅基招股书显示公有云毛利 **−119%**、本地部署毛利 **+82.5%**，2025 年免费代金券成本 5,421 万元，约等于全年收入 5,533 万元；PPIO 整体毛利率 9.4%；并行科技靠智算合同，毛利率 19%。

2. 海外推理平台（Together、Fireworks、OpenRouter、Groq、Baseten、DeepInfra、Modal 等）

- **同样同模型同价**：GLM-5.3 在 Together、Fireworks、Baseten、Novita 都是 1.40 / 4.40 美元。差价来自**服务档位**：加急档约 1.5 倍，指定地区处理 1.15–1.75 倍，Batch 5 折，可中断档 0.8 倍。
- **收入大头是承诺量**：按量 → 批处理 → 包月吞吐 → 专属 GPU → 集群包月 → 多年集群。Together 约 60–70% 收入来自 GPU 租赁（Sacra 估算）；Cerebras 在手合同 254 亿美元。
- **同一张 H100：裸卡 1.70–2.90 美元/时，托管推理 3.95–8.00 美元/时**，差价买的是优化、扩缩容和 SLA。
- **资本只给两头溢价**：纯托管市场 Replicate 被 Cloudflare 以 5,740 万美元现金收购；纯路由 OpenRouter 被 Stripe 收购（传 70 亿美元以上，未核实）。OpenRouter 上中国开源模型用量占比超 50%，支持支付宝，**是沐仞 Token 出海的现成渠道**。

3. 能源与算力结合（Crusoe、Soluna、Emerald AI、Lancium、矿企转型、Nscale；国内大唐、晶科、远景、共绩、特锐德等）

- **海外靠长约容量赚钱**：Hut 8 与 Google 担保的 15 年约 70 亿美元租约（245 MW）；IREN 与微软 5 年 97 亿美元合同，客户预付 20%；Core Scientific 为 CoreWeave 托管约 590 MW。
- **卖电网灵活性现金很少**：Soluna 需求响应只占收入约 6%；Emerald AI 卖的是「用可验证的灵活性换更快并网」，2026-08 以 10.5 亿美元估值融资 1.5 亿美元，未公开价格。
- **国内发电企业正在自己做算力**：大唐中卫、晶科中卫 1 GW 约 245 亿元、甘肃电投与中能建庆阳、远景目标 5 GW。它们有电有地，缺算力运营、调度和售卖，**是沐仞「联合运营 / 私有化部署整套系统」的天然买家**。

- **城市级平台开始按任务发碳溯源证书**（扬州 24 个算力池、撮合超 100 万元），沐仞产地卡应对接而非另起一套。
- **共绩科技是叙事上最近的对手**：清华背景，主打「闲时算力、算电协同、以算代储」，2026-05 近亿元 Pre-A；轻资产聚合别人的闲置卡，可抢占价比按需低约 40%。沐仞的区别是电站旁的自有一体机，能拿到确定的绿电与电价。

4. **私有化一体机与企业智能体**（华为昇腾伙伴、浪潮、联想、新华三、讯飞、智谱、Dify 等）

- **一体机都不公开价格**，真实价格看中标：超聚变单台 68.6 万元；广西北部湾银行 671B 满血 358 万元（约 11 万元/卡【算】）；国信证券两台 568.2 万元；讯飞两套 968 万元。低端已卷到 25 万元左右，传闻 14.9 万元【未核实】。2025 年 2 月已有 60 多家厂商卖 DeepSeek 一体机。
- **付费三段式**：硬件买断 + 平台许可（多捆绑）+ 实施运维（按人天或「3 年 7×24」写进标书）。
- **招标按「模型 × 精度 × 并发 × Token/秒」写**，不写卡数；多数标由集成商或运营商中，厂商供货。
- **几乎没人公开「租一体机 + 按月运维 / 按 Token 计费」的订阅价**，最接近的是 FastGPT 私有化 1 万元/月——**这是空位**。
- 软件参考价：Dify 企业版 AWS 中国 50 万元/年；NVIDIA AI Enterprise 4,500 美元/GPU/年。
- **私有化撑可信度、不撑增长**：智谱私有化收入占比从 73.7% 降到约 13.5%，API 升到 86.5%（媒体报道，口径不一）。

收费方式全景

收费方式	代表	价格区间	对沐仞
按量 Token	全部平台	同模型基本同价	已有，只作引流
分时 / 闲时折扣	DeepSeek、阿里、百度、七牛、硅基、无问	0.2–0.5 倍	改为按电站出力定价
服务档位（加急 / 批处理 / 可中断）	Fireworks、DeepInfra、Groq、Together	0.5–1.75 倍	可直接借用
Token Plan 订阅	阿里、腾讯、PPIO、七牛	个人 28–600 元/月，企业 5,000–20,000 元/月	建议做
包月吞吐 / 预留实例	Together、硅基	1 个月起，99% SLA	建议做
GPU 时租 / 专属集群	Together、DeepInfra、Crusoe	H100 1.7–8 美元/时	一体机产能可出租
一体机买断 + 运维	华为伙伴、浪潮、讯飞	单台 25 万–数百万元	已有，补订阅版
私有化软件许可	Dify、FastGPT、NVIDIA AIE	12 万–50 万元/年	世界模型许可
长约容量 / 托管	Hut 8、IREN、Core Scientific	约 140–190 万美元/MW/年【算】	电站侧中长期
联合运营分成	硅基 Token 工厂、并行科技、Lancium	未公开	已有，补标准方案
电网调节收入	Soluna、国网上海	收入占比小	附加项

销路规律

销路	谁在用
开发者自助：免费模型、代金券、预装进 Dify / Cherry Studio	硅基、PPIO、海外全部
大厂高额渠道激励：阿里卖 1 万元 Token 给 1:1 业绩，伙伴打包 Agent 抽 30%；火山 Token 提成是云产品 10–20 倍【媒】	阿里、火山
集成商、运营商代理中标	一体机全行业；硅基前五大客户多为集成商
与运营商、国资联合运营 / 合资建中心	硅基 Token 工厂、并行科技（湖北科投、光明科学城）
云市场上架、抵扣云承诺额	Dify（AWS）、Baseten

销路	谁在用
做聚合平台的供应商	OpenRouter 上各家托管商
长约 + 大客户担保 / 预付	Hut 8（Google 担保）、IREN（微软预付 20%）
模型首发合作	Together（月之暗面）、fal（字节、可灵）

对沐仞的建议：四条产品线

产品线 1 · 绿色 Token（引流和规模，不指望利润）

- 价格按**电站出力**分三档：实时档原价；可延后档排进绿电时段打折；可中断档只在弃电时段跑，最便宜。低价时段是**中午光伏大发**，正好与别家的夜间低价错开。
- 加 **Token Plan 订阅**（个人档 + 企业额度包）和**包月吞吐**（承诺用量换折扣与 SLA）。
- **出海**：在 OpenRouter 上做供应商，加上自有的 Token 出海批复通道。

产品线 2 · 一体机与私有化（利润最高）

- 型号按「模型 × 并发 × Token/秒」定义，附实测性能表，对付「量化冒充满血」。
- 两种买法：**买断**（硬件 + 3 年运维）；**订阅**（一体机租赁 + 按月运维 / 按 Token 计费，市场空位）。
- 企业智能体作为附加服务，按席位或项目收费；投标与集成商组成联合体。

产品线 3 · 电站与能源企业解决方案（护城河）

- 联合运营分成：电站出地和电，沐仞出设备与运营（参考 Lancium「电力房东」、硅基 Token 工厂）。
- **算电世界模型私有化许可**：一次性部署费 + 按管理 MW 数收年费；同行无公开价，定价权在我们手里。
- 一体机集群接入虚拟电厂拿调节补贴，作附加收入；大合同争取预付或第三方担保来融资设备。

产品线 4 · 绿电与碳凭证

- 每单产地卡对接城市级碳溯源平台，给需要 ESG 披露的企业做成付费增值项。

建议停下的三件事

1. 不再以「最低几折」作主卖点：七牛「包年 4 折 × 闲时 0.3 倍」叠加约 1.2 折【三方】，比「4 折起」还低，拼价格拼不过。
2. 少发免费代金券：硅基代金券成本约等于全年收入。
3. Claude 转售先确认上游授权与合规，再决定是否公开展示。

需要后续核实的关键缺口

- 一体机官方价目表均未公开，中标价约一半来自媒体转载，对外引用前请到中国政府采购网核对原公告。
- 腾讯 Token Plan、百度 Token Plan 四档价格、火山 TPM 保障包、共绩 / 蓝耘 / 胜算云价格未公开或未能打开。
- Emerald AI、特锐德、Lancium 未公开价格；国家电投、三峡、中核的算力项目细节未查到。
- Novita AI 是否为 PPIO 海外品牌、OpenRouter 收购价、多家估值与 ARR 均来自二手报道。

A｜国内 MaaS / Token / 推理云平台：产品线、定价、方案与销路

沐仞科技内部竞品资料｜2026-11-02 整理｜共 13 家

怎么读这份资料

- **范围**：大厂云 4 家（火山方舟、阿里云百炼、百度千帆、腾讯云 TokenHub）；独立 Token 平台 3 家（硅基流动、PPIO、无问芯穹）；带 AI 推理业务的上市云 3 家（七牛、优刻得/优云智算、并行科技）；算力聚合 3 家（共绩科技、蓝耘、胜算云）。华为云只在文末附一条。
- **复用的旧资料**：硅基流动、PPIO、无问芯穹沿用 10-12 至 10-30 的本地调研，没有重做，本文只补新内容。文中写【旧】的，出处见各家来源行：
  - `全部竞品_产品收费与定价_2026-10-21.qmd`
  - `硅基流动与海外同类/…_2026-10-14.qmd`
  - `无问芯穹/无问芯穹_产品与收费定价_2026-10-21.qmd`
  - `模型渠道全量比价_2026-10-30/ppio_browser_observation_2026-10-30.json`
- **单位**：价格都是”输入 / 输出”，单位元/百万 Token，括号里是缓存命中价。“M”指百万 Token。
- **核验日期**：凡是没写日期的来源，都是 2026-11-02 访问的。
- **标记**：
  - 【媒】：只有媒体报道，官方没有公布；
  - 【三方】：来自第三方博客或汇总页，未经核实；
  - 【未核实】：只找到单一、不可靠的来源；
  - 【算】：我自己算的；
  - 【判断】：我的分析判断。
- **未取得的页面**：腾讯云和火山方舟的部分页面要过反爬验证，WebFetch 读不到。这里不绕过验证，改用搜索摘要，并照样标注。

---

0. 汇总表

公司	产品线	计费方式	代表价格	解决方案	销路
火山引擎·方舟（字节）	方舟模型推理（常规、低延迟、低优、批量、TPM 保障包）、Coding Plan / Agent Plan、AgentKit、HiAgent 3.0、ArkClaw 企业 Agent 工作台、扣子、AI Trust、方舟 CLI	按 Token，分三个档位：低延迟加价、常规、低优约 5 折；批量；按输入长度分档；个人订阅（月费）	豆包 2.1 Pro 6 / 30（1.2）；2.0 mini 0.2 / 2；DeepSeek V4 Pro 9 / 27；Coding / Agent Plan 40 和 200 元/月	编程、Agent、视频（短剧占约 95%【媒】）、汽车、手机、企业智能体	直销大客户（“万亿 Token 俱乐部”200+ 家）；高额 Token 销售提成【媒】；自助控制台；大会
阿里云·百炼	百炼按量 API、Token Plan（个人版 / 团队版）、Coding Plan（停售中）、节省计划、Qwen Cloud 独立站、Batch	按 Token；上下文阶梯；Batch 5 折；缓存约 1 折；DeepSeek 峰谷价；Credits 订阅；夜间 2 折	qwen-flash 0.15 / 1.5；qwen3.8-max 12 / 36；Token Plan 个人版 39—499 元/月，团队席位 150—1,398 元/席/月	AI 编程、企业核心系统接入、Agent	直销加专门的 MaaS 销售团队；伙伴随 Agent 一起卖 Token，阿里抽 30%，伙伴另得 1.5 倍系数【媒】；控制台自助
百度智能云·千帆	千帆 ModelBuilder / 推理 API、Token Plan 个人版（Mini / Lite / Pro / Max）、Coding Plan（2026-06-25 起停止续费）、私有化（软件或	按 Token（峰谷）；Token 量包或 TPM 预付；个人 Token 订阅	ERNIE 5.1 4 / 18；DeepSeek V4 Pro 高峰 9 / 27，非高峰 4.5 / 13.5；个人 Token Plan 首购最低 4.9 元	政企、金融、能源等行业大模型，私有化	政企招投标：上半年大模型中标额 13.85 亿元，居首【媒】；直销；控制台

公司	产品线	计费方式	代表价格	解决方案	销路
	软硬一体）、GPU 云（百舸）				
腾讯云·TokenHub / 混元	TokenHub 大模型服务（按量）、Token Plan 个人版 / 企业版、智能体开发平台 ADP、CodeBuddy / WorkBuddy	按 Token；积分订阅（100 积分 = 1 元）；ADP 平台订阅加资源包	Hy3 1 / 4（0.25）；个人 Token Plan 28、78、238、468 元/月；企业版月预算 5,000–20,000 元	编程与办公 Agent、ADP 企业智能体	腾讯云直销与生态；自家应用带量（CodeBuddy 等）
硅基流动	SiliconCloud 按量 API、预留实例、私有化 MaaS / 网关 / 一体机、Token 工厂联合运营、国际站、BizyAir	按 Token；分时价；预留实例月租；私有化收许可 + 实施 + 维保；联合运营分成	V4 Pro 12 / 24；预留实例 38.6–77.2 万元/组/月【旧】	政企本地部署（昇腾等国产卡）、AIGC、出海	开发者漏斗（免费小模型、代金券、工具预置）；集成商；运营商与国资联合运营；OpenRouter
PPIO 派欧云	模型 API（文本、图像、视频）、企业 Token Plan、Agent 沙箱 / 托管、GPU 云（即将下线）、GPU SPOT、边缘云（收入大头）	按 Token；批量 5 折；企业月度订阅包（融合额度 × 模型系数）	V4 Pro 9 / 27；Token Plan Basic 1,598 元/月（16 亿融合 Token）、Pro 4,798 元、Max 13,998 元	Agent 基础设施（沙箱、RL）、出海	自助；开发者工具（Skills、MCP、CLI）；BD 资源合作；华为云大会等生态活动
无问芯穹	GenStudio 大模型 API、编码套餐、ComfyUI 托管、AIStudio GPU、智能体平台、AgentWorks、私有化、运营商合作、端侧	按 Token（价格不公开）；包并发；按秒；GPU 卡时或包月；积分；项目合同	ComfyUI 每秒 0.0028–0.0076 元；H100 8 卡包月 11 万元【旧】	政企算力平台、运营商、AIGC	只服务企业（2026-07 起）；政府和运营商项目；直销
七牛云（七牛智能 02567）	AI 大模型推理（聚合多家模型）、Token Plan（企业订阅）、资源包、MCP / Agent 接入、音视频云（主营）	按 Token（分时）；资源包按比例抵扣；Token Plan 积分 × 模型系数 × 闲时倍率	V4.1 Flash 1–2 / 4–8；Token Plan 包年最低 4 折，18:00–08:00 闲时扣 0.3 倍，叠加后约等于刊例价 1.2 折【三方】	开发者、Agent 应用、音视频 + AI	新客送 300 万 Token；CPS 返现、AI 推荐官、生态伙伴计划；存量音视频客户
优刻得 / 优云智算（688158）	优云智算 GPU 实例（4090 / 5090 / A800 / H20）、模型 API（ModelVerse）、Coding Plan、Agent 托管、孔明智算平台、公有云和私有云	GPU 按时、按日、包月；模型 API 后付费，每小时出账	4090 2.15 元/时，5090 3.32 元/时，A800 6.23 元/时；高校和企业再打 95 折	AIGC、科研、政企私有云	自助（镜像社区）；高校与企业折扣；政企直销
并行科技（920493）	超算云、智算云（GPU 算力服务）、MaaS 平台、AI Coding 平台（与山东联通合作）、HPC 系统集成与软件	算力服务（卡时、包月、长约）；MaaS 按 Token	未见公开 Token 价	科研超算、企业智算、区域智算中心	高校与科研院所的基本盘；企业直销（上半年企业端收入 7.05 亿元）；与地方国资合资建智算中心
共绩科技（共绩算力）	弹性部署（Serverless）、云主机、裸金属、大模型云服务 MaaS、分布式算力调度、Job 批处理	“纯动态按量计费，无订阅费”	官网没有列价；4090 1.68 元/时【未核实】	闲时算力、算电协同、“以算代储”	清华背景；运营商、芯片厂、能源企业（宁德时代）生态；WAIC 等大会
蓝耘（元生代）	元生代 MaaS 平台、智算云 GPU、本地私有化	阶梯定价、预充值折扣【三方】	新用户 500 万 Token【未核实】	私有化、智算中心	推广文章、评测榜

公司	产品线	计费方式	代表价格	解决方案	销路
胜算云	大厂模型 Router（100+ 模型，含海外闭源模型）、模型超市、模型集群、GPU	未公开	未公开	科研和开发者用的”国内版 OpenRouter”	长三角国家技术创新中心扶持；预置在 LangBot、AstrBot 等开源工具里

1. 火山引擎·火山方舟（字节跳动）

1. 产品线

- **方舟模型推理**，分五种模式：
  - 在线推理（常规）；
  - 在线推理（低延迟，只有部分豆包模型）；
  - 在线推理（低优）：价格约为常规的 50%；
  - 批量推理；
  - TPM 保障包：文档写着”暂无支持的模型”。
- **自研模型**：
  - 豆包 Seed 2.1 Pro / Lite / Turbo，Seed 2.0 Pro / Lite / Mini；
  - 视频 Seedance 2.5、图像 Seedream 5.0 Pro、音频 Seed-Audio 1.0；
  - 同时上架 DeepSeek V4 系列。
- **个人订阅**：
  - Coding Plan Lite / Pro；
  - Agent Plan Small / Medium：多模态 + Harness，含 Seedance、Seedream。
- **Agent 企业基础设施（2026-06 FORCE 大会发布）**：方舟 CLI、AgentKit、HiAgent 3.0、ArkClaw 企业版 Agent 工作台、AI Trust 产品体系、扣子。

2. 定价

元/百万 Token，输入 / 缓存命中 / 输出。来源：官方文档 docs.volcengine.com/docs/82379/1544106。

模型	常规	低优（批量同价）	低延迟
doubao-seed-2.1-pro	6 / 1.2 / 30	3 / 1.2 / 15	—
doubao-seed-2.1-lite	0.8 / 0.16 / 2.7	0.4 / 0.16 / 1.35	1.6 / 0.32 / 5.4
doubao-seed-2.1-turbo	3 / 0.6 / 15	1.5 / 0.6 / 7.5	6 / 1.2 / 30
doubao-seed-2.0-mini（≤32k 输入）	0.2 / 0.04 / 2	0.1 / 0.04 / 1	0.4 / 0.08 / 4
deepseek-v4-pro 正式版	9 / 0.3 / 27	4.5 / 0.3 / 13.5	—
deepseek-v4-1-flash	高峰 2 / 0.04 / 8；非高峰 1 / 0.02 / 4	1 / 0.02 / 4	—
deepseek-v4-1-flash 经济版	高峰 1.6 / 0.032 / 6.4；非高峰 0.8 / 0.016 / 3.2	—	—

- **时段和分档规则**：
  - 高峰为工作日 09:00–12:00、14:00–18:00，其余时间算非高峰；
  - 缓存存储 0.017 元/百万 Token/小时；
  - 豆包 2.0 系列按输入长度分 0–32k、32–128k、128–256k 三档。
- **个人订阅**：
  - Coding Plan Lite 40 元/月、Pro 200 元/月；Agent Plan Small 40 元/月、Medium 200 元/月。
  - 到 2026-08-27 为止，前两个月打 2.5 折（9.9 元 / 49.9 元），见 IT之家（2026-06-08）。
  - 额度没有官方数字。第三方估计 Lite 每 5 小时约 1,200 次请求、Pro 约 6,000 次【三方】。

- **商业化手法**：Seedance 2.0 满血版只开放给签了年框的客户（白名单）。来源：KrASIA，2026-06-05【媒】。

3. 解决方案

- 编程和 Agent：2.1 Pro 主打 Coding 与 Agent。
- 视频生成：Seedance 在短剧行业渗透率约 95%【媒】。
- 企业智能体：HiAgent、ArkClaw。
- 手机和汽车厂商的端云合作。

4. 销路

- **大客户直销**：年用 Token 超过 1 万亿的企业已有 200+ 家；超过 110 万家企业和个人在用方舟。来源：新华网，2026-06-23。
- **销售激励**：行业传闻火山卖 Token 的提成是卖云产品的 10—20 倍，2023 年就建了 MaaS 销售体系。来源：36氪 / 中国企业家，2026-05-27【媒】。
- **其他**：控制台自助；FORCE 大会；个人订阅用低价首月拉新。

5. 差异化与数字

- **调用量**：豆包日均 Token 超过 180 万亿，2026-06 披露，2026-03 时是 120 万亿。来源：同花顺。
- **MaaS 收入**：2025 年约 15 亿元；2026 年目标 150 亿元，4 月上调；Seedance 2.0 单月收入超过 10 亿元。来源：KrASIA【媒】。
- **IDC 市场规模**：2026 年上半年中国 MaaS 市场 106.3 亿元，同比 +889.4%。来源：IDC，2026-10-29。
- **火山的份额**：45.1%，出自媒体对 IDC 报告的转述；IDC 正文没有列各家份额。来源：36氪。
- **【判断】护城河**：自研全模态模型，加上抖音、字节自身的用量，加上最低价的低优和批量档。它是全行业的价格锚，也是最大的销售机器。

---

2. 阿里云·百炼（Model Studio）

1. 产品线

- 百炼按量 API：千问全系列，以及 DeepSeek、Kimi、GLM、MiniMax 等第三方模型。
- Batch 批量调用；上下文缓存。
- 订阅类：
  - Token Plan 个人版（Lite / Essential / Standard / Pro）；
  - Token Plan 团队版（标准 / 高级 / 尊享席位，外加共享用量包）；
  - Coding Plan：Lite 已于 2026-03-20 停止新购，Pro 限量。
- AI 通用节省计划：预付，承诺每小时最低消费，换取折扣。
- Qwen Cloud 独立网站（面向 Agent）；AgentStudio 等工具（Harness）。

2. 定价

按量（华北 2 北京，刊例价）。 来源：help.aliyun.com/zh/model-studio/model-pricing。

模型	输入 / 输出
qwen3.8-max / qwen3.7-max	12 / 36（送 100 万免费 Token）
qwen-max	2.4 / 9.6
qwen-plus（0—128k）	0.8 / 2（不思考）或 8（思考）；128—256k 为 2.4 / 20—24；256k—1M 为 4.8 / 48—64
qwen-flash（0—128k）	0.15 / 1.5
deepseek-v4-pro	12 / 24（不分峰谷）
deepseek-v4.1-flash	高峰 2 / 8；非高峰 1 / 4（非高峰为 22:00—08:00）

- **计费规则**：
  - 阶梯价看单次请求的输入长度，整次请求按所在档位计价；
  - Batch 5 折；
  - 缓存命中约为输入价的 10%；
  - Batch 和缓存优惠不能叠加。
- **免费额度**：部分模型 100 万 Token，90 天有效。

Token Plan 中国站（只在北京地域）。 来源：官方文档。

版本	档位	刊例价 → 限时价	每月额度（Credits）
个人版	Lite	60 → 39 元/月	11,500
个人版	Essential	120 → 79 元/月	25,500
个人版	Standard	180 → 139 元/月	45,000
个人版	Pro	600 → 499 元/月	180,000
个人版	用量包	100 元/个/月	20,000
团队版	标准席位	198 → 150 元/席/月	25,000
团队版	高级席位	698 → 550 元/席/月	100,000
团队版	尊享席位	1,398 元/席/月	250,000
团队版	共享用量包	5,000 元/个/月	625,000

- **规则**：额度当月用完即停，不结转；不退款；Token Plan 与按量计费互斥，要用专属 API Key。
- **促销**：
  - 夜间 22:00–08:00 调用 Qwen3.7 系列”低至 2 折”；
  - 节省计划”最高 5.3 折”。
  - 来源：阿里云开发者社区，2026-07-28【三方】，未核实。

3. 解决方案

- AI 编程：Qwen 3.7-Max 主打 agentic coding。
- 企业核心业务系统接入：阿里云用”连接的客户核心业务系统数”作为考核指标。
- 企业智能体。

4. 销路

- **“530 Token 战役”**（2026-04 发起）：目标是年底 Token 收入达到 4 月初的 30 倍。销售每卖 1 万元 Token，奖励 1:1 的业绩。
- **伙伴分成**：鼓励伙伴把 Token 和 Agent 产品一起卖。例子：产品收入 100 元、其中含 MaaS 消耗 5 元时，阿里抽 30%，伙伴另得 1.5 倍系数奖励。来源：36氪 / 中国企业家，2026-05-27【媒】。
- **其他**：多支 MaaS 销售团队和直销团队并行；Qwen Cloud 独立站；2025-06 起通过”繁花计划”接入硅基流动等第三方 API【旧】。

5. 差异化与数字

- **2026 财年第四季度（2026 年 1–3 月）**：
  - 阿里云收入 416.26 亿元，同比 +38%；
  - AI 相关产品收入 89.71 亿元，占外部收入超过 30%，连续 11 个季度三位数增长；
  - 百炼客户数同比增长 8 倍；
  - 含百炼在内的 AI 模型与应用服务 ARR 超过 80 亿元，年底目标 300 亿元。
  - 来源：同花顺转述财报。
- **MaaS 收入**：2026 年前 5 个月增长 15 倍；月收入达到”九位数”，即每月 1 亿元以上。来源：KrASIA，2026-05-25。
- **【判断】护城河**：开源千问生态，加上平头哥 PPU（出货 54 万片以上），加上存量云客户，再加上伙伴分成。它和火山是”自研模型 + 自有芯片或资源”的双寡头。

3. 百度智能云·千帆

1. 产品线

- 千帆模型服务：ERNIE 5.1，以及 DeepSeek、GLM、Kimi 等。
- 数据、精调、评测、应用开发全流程。
- Token Plan 个人版：Mini / Lite / Pro / Max 四档，2026-07-13 发布。
- Coding Plan：2026-06-25 起停止续费。
- Token 量包预付、TPM 预付。
- 交付方式：公有云共享资源或专属资源；私有化可以纯软件，也可以软硬一体（一体机）。
- GPU 云。

2. 定价

按量。 来源：cloud.baidu.com/doc/qianfan/s/wmh4sv6ya，原单位元/千 Token，已 ×1000 换算【算】。

- ERNIE 5.1：输入 ≤32k 时 4 / 18；32—128k 时 6 / 22。
- DeepSeek V4-Pro-0813：
  - 高峰（8:00—22:00）9 / 27（0.3）；
  - 非高峰 4.5 / 13.5（0.15）。
- DeepSeek V4.1-Flash：高峰 2 / 8，非高峰 1 / 4。
- DeepSeek V4-Pro 标准行：12 / 24。

预付。 买了 Token 量包或 TPM 预付的客户，即使账户欠费，调用也不中断（同一文档）。

Token Plan 个人版：

- 四档月套餐，首购 5 折，最低 4.9 元。来源：IT之家，2026-07-13。
- 统一按通用 Token 抵扣：不区分模型倍率，也不区分输入、输出、缓存。
- 各档的价格和额度没有查到。
- “夜享 Tokens”（2026-08-14 起）：每天 21:00—次日 08:00，指定模型按 2 折计。来源：CSDN 新闻，搜索摘要；页面返回 521，未能打开核对。

3. 解决方案

- 行业大模型：金融、游戏、具身智能。IDC 称百度智能云在这三个行业份额第一【媒】。
- 政企私有化、一体机。
- 电商客服、营销文案等。

4. 销路

- **政企招投标是主战场**：2026 年上半年大模型相关中标额 13.85 亿元，居五家主流云厂商首位，约占它们合计金额的六成。来源：智能超参数报告，经财经报道转引【媒】。
- **其他**：直销；控制台自助；个人订阅。

5. 差异化与数字

- 2026 年第二季度：AI 业务收入 125 亿元；AI 云基础设施 73 亿元，同比 +50%；其中 GPU 云同比 +283%。来源：东方财富。
- 【判断】它不靠 Token 规模取胜，而是靠政企项目、GPU 云和一体机。按量价格跟 DeepSeek 官方峰谷价完全一致。

---

4. 腾讯云·TokenHub / 混元

1. 产品线

- TokenHub 大模型服务平台：混元 Hy3 / Hy4 preview，以及 GLM、Kimi、MiniMax、DeepSeek 等。
- Token Plan 个人版（面向 OpenClaw 和编程场景）和企业版。Coding Plan 已被 Token Plan 取代【三方】。

- 智能体开发平台 ADP：分免费版、Skill Plan 版、专业版、企业版。
- CodeBuddy、WorkBuddy 等自家 AI 工具。

2. 定价

- **按量**：Hy3 正式版（2026-07-06 发布）1 / 4（0.25）。来源：北京商报、TechNode。
- **Token Plan 个人版**（积分制，按日常价）：

档位	价格	每月积分
Lite	28 元/月	560
Standard	78 元/月	1,560
Pro	238 元/月	4,760
Max	468 元/月	9,360

- 搭配的模型是 Hy4 preview 和 Hy3。
- 来源：腾讯云 tokenplan 活动页的搜索摘要。该页面有反爬验证，未能直接打开。
- **Token Plan 企业版**：
  - 月预算 5,000—20,000 元，以 5,000 元为一档；100 积分卖 1 元；可买 1—12 个月；
  - 可用模型包括 Auto 智能路由、Kimi-K2.5、MiniMax-M2.5、GLM-5 等。
  - 来源：官方文档 cloud.tencent.com/document/product/1823/130660 的搜索摘要，页面有反爬验证。
- **涨价**：
  - 2026-03：HY2.0 Instruct 输入从 0.0008 元/千 Token 涨到 0.004505 元/千 Token，涨了 5 倍以上；
  - 2026-05-27：Hy3 preview、DeepSeek-V4-Pro 结束免费公测。
  - 来源：界面、IT之家【媒】。
- **ADP**：平台订阅月费 0—4,880 元，另加资源包【媒】。

3. 解决方案

- 编程和办公 Agent：CodeBuddy、WorkBuddy、OpenClaw 场景。
- ADP 企业智能体。

4. 销路

- 腾讯云直销；自家产品导流；企业版按”月预算”出售。
- 一份评论称，按 IDC 2025 年下半年数据，腾讯云在企业级 MaaS 市场没进前三。来源：虎嗅【媒】。

5. 差异化

【判断】腾讯有自研模型和应用场景，但 GPU 储备相对少，所以 2026 年起持续涨价、收紧免费额度。企业版”按月预算订阅加智能路由”的形式，和沐仞”一个 Key 加月度预购”最接近，可以直接对照。

---

5. 硅基流动 SiliconFlow

已有完整调研【旧】：`硅基流动与海外同类_业务市场营销调研_2026-10-14.qmd`、`全部竞品_产品收费与定价_2026-10-21.qmd`。本文只摘要，并补充 IPO 进展。

1. 产品线

- SiliconCloud 按量 API（国内站和国际站），覆盖文本、图像、视频、语音。
- 专属 / 预留实例。
- 私有化：MaaS、AI 网关、昇腾等国产卡一体机。
- Token 工厂联合运营：面向 IDC、区域智算中心、运营商。
- BizyAir（ComfyUI 云节点）；开源的 OneDiff。

2. 定价

- V4 Pro 12 / 24（1）。
- V4-Flash 凌晨 2—8 点半价；Hunyuan-A13B 白天贵。
- 预留实例 38.61 万—77.22 万元/组/月，官方折合 2.08—8.94 元/M。
- 私有化收许可 + 实施 + 维保，可订阅也可买断。
- 联合运营按服务量分成。
- 2026-05 起必须实名；赠送余额改成代金券。

3. 解决方案

- 能源、金融、电信、政企的本地部署（国产芯片）。
- AIGC（ComfyUI）。
- 出海：国际站、OpenRouter。

4. 销路

- 开发者漏斗：免费小模型、注册和邀请送代金券、首发热门模型；近百款应用把它设为内置服务商（Dify、Cherry Studio、TRAE 等）。
- 系统集成商：前五大客户多为集成商。
- 运营商和国资联合运营：贵州移动、浙江省数据集团等。
- 团队：销售和市场 21 人，2025 年末数据。

5. 差异化与数字

- 2025 年收入 5,533 万元：公有云 52.9%，本地部署 47.1%。
- 毛利率：本地部署 82.5%，公有云 −119%。
- 2025 年免费代金券对应的算力成本 5,421 万元，约等于全年收入。
- 2026-04 日均 Token 5,785 亿；注册用户 1,028 万。
- 按 Token 吞吐量计，中国市场份额 1.5%，排第四。
- 2026-06-30 按 18C 章递表港交所（华泰国际、海通国际保荐）。截至 2026-11-02，没查到聆讯消息。来源：澎湃。
- 赎回负债 4.986 亿元：2030 年底前不上市，投资人可要求赎回。

---

6. PPIO 派欧云

1. 产品线

来源：ppio.com 首页。

- 大语言模型 API；图像和视频生成 API（MiniMax、Qwen、Vidu 等）。
- 企业 Token Plan。
- Agent 沙箱（浏览器、代码、自定义，用于强化学习、数据处理、AI 编程）。
- Agent 托管（Beta，可托管 PPClaw、PPHermes，“暂停即停费”）。
- GPU 容器实例（H100 / H800 / H20），标注”即将下线”；GPU SPOT；Serverless GPU。
- 开发者工具：Skills、MCP Server、沙箱 CLI。
- 边缘云：收入的大头，见第 5 点。

2. 定价

- **按量**：V4 Pro 9 / 27（3），GLM-5.3 8 / 28，Kimi K3 20 / 100；批量限时 5 折【旧】。
- **企业 Token Plan**（2026-10-30 页面实录【旧】）：

档位	价格	融合 Token
Basic	1,598 元/月	16 亿
Pro	4,798 元/月	48 亿
Max	13,998 元/月	140 亿

- 每 1 元约合 100 万融合 Token【算】，实际扣量按各模型的抵扣系数换算。
- 当月不结转；最多 200 个席位；SLA 最高 99.5%；官方宣传"低至 4.5 折"。
- **GPU SPOT**："低至 5 折"，4090 1.16 元/时（首页）。

3. 解决方案

- Agent 基础设施：沙箱、托管、强化学习环境。
- AI 应用推理，案例有极豆、Monica、蜜度。
- 出海和全球分布式节点。

4. 销路

- 自助注册；开发者工具（Skills、MCP）；BD 资源合作（bd@ppio.com）。
- 生态大会，如华为云创想者大会。来源：CSDN。
- 招股书相关报道里没有销售团队和分销结构的信息。

5. 差异化与数字

- **收入**：2023 年 3.584 亿元，2024 年 5.58 亿元，2025 年 7.703 亿元。
- **AI 云收入**：2024 年 1,038.7 万元，2025 年 1.192 亿元。
- **调用量**：2026-04 日均 Token 1.028 万亿；注册开发者 57.4 万。
- **节点**：截至 2025 年末，计算节点 4,600+，覆盖 1,340+ 个县市。
- 以上收入和规模数据来自 2026-06-10 第二次递表港交所的招股书，经 GMT8 报道。
- **毛利率**：2025 年整体 9.4%，边缘云占收入 84.5%【旧，36氪转述】。
- **首页现在的口径**：日均 Token 2.2 万亿以上、注册用户 68 万以上、200+ 个模型、5,000+ 个节点。
- 【判断】Token 量冲得很猛，但利润靠边缘云撑着。它正从 GPU 云撤出，转向"Token Plan + Agent 沙箱"。

---

7. 无问芯穹 Infinigence

已有完整调研【旧】：`无问芯穹/无问芯穹_产品与收费定价_2026-10-21.qmd`、`…_业务市场与营销销售调研_2026-10-12`。这里只摘要。

1. 产品线

- GenStudio 大模型 API。
- 编码套餐（Lite 40 元/月、Pro 200 元/月，文档已下线）。
- ComfyUI 托管。
- AIStudio GPU 和存储。
- 智能体服务平台（积分制）；AgentWorks。
- ONEtake 短剧生成。
- Agentic Infra、私有化、一体机、政府算力平台、运营商合作（如上海移动"天问"）。
- 端侧：Megrez、LPU IP、InfiniClaw Box。

2. 定价

- **大模型 API**：
  - 2025-11 起单价只在控制台显示；
  - 2026-03-30 起基础版也收费；
  - 2026-08-28 起两个 DeepSeek V4 模型在 22:00—08:00 半价；
  - 包并发按月付费，价格不公开。
- **ComfyUI 托管**：按秒 0.0028—0.0076 元，或每并发每月 1,600—3,580 元。
- **GPU**：H100 8 卡包月 11 万元，折合约 18.8 元/卡时【算】。
- **智能体平台**：1 元 = 100 积分。

3. 解决方案

- 政府和区域智算平台、运营商算力运营、异构芯片（多种国产卡）统一调度、AIGC 和短剧。

4. 销路

- 2026-07 起只服务企业，停止个人注册。
- 政企和运营商项目制，直销。
- 唯一查到的合同样本：中科院深圳先进院算力租赁 43.8 万元（2025-04）。

5. 差异化与数字

- 2024 年营收超过 8,500 万元。来源是清华的材料，非审计数据。
- C 轮之后累计融资 43 亿元（见记忆资料 `fathompeak-infinigence-research`）。
- 【判断】它的路线是"异构算力调度 + 政企项目"，和沐仞"电站侧调度 + 私有化"最像，但它不讲能源。

---

8. 七牛云（七牛智能，港股 02567）

1. 产品线

来源：qiniu.com/ai/models。

- AI 大模型推理：模型广场，聚合文本、图像、视频、生图模型，OpenAI 和 Anthropic 两种协议都兼容。
- Token Plan（企业订阅）；资源包（在云商城购买，"全系列大语言模型调用按比例抵扣"）。
- 联网搜索按次收费。
- 其他：全栈应用服务器 LAS、对象存储、CDN、直播；音视频云是主营。

2. 定价

按量（页面价 ×1000 换算【算】）：

模型	输入 / 输出（缓存）
DeepSeek-V4.1-Flash	1–2 / 4–8（分时）
Kimi-K3	20 / 100（2）
GLM-5.2	8 / 28（2）
MiniMax-M3	2.1 / 8.4
Qwen3.7-Max	12 / 36
Doubao-Seed-2.0-Lite	0.6 / 3.6

- 生图：Seedream 5.0 Pro 0.3 元/张。
- 视频：Kling V3 0.6 元/秒。

Token Plan：

- 包月、包季、包年；"企业包年最低 4 折"。
- 18:00–次日 08:00 为闲时，参与活动的模型按 0.3 倍扣积分；周末全天都算闲时。
- 叠加后的等效价约为刊例价的 1.2 折（条件价，不是标价）。
- 按周刷新额度，不结转。
- 来源：SegmentFault，2026-09-27，原文称官方页面 qiniu.com/ai/plan 已于 09-24 核对【三方】。

免费额度：

- 新用户 300 万 Token；
- Conatus 模型 10-24 至 11-30 认证用户每天 1 亿 Token；
- Nemotron 3 Ultra 免费。

3. 解决方案

- 开发者构建 Agent 的基座、音视频 + AI、中立的多模型聚合（"中国版 OpenRouter"，券商用语）。

4. 销路

- 存量音视频和存储客户交叉销售。
- 渠道计划：CPS 返现、“AI 推荐官”、大模型生态伙伴合作计划、AI 开源项目扶持计划。
- 页面有”产品报价”入口，走企业销售。

5. 差异化与数字

- 2025 年：收入 17.69 亿元；AI 相关收入 4.37 亿元，占 24.7%。
- 2026 年上半年：收入 8.99 亿元；按报表分类，AI 云收入 1.58 亿元，占 17.57%。这和公司以前说的”AI 相关收入”口径不同。
- 截至 2026-01，注册用户 192 万；2025 年末开通大模型服务的开发者超过 16 万。
- 来源：同花顺、格隆汇。
- 【判断】七牛是”闲时倍率 + 包年折扣”最激进的一家，1.2 折的等效价已经低于沐仞的”4 折起”。

---

9. 优刻得 UCloud / 优云智算 Compshare（688158）

1. 产品线

- 优云智算 GPU 实例：4090、5090、A800、H20 等。
- 镜像社区：500+ 个镜像。
- 模型 API（ModelVerse）；Coding Plan、Agent 托管（页脚有入口）。
- AI 生图、音频工作室；桌面客户端。
- 孔明智算平台：异构算力调度。
- UCloud 公有云和私有云；两座自建数据中心，“超万卡”规模。

2. 定价

- **GPU**：
  - 4090 2.15 元/时（乌兰察布、上海）；
  - 5090 3.32 元/时；A800 6.23 元/时；无卡模式 0.15 元/时；
  - 高校和企业再打 95 折。
  - 来源：compshare.cn。
- **模型 API**：
  - 按量后付费，每小时整点出账；
  - 例：DeepSeek-R1 4 / 16，Qwen3-max（≤32k）2.5 / 10，GLM-5（<32k）4 / 18，Kimi-K2.5 4 / 21，doubao-seed-2.0-pro 3.2 / 16。
  - 来源：价格文档。这页的模型版本偏旧，可能没有及时更新。
- **免费资源**：100GB 云盘，30TB 模型库免费下载。

3. 解决方案

- AIGC、科研训练、政企私有云。
- 官方称 AI 业务覆盖基础模型、行业模型、Agent、AI 机器人、AI + 硬件。

4. 销路

- 自助社区：镜像、教程。
- 高校和企业专项折扣。
- 政企直销：私有云。

5. 差异化与数字

- 2026 年上半年：收入 9.82 亿元，同比 +24.09%；归母净利润 807.72 万元，首次转正；毛利率 28.36%；AI 相关收入占比超过 40%。来源：同花顺。
- 乌兰察布智算中心的定增（不超过 15 亿元）已于 2026-09-02 终止。来源：21 世纪经济报道、中证网。
- 【判断】它在西部（乌兰察布）有低电价机房，用 GPU 时租的低价做个人和科研流量。这是”西部能源 + 算力”的上市公司样本，但它不讲绿电。

10. 并行科技（北交所 920493）

1. 产品线

- 超算云（北龙超云）；智算云（GPU 算力服务）。
- MaaS 平台：已上线 GLM-5.3、DeepSeek-V4 等。
- AI Coding 平台：与山东联通联合发布，集成近 90 款模型。
- 高性能计算系统集成；软件与技术服务。
- 并行算网：整合分布式算力，做全域异构调度和削峰填谷。

2. 定价

- 以算力服务合同为主（卡时、包月、长约）。合同负债 7.36 亿元，较上年末 +55%，说明客户在提前锁定算力。
- 没有找到公开的 Token 单价。

3. 解决方案

- 高校和科研超算；企业 AI 训练与推理；区域智算中心。
- 与地方国资合资：湖北科投（楚云智算）、深圳光明科学城（粤云智算）。

4. 销路

- 高校和科研院所是基本盘：2026 年上半年分别增长 18.73% 和 6.88%。
- 企业端：收入 7.05 亿元，同比 +168%。
- 与地方政府和国资合资建中心；与运营商合作（山东联通）。

5. 差异化与数字

来源：东吴证券中报点评，2026-08-30。

- 2026 年上半年收入 9.46 亿元，同比 +106.76%；归母净利润 0.42 亿元。
- 算力服务 8.95 亿元，占 94.62%；其中智算服务 6.47 亿元，同比 +144.51%。
- 整体毛利率 19.16%；2025 年全年收入 11.10 亿元。
- 【判断】这是”调度 + 国资合资建中心”的样本：靠合同预收锁定客户，而不是靠 Token 单价。

---

11. 共绩科技（共绩算力，ComNergy）

这是概念上和沐仞最接近的对手，需要重点盯。

1. 产品线

来源：suanli.cn（gongjiyun.com 会跳转到这里）。

- 弹性部署：Serverless，宣称”0 空闲成本”。
- 云主机；裸金属（短租独占）。
- 大模型云服务 MaaS：“完美兼容标准接口”。
- 分布式算力调度；Job 批处理（任务优先级、自动排队）。

2. 定价

- “纯动态按量计费，无订阅费”。官网没有列价。
- 4090 1.68 元/时的说法只出现在搜索摘要里【未核实】。

3. 解决方案

- 自称”全球首个闲时算力调度平台”，把个人、网吧、智算中心的闲置算力汇集起来。

- “电网式算力调度网络”；“算电协同”；“以算代储”：用任务分发代替电力传输，帮新能源消纳。

4. 销路

- 案例：面壁智能（成本降 68%）、Liblib（降 50%）、Tripo、VAST、Remy（鸿蒙 6）。
- 生态：三大运营商、中国信通院、华为、阿里、腾讯、火山、NVIDIA、多家国产芯片厂、宁德时代、智谱、Kimi、MiniMax。
- WAIC 等大会，加上官媒报道（人民日报评论【媒】）。
- 清华学术背书：在《电力系统自动化》《Energy Use》发表论文，见本地笔记 `算电协同论文_清华共绩_2026-10-25/`。

5. 差异化与数字

- 官网口径：“70 万 +”算力资源，服务客户”超 12,000 家”。
- 融资：2024-10 天使轮数千万元（水木创投领投）；2026-05 Pre-A 轮近亿元（春华创投、彼岸时代领投）。来源：36氪。
- 论文实测：三地调度成本降近 18%，绿电利用率提升近 20%（见本地笔记）。
- 【判断】共绩的卖点是”分布式闲时算力 + 算电协同”。沐仞是”电站旁自有一体机 + 绿电 Token”。两家的叙事高度重叠：都讲算电协同、削峰填谷、清华背景、绿电消纳。差别在资产形态：共绩是轻资产聚合，沐仞把设备放在电站边上。沐仞对外要讲清”电站侧确定性的绿电和电价”，这一点共绩给不了。

---

12. 蓝耘科技（元生代 MaaS）

- **产品线**：
  - 元生代 MaaS 平台：零代码体验、API 调用、本地私有化部署。来源：官方新闻稿，2025-08。
  - 智算云 GPU。
- **定价**：“阶梯定价、预充值折扣”，新用户 500 万免费 Token。只见于一篇疑似推广的文章：网易【未核实】。
- **解决方案**：私有化，智算中心运营。
- **销路**：评测榜单曝光，如 AI Ping 上 DeepSeek-V3.2 延迟 0.87 秒【三方】；推广软文。
- **差异化与数字**：没有找到可靠数字。

13. 胜算云

- **产品线**：
  - “大厂模型 Router”，聚合 100+ 个模型，含 Claude、GPT、Gemini 等海外闭源模型；
  - 模型超市、模型集群、GPU 资源。
  - 来源：ai-bot.cn【三方】、LangBot wiki。
- **定价**：没有找到公开价格。
- **解决方案**：科研和 AI 开发者用的”国内版 OpenRouter”；据称受长三角国家技术创新中心专项扶持【三方】。
- **销路**：预置在 LangBot、AstrBot 等开源 Bot 框架里。
- **差异化**：【判断】它能调海外闭源模型，这在国内有合规风险。沐仞不宜对标这一块。

附：华为云

华为云也推出了 Token Plan（Lite / Standard / Pro / Max）。搜索摘要显示 Lite 每月 5,000 万 Token、Max 每月 8.8 亿 Token，但官方页面打开时返回 404，这些数字【未核实】。

---

14. 横向规律与对沐仞的含义【判断】

1. **订阅制已经从”Coding Plan”换成了”Token Plan”，并分成个人和企业两层。**
   - 阿里（2026-03 停售 Coding Lite）、百度（2026-06 停止续费）、腾讯都把按请求次数计费的 Coding Plan 换成了按 Token 或积分抵扣的 Token Plan。

- 个人档：28–600 元/月。
- 企业档有三种形式：
  - 按席位：阿里 150–1,398 元/席/月；
  - 按月预算：腾讯 5,000–20,000 元/月；
  - 按融合额度：PPIO 1,598–13,998 元/月。
- 沐仞的”月度预购”产品可以参照这三种形式定档：席位适合团队，月预算适合企业，融合额度适合开发者。

2. **“闲时折扣”已经是标配，单靠时段定价做不出差异。**

平台	闲时或低价档
DeepSeek 官方	非高峰 5 折
火山	低优档约 5 折
阿里	22:00–08:00 Qwen3.7 低至 2 折
百度	21:00–08:00 2 折
七牛	18:00–08:00 0.3 倍
硅基	2:00–8:00 半价
无问	22:00–08:00 半价

- 这些都按”用户需求的低谷”定时段，没有一家按电站出力或电价曲线定时段，也没有一家在账单上写明绿电来源。
- 沐仞要讲的不是”晚上便宜”，而是三件事：价格时段跟着电站出力走、可追溯的绿电和碳凭证、以及中午光伏大发时段的价格低谷（同行都是夜间低价）。

3. **同一模型各家基本同价，价格锚是 DeepSeek 官方的峰谷价。**

- DeepSeek V4 Pro 在火山、百度、PPIO 都是 9 / 27；阿里和硅基是 12 / 24。
- 七牛的”包年 4 折 × 闲时 0.3 倍”等效约 1.2 折，是目前查到的最低条件价。
- 沐仞”4 折起”如果写成无条件价，单价最低；但别人可以靠叠加条件压到更低。所以沐仞的报价要讲清”无条件价”和”条件价”的区别。

4. **收入集中在大厂。独立平台赚钱靠的不是 Token。**

- 2026 年上半年 MaaS 市场 106.3 亿元，火山约占 45%【媒】。
- 独立平台怎么赚钱：
  - 硅基：公有云毛利 −119%，本地部署 82.5%；
  - PPIO：靠边缘云撑着，整体毛利率 9.4%；
  - 并行科技：靠算力合同（智算 6.47 亿元，毛利率 19%）；
  - 优刻得：GPU 时租。
- IDC 口径下，2026 年上半年大模型私有化部署市场 28.8 亿元，同比 +108%。
- 沐仞”一体机私有化 + 电站合作”的利润空间，比卖 Token 大得多。

5. **大厂靠高额销售激励和伙伴分成卖 Token。**

- 阿里：每卖 1 万元 Token，奖励 1:1 业绩；伙伴随 Agent 一起卖，阿里抽 30%，伙伴另得 1.5 倍系数。
- 火山：传闻 Token 提成是云产品的 10–20 倍【媒】。
- 独立平台的打法：开发者漏斗（免费模型、代金券、预置进 Dify / Cherry Studio）；集成商；和运营商、国资合作运营（硅基 Token 工厂、并行科技合资建中心）。
- 沐仞没有大厂的销售规模，更适合走三条路：
  - 电站和能源集团的合作通道（联合运营、私有化）；
  - 渠道伙伴分成：参考阿里的系数思路，伙伴的 Agent 产品里用 Token 越多，奖励系数越高；
  - 出海：Token 出口已有网信办许可，可以上 OpenRouter 这类聚合平台。

6. **直接对手要分层看。**

- 叙事层面：共绩科技（清华、闲时算力、算电协同、以算代储、宁德时代生态）最近。

- 商业模式层面：无问芯穹（政企、异构调度、私有化）、硅基 Token 工厂（联合运营分成）、并行科技（国资合资建中心）最近。
- 价格层面：火山低优档、七牛 Token Plan。

15. 待核实

- 火山 TPM 保障包、模型单元的现行价格；Coding / Agent Plan 的官方额度。
- 百度 Token Plan 四档的价格和额度。
- 腾讯 Token Plan 官方页：本次因反爬未能直接打开。
- 七牛 Token Plan 官方页（qiniu.com/ai/plan）的档位价格。
- 共绩、蓝耘、胜算云的价格。
- IDC 2026 年上半年 MaaS 报告中的各厂商份额：原文只在图表里，媒体转述的口径不一。
- 并行科技 MaaS 单价。
- 华为云 Token Plan。
- 以上所有价格都变得很快（2026 年各家几乎每月调价），引用前要重新抓取。

B. 海外推理 / 模型 API 平台与聚合器：产品线、定价与销路

沐仞科技内部竞品资料 | 12 家 | 2026-11-02 整理

范围。 Together AI、Fireworks AI、OpenRouter、Groq、Baseten、DeepInfra、Novita AI、Replicate、Modal、Cerebras、SambaNova、fal。

口径。

- **日期：** 带「访问 2026-11-02」的是本次在线抓取；Together、Fireworks、OpenRouter 的细节价目沿用本地 10-14 / 10-21 快照（见 `../全部竞品_产品收费与定价_2026-10-21.qmd` 与 `../硅基流动与海外同类/`），本次只补新变化。
- **单位：** 美元；“M”＝百万 Token；GPU 价格统一换成”美元/卡时”。
- **标记：** 【官】公司官网/新闻稿/SEC 文件；【媒】可信媒体；【三方】Sacra 等第三方估算或价格追踪站；【传】报道中的谈判、未完成；【算】我自己换算；【判断】分析判断；【待核实】只有弱来源或互相矛盾。
- 没查到的数字一律写”未公开”，不估。

---

0. 一页总览

公司	产品线	计费方式	代表价格（访问日见各节）	解决方案 / 主打场景	销路
Together AI	Serverless 推理、Batch、预留吞吐、专属推理、GPU 集群（Instant / 预留）、微调与 Post-training/RL、代码沙箱、存储、Together Link、AI Factory	按 Token；按卡时；按 vCPU 时；按 GiB；全部预付	GLM-5.3 1.40/4.40；Batch 5 折；H100 集群按需 3.99、可抢占 1.99、预留 3.19–3.69；专属推理 H100 5.49、B200 8.99；B200 Post-training 按需 11.00（首发价 9.00）	开源模型替代闭源（编码代理、客服 Agent）、训练到推理全周期、主权/区域 AI 工厂	自助预付 + SDE 转大单；Strategic AE + FDE；AWS Marketplace、Hugging Face、OpenRouter；模型厂首发（月之暗面）；Startup Accelerator；研究品牌（FlashAttention）
Fireworks AI	Serverless（Standard/Priority/Fast/US-only 四档）、Batch、按需 GPU 部署、预留吞吐、BYOC、训练（SFT/DPO/RFT/Training API）、Nexus、FireRouter	按 Token（分速度/区域档）；按 GPU 秒；按训练 Token；预留按美元/分钟	Kimi K3 Standard 3/15、Fast 与 US-only 4.50/22.50；Batch 5 折；H100/H200 8.00、B200 13.00、B300 15.00、GB300 20.00 /卡时；SFT/DPO 0.5–40 /M 训练 Token	“Own your AI”：用客户数据训练专用模型；AI 编程（Nexus）；低延迟产品体验	自助 Tier 1–4 → 企业 AE（AI 原生 / 企业两线）；AWS SCA、AWS/GCP Marketplace、微软 Foundry；咨询伙伴（BCG、Deloitte）；创业计划；Discord；DevDay / Forge 大会
OpenRouter（已被 Stripe 宣布收购）	统一 API 接 600+ 模型 / 80+ 供应商、自动路由、BYOK、预算与管理 API、私有端点	**不定价**：按供应商标价 + 买 credit 时收平台费	Standard 5.5%、Business 8%、Enterprise 合同折扣；BYOK 每月 2.5 万美元标价用量内免费，超出 5%	多模型路由、成本优化、出海模型分发	纯自助 + 企业合同；排行榜（Rankings）本身就是获客；支付宝、USDC 付款；供应商是”货架”上的卖家
Groq	GroqCloud API（LPU 旧集群 + NVIDIA 系统）、Flex / Batch / Performance 服务档、语音转写与 TTS、数据中心容量（NCP）	按 Token；语音按小时；企业合同	GPT OSS 120B 0.15/0.60、GPT OSS 20B 0.075/0.30；Llama 系列改为”联系销售”；Whisper	极低延迟（语音、实时 Agent）；中大型 NVIDIA 集群租赁	开发者自助（自称 600 万开发者）；企业销售；作为 NVIDIA Cloud Partner 卖集群

公司	产品线	计费方式	代表价格（访问日见各节）	解决方案 / 主打场景	销路
			Large V3 0.111/小时、Turbo 0.04/小时；Orpheus TTS 22–40 /M 字符		
Baseten	Model APIs、Dedicated Inference、Training、Model Labs（自有模型系列 joey/elephant/mammoth）、多云容量管理、FDE、自托管/混合部署	按 Token；专属部署与训练按 GPU **分钟**；Pro/Enterprise 量折	GLM-5.3 1.40/4.40（Fast 版 2.10/6.60）；DeepSeek V4 Pro 1.32/3.96；H100 0.10833/分钟 ≈6.50/卡时【算】、B200≈9.98【算】	生产级专属推理：语音转写、TTS、编码、医疗（Abridge、OpenEvidence）	Basic 自助 → Pro/Enterprise 报价；Enterprise 可走客户 VPC / 自托管 / 混合并抵扣客户云承诺消费；FDE 驻场
DeepInfra	Model APIs（100+ 模型：LLM、嵌入、语音、图像、视频、音乐）、Custom LLM 专属部署、GPU 租用、DeepCluster 长约集群	按 Token / 按图 / 按音频分钟；GPU 按分钟；服务档倍率 Standard 1×、Priority 1.5×、Flex 0.8×	DeepSeek-V3.2 0.26/0.38；Kimi-K2.6 0.75/3.50；专属 H100 2.90、H200 3.49、B200 4.89、B300 5.89 / 卡时；**DeepCluster B300 5 年期 1.98 /卡时**	低价批量推理；长期包机房	自助（零长约）+ 企业咨询；美国 8 个数据中心；OpenRouter 上的低价供应商
Novita AI	Model APIs（Serverless + Dedicated Endpoint）、GPU 实例（按需 / Spot / 裸金属）、Serverless GPU、Agent Sandbox、Embeddings、AI Search（转售 Exa / Tavily）	按 Token；GPU 按小时/按秒；搜索按次	DeepSeek V4 Pro 1.60/3.20；GLM-5.3 1.40/4.40；Batch 5 折（推广期）；H100 按需 3.39、Spot 1.70【三方】	开源模型 API + Agent 基础设施一站式	自助 + 创业计划 + 联盟（affiliate）+ 首月促销；在 OpenRouter 上做供应商
Replicate（2025-12 被 Cloudflare 收购）	公共模型按次调用（5 万+ 模型）、私有模型部署、快速启动微调、Cog 打包工具	公共模型按秒或按输出；私有模型按在线时长（含空闲）	H100 5.49 /卡时、A100 5.04、L40S 3.51；flux-1.1-pro 0.04/张；wan-2.1 720p 0.25/秒视频	开发者快速试模型，尤其图像/视频	开发者社区（模型作者上传）；并入 Cloudflare Workers AI；企业承诺消费
Modal	Serverless Python 计算（GPU/CPU）、Sandboxes、推理、多节点训练、Batch、Notebooks	按秒计费 + 月费档；区域选择 1.15–1.75×，不可抢占 3×	Team 月费 250 美元；H100 3.95、B200 6.25、B300 7.10 /卡时【算】；Sandbox CPU 为基础价 3×	AI Agent 代码沙箱（年化 3 亿美元）、推理、生成媒体、机器人、药物发现	开发者自助（Python SDK）为主；Team / Enterprise；创业与学术额度
Cerebras（已上市 CBRS）	Inference Cloud（共享 + 专属）、Training Cloud、CS-3/CS-4 系统、晶圆级芯片	共享推理按 Token；专属/企业报价；硬件销售	GPT OSS 120B 0.35/0.75、Qwen 3.8 27B 0.99/1.49；免费试用送 5 美元	极速推理（编码、Agent、实时）；为 OpenAI 等大客户建专属容量	自助 Developer 档 + 企业；AWS Marketplace、OpenRouter、Hugging Face、Vercel、OCI；大合同（OpenAI 750 MW）
SambaNova	SambaCloud（API）、SambaStack（软件栈）、SambaRack SN40-16 / SN50（整机）、RDU 芯片	云端按 Token；硬件与本地部署按合同	gpt-oss-120b 0.22/0.59；MiniMax-M3.1-Flash 0.30/1.20；DeepSeek-V3.2 3.00/4.50	本地/主权 AI、Neocloud 交钥匙、金融机构私有推理（JPMorgan）、电力行业（TEPCO Systems）	企业直销 + 硬件销售；Intel 联合销售（与 Xeon 打包）；OpenRouter、Hugging Face 上做供应商
fal	Model APIs（图像/视频/音频生成 600+ 端点）、Serverless GPU、私有部署	按输出（每张、每百万像素、每秒视	FLUX 2 0.012/百万像素；Kling v3 Pro 0.14/秒；	生成媒体：广告、电商、游戏、影视	自助预付 + 企业销售；模型厂首发合作

公司	产品线	计费方式	代表价格（访问日见各节）	解决方案 / 主打场景	销路
		频、每千 Token）；GPU 按秒	Seedance 2.0 Fast 0.0112/千 Token；Nano Banana Pro 0.15/张；H100 列表 4.50、最低 2.49 /卡时		（BFL、字节、可灵）；开发者社区

一句话结论【判断】： 海外这 12 家没有一家只卖 Token。它们都把”按 Token 的 Serverless”当入口，把钱赚在后面三层：**按承诺强度递增的容量产品**（Batch→预留吞吐→专属部署→长约集群）、**训练/定制**（让客户的模型留在平台上）、**分发与渠道**（Marketplace、聚合器、模型厂首发）。详见第 13 节。

1. Together AI

定位：“AI Native Cloud”，开源模型推理 + GPU 集群，覆盖训练到推理。

产品线

- **Serverless Inference**：按 Token 调用 100+ 开源模型。
- **Batch API**：异步批量，5 折。
- **Provisioned Throughput**：按 Token 计价的预留容量，SLA 99%，1 个月起订（2026-07 推出）。
- **Dedicated Inference**：独占 GPU 跑指定模型。
- **GPU Clusters / Instant Clusters**：可抢占、按需、3—180 天阶梯预留；181 天以上找销售。
- **Fine-tuning / Post-training / RL API**：按训练 Token 或 GPU 时计价；2026-10 新增 B200 按需 Post-training。
- **Code Sandbox / Code Interpreter**（收购 CodeSandbox 而来）、托管存储。
- **Together Link**（2026-10）：在 Claude Code、Codex 里切换成开源模型。
- **AI Factory**：与伙伴合建大型数据中心（Hypertec、IBM、沙特 HUMAIN）。

定价（美元）

项目	价格	来源
GLM-5.3 / Kimi K3 / DeepSeek V4 Pro	1.40/4.40；3.00/15.00；1.32/3.96	本地快照 10-14
Batch	Serverless 价 5 折	同上
GPU 集群 H100	可抢占 1.99、按需 3.99、预留 3.69 / 3.45 / 3.19（3—30 / 31—90 / 91—180 天）	同上
GPU 集群 B200	可抢占 4.09、按需 8.19、预留 7.99 / 7.79 / 6.79	同上
专属推理	H100 5.49、B200 8.99	同上
B200 Post-training 按需	列表 11.00，首发促销 9.00（2026-10-20 上架）【三方】	pricingsaas 追踪，访问 2026-11-02
沙箱 / 存储	0.0446 /vCPU 时；0.16 /GiB/月	本地快照 10-14
付款	全部预付，首充 ≥15 美元；2026-04 取消用户分级	同上

10 月价格页还有几处小变动【三方】：下架 Gemma 4 31B、DeepSeek V4 Flash 0731、Llama 3.3 70B、MiniMax M2.7 四个 Serverless 模型；Kimi K3 缓存价上调（来源同上）。

解决方案：开源模型替代闭源（Decagon 客服、Cursor 编码），DeepSWE 成本对比内容，主权 / 区域 AI 工厂。

销路

- 自助预付，Sales Development Engineer 把自助用户转成大单。

- 战略客户经理 + 方案架构师 + FDE 做 POC。
- 渠道：AWS Marketplace（可抵扣 AWS 承诺消费）、Hugging Face Inference Providers、NVIDIA DGX Cloud Lepton、Vercel、OpenRouter。
- 模型厂首发：2026-07-29 与月之暗面签约，Kimi K3 起其开源模型在 Together 首发。
- Startup Accelerator：按融资阶段发 1.5 / 3 / 5 万美元额度 + FDE 工时 + 联合推广。

数字

- C 轮 8 亿美元、投后 83 亿美元（2026-07-01）【官】；上季度年度 bookings 超过 11.5 亿美元【官】；年化收入 12 亿美元【媒·NYT】。
- 收入结构未披露；Sacra 估计 API 占三到四成，其余是 GPU 出租【三方】；毛利约 45%【三方】。
- 自述在 OpenRouter 上承接 DeepSeek V4.1 Flash 40.8%、GLM 5.3 Flash 28.2%、Kimi K3 23.1% 的 Token（截至 2026-09-30）【官】。
- 来源：本地 `../硅基流动与海外同类/硅基流动与海外同类_业务市场营销调研_2026-10-14.qmd` §3 及其 `sources/together/`（原始链接：价格页、C 轮博客、Together Link）。

---

2. Fireworks AI

定位： 开源模型推理 + 用客户数据训练专用模型（“Own Your Specialized Intelligence”）。

产品线

- **Serverless**：四档——Standard、Priority（约 1.25×）、Fast（1.5×）、US-only（1.5×，只在美国处理）。
- **Batch**：5 折。
- **On-demand Deployments**：按 GPU 秒；锁定单一区域加价 50%。
- **Reserved Throughput**：按美元/分钟购买，附 SLA。
- **BYOC**：部署到客户自己的云（Virtual Cloud，18+ 区域、8 家云）。
- **训练**：SFT / DPO / RFT、Training API（2026-08 GA）、专属训练按 GPU 时。
- **Nexus**（2026-07）：抢企业 AI 编程预算；**FireRouter** 路由；自研基准 SII 与模型 Ember-1。
- 2026-06-10 主动下线音频推理和图像生成。

定价（美元，本地快照 10-14）

项目	价格
Kimi K3	Standard 3.00/15.00；Priority 3.75/18.75；Fast 与 US-only 4.50/22.50
DeepSeek V4.1 Flash	0.30/1.20（10-01 由 0.22/0.66 上调）
按需 GPU	H100 / H200 8.00、B200 13.00、B300 15.00、GB300 20.00 /卡时
训练	SFT/DPO 0.5–40 /M 训练 Token；微调后模型按基础模型同价推理
账户	自助 Tier 1–4（累计 50 / 500 / 5,000 美元解锁）；2026-07 起自助预付，合同客户后付

解决方案：AI 编程（Cursor、Sourcegraph）、低延迟产品（Notion 2 秒→350 毫秒）、法律（Harvey）、专用模型训练闭环。

销路

- 自助 → 企业 AE（AI 原生团队、企业两条线，含 EMEA）+ FDE（新加坡、伦敦）。
- AWS 战略合作协议（含联合创业计划）、AWS / GCP Marketplace、微软 Foundry。
- 咨询伙伴 BCG、Deloitte；专门招”AI Factory 伙伴”岗位。
- 首发营销（Qwen 3.6 Plus 除阿里外只在 Fireworks 提供）、Artificial Analysis 测速、Discord 社区约 1.3 万人、DevDay、Forge 大会（2026-11-03）。

数字

- ARR 超过 10 亿美元，同比约 5 倍；日处理超过 40 万亿 Token（2026-07-15）【官】。
- D 轮 15.05 亿美元，投后 175 亿美元（2026-07）【官】。
- 2026-10-20 前后报道在谈 300—400 亿美元估值的新一轮【传】（aiweekly，访问 2026-11-02）。
- 不自有 GPU，从 20 多家云租（Oracle、AWS、Crusoe、微软、AMD）【媒/官】；毛利约 50%【媒·The Information 转述】。
- 来源：本地 10-14 调研 §4 与 `sources/fireworks/`（原始链接：价格页、serverless 价格文档、changelog）。

---

3. OpenRouter

定位： 模型聚合路由，“Token 交易所”。自己不跑推理。

产品线

- 统一 OpenAI 兼容 API：600+ 模型、80+ 供应商（价格页口径；Stripe 新闻稿写的是 400+ / 80+）。
- 自动路由（按价格、速度、可用性）、Fallback、预算与 Key 管理、管理 API、缓存。
- BYOK：用户自带供应商 Key。
- Business 档：欧盟 / 美国境内路由、Workload Identity Federation、1,000 个工作区。
- Enterprise：Private Endpoints（加购）、托管策略、SSO/SAML/SCIM、合同 SLA、DPA 定制、专属支持与 FDE。
- 公开排行榜（Rankings）：按模型、应用、供应商统计 Token 份额。

定价（openrouter.ai/pricing，访问 2026-11-02）

档位	平台费	说明
Free	—	25+ 免费模型；每天 50 次、每分钟 20 次；充值满 10 美元后每天 1,000 次
Standard	5.5%	平台费在**买 credit 时**收，不按请求；推理按供应商标价
Business	8%	加区域路由、高级通知、签署版 DPA
Enterprise	合同折扣	开票 / 采购单付款
BYOK	Standard/Business 每月 2.5 万美元标价用量免费，超出收 5%	Free 档不能用

付款方式含信用卡、**支付宝**、USDC。

解决方案：多模型路由与成本优化；对供应商而言是分发渠道——沐仞若上架，就和 Together、DeepInfra、Novita、硅基流动在同一页比价。

销路：几乎全靠自助和口碑；排行榜和应用榜单本身就是增长飞轮；客户含 NVIDIA、Zoom、Lovable【官·Stripe 新闻稿】。

数字

- Stripe 2026-08-19 宣布收购，价格未披露【官】；媒体报道 70 亿—80 亿美元以上，多为股票【媒】（Stripe 新闻稿、Orrick、The Next Web，访问 2026-11-02）。Stripe 收购理由：“Tokens are the central currency”——Token 是 AI 公司的核心货币。
- 2026-05 B 轮 1.13 亿美元，CapitalG 领投，估值约 13 亿美元【媒】（shopifreaks 汇总）。
- Sacra 估 2026-07 年化**收入**（平台抽成，不是 GMV）约 1.4 亿美元，近四个月环比 +29%；月吞吐约 250 万亿 Token；中国开源模型占 50% 以上用量；每 Token 变现率下降约 60%（费率不变、Token 变便宜）【三方】（Sacra，访问 2026-11-02）。按 5% 抽成反推年化流水约 28 亿美元【算】。

---

4. Groq

定位： 从”LPU 芯片公司”转成”推理云 + NVIDIA 集群运营商”。

背景变化（重要）

- 2025–12–24 与 NVIDIA 签非独家技术授权；NVIDIA 同时聘走创始人兼 CEO Jonathan Ross 及大部分工程团队。媒体普遍报道交易约 200 亿美元，双方未确认【媒】。
- NVIDIA 2026–03 GTC 发布基于该技术的 Groq 3 LPX 机架【媒】。
- Groq 保持独立，CEO 改由 Simon Edwards 担任；2026–06 融 6.5 亿美元，2026–08–17 宣布 3.5 亿美元 A 轮、估值 35 亿美元（Disruptive 领投，NVIDIA 计划参投），2025–09 估值曾为 69 亿美元【官】。
- 2026–08 起成为 NVIDIA Cloud Partner，卖”中大型 NVIDIA 集群用于训练和推理”，旧 LPU 云并行运行【官】。
- 13 个数据中心（北美、欧洲、中东、亚太），计划从 54 MW 扩到 2027 年 200 MW 以上【媒】。
- 来源：Groq 新闻稿、ai2.work 汇总，访问 2026–11–02。

产品线

- GroqCloud API：LLM、语音转写（Whisper）、TTS（Orpheus，预览）。
- 服务档：On–demand、**Flex**（同价、限流放宽 10 倍、容量不足时快速失败，仅付费用户）、Performance、Batch。
- 企业：专属容量、NVIDIA 集群租赁。

定价（console.groq.com/docs/models，访问 2026–11–02）

模型	价格
GPT OSS 120B	0.15 / 0.60（约 500 Token/秒）
GPT OSS 20B	0.075 / 0.30（约 1,000 Token/秒）
Llama 3.1 8B、Llama 3.3 70B	改为”Contact Sales (Enterprise)”
Whisper Large V3 / Turbo	0.111 / 0.04 美元每音频小时
Orpheus TTS（预览）	英文 22、阿拉伯语 40 美元/百万字符

Batch 与缓存 5 折的说法只见于第三方页面【待核实】。

解决方案：极低延迟——语音 Agent、实时对话、阿拉伯语 TTS（中东客户）。

销路：开发者自助（自称 600 万以上开发者【官】）+ 企业销售 + NVIDIA 生态（NCP）。

数字：收入未披露；MLQ 称 NVIDIA 交易前后年收入约 1 亿美元【媒·转述，待核实】。

---

5. Baseten

定位： 生产级专属推理平台，强在”把客户自己的模型稳定跑起来”。

产品线（Series F 公告，访问 2026–11–02）

- **Model APIs**：按 Token 的共享 API。
- **Dedicated Inference**：客户模型独占部署，自动扩缩。
- **Training**：与专属部署同一套 GPU 价格。
- **Model Labs**：自有模型系列 joey–1 / elephant–1 / mammoth–1（价目表上最便宜的几行）。
- 平台层：Model Runtimes、多云容量管理。
- **FDE**：驻场工程师。
- 部署形态：Baseten Cloud、客户 VPC、自托管、混合。

定价（baseten.co/pricing，访问 2026–11–02）

项目	价格
套餐	Basic 0 美元月费按量；Pro、Enterprise 报价，含量折。页面未列平台费
Model APIs	GLM-5.3 1.40/4.40（**Fast 版 2.10/6.60**）；DeepSeek V4 Pro 0813 1.32/3.96；DeepSeek V4.1 Flash 0.30/1.20（Fast 版 0.60/2.40）；Kimi K3 3.00/15.00；GPT OSS 120B 0.10/0.50；joey-1 输入 0.01
专属部署 / 训练（页面价格列未标单位，按分钟理解【判断】）	H100 0.10833 →约 6.50 /卡时【算】；B200 0.16633 →约 9.98【算】；A100 0.06667 →约 4.00【算】；L4 →约 0.85【算】；按分钟计费
Enterprise 附加	自托管、抵扣客户已有云承诺消费、数据驻留、自定义区域、高级 RBAC、定制 SLA

解决方案：语音转写与 TTS、编码（Cursor）、医疗（Abridge、OpenEvidence）、企业（HubSpot、Notion、Harvey）、客服（Decagon）。

销路：自助 Basic → 销售报价 Pro/Enterprise；以 FDE 驻场 + 自托管/混合部署打大企业；“可用你已有的云承诺消费”降低采购门槛。

数字

- Series F 15 亿美元、估值 130 亿美元（2026-06-22），Altimeter、Conviction、Spark 领投；过去一年收入增长 20 倍、推理量增长 40 倍【官】。
- 2026-01 E 轮 3 亿美元、估值 50 亿美元（NVIDIA 出 1.5 亿）【媒】。
- 年化收入约 6 亿美元（2026-03，The Information）【媒·转述】；2026-09 传在谈约 260 亿美元估值【传·待核实】。

6. DeepInfra

定位： 低价、高吞吐的开源模型推理云，自建/托管美国机房。

产品线（deepinfra.com、pricing，访问 2026-11-02）

- **Model APIs**：100+ 模型，LLM、嵌入、重排、语音识别/TTS、文生图、文生视频、文生音乐、世界模型；也转售 Claude、Gemini。
- **Custom LLMs**：自带模型专属部署，按在线时长计费、按分钟计、周结发票。
- **GPU 租用**：DGX B300 按需。
- **DeepCluster**：B300 专属集群，5 年期，256–5,000 卡。

定价

项目	价格
LLM	DeepSeek-V3.2 0.26/0.38；Kimi-K2.6 0.75/3.50；Qwen3.5-397B 0.45/3.00；Llama 3.3 70B Turbo 0.10/0.32；（转售）claude-sonnet-4-6 3.00/15.00
服务档倍率	Standard 1×、Priority 1.5×、**Flex 0.8×**
嵌入 / 图 / 语音	bge-m3 0.01 /M；FLUX-2-pro 0.015 /张；ASR 0.0002–0.003 /音频分钟
专属 GPU	A100 1.49、H100 2.90、H200 3.49、B200 4.89、B300 5.89 /卡时
DeepCluster	**B300 5 年期 1.98 /卡时**，Tier 3 机房，SLA 99.982%
付款	绑卡或预付；开票客户次月初结

解决方案：成本敏感的批量推理、开源模型 API、长期包集群。

销路：自助、无长约；企业咨询；在 OpenRouter 上常是低价供应商。SOC 2、ISO 27001、零留存（ZDR）。

数字：B 轮 1.07 亿美元（2026-05，500 Global 与 Georges Harik 联合领投，NVIDIA、Samsung Next、Supermicro 参投），估值未披露；美国 8 个数据中心；自称 A 轮后 Token 量增长 25 倍【官/媒】（SDxCentral，访问 2026-11-02）。收入未公开。

---

7. Novita AI

定位： 开源模型 API + GPU 云 + Agent 沙箱的一站式开发者云。

与沐仞的关系【待核实】： 业内常说 Novita AI 是 PPIO 派欧云的海外品牌，两者产品结构（模型 API、GPU 实例、Agent 沙箱）高度一致；但本次没找到招股书或官方声明原文。如属实，它就是”中国团队做 Token 出海”的直接样本，需要在 PPIO 招股书里核对。

产品线（novita.ai/pricing，访问 2026-11-02）

- Model APIs：Serverless Endpoints、Dedicated Endpoints。
- GPU：按需实例、Spot（官网称最多省 50%）、裸金属、Serverless GPU（按秒计、30 秒缩到零）。
- Agent Sandbox。
- Embeddings；AI Search（转售 Exa、Tavily，按次）。

定价

项目	价格
LLM	DeepSeek V4 Pro 1.60/3.20；DeepSeek V4.1 Flash 0.30/1.20；GLM-5.3 1.40/4.40；Kimi K3 3.00/15.00；Kimi K2.6 0.80/3.40；Qwen3.8 Max 2.00/6.00；GPT OSS 120B 0.05/0.25
Batch	推广期 5 折
AI Search	Exa 0.007—0.015 /次；Tavily 0.008—0.016 /次
GPU	H100 SXM 按需 3.39、Spot 1.70 /卡时（2026-09-23 抓取）【三方】；官网 GPU 页价格动态加载，本次未直接读到

解决方案：AI 应用开发者、Agent 运行环境。

销路：自助；创业计划；联盟推广（affiliate）；Build Month 等促销（最高 8 折）；OpenRouter 供应商；Ramp 支出数据里被列为头部 AI 基础设施供应商之一【三方】。

数字：融资、收入均未查到可靠数据（Latka 等聚合站的数据与常识不符，不采用）【待核实】。

---

8. Replicate（Cloudflare 旗下）

定位： 开发者”一行代码跑任意模型”的模型托管市场，强在图像/视频。

归属： Cloudflare 2025-11-17 宣布收购，**2025-12-01 交割**，现金对价 5,740 万美元，对 Cloudflare 财务不重大【官·SEC 10-Q/10-K】；保留独立品牌和 API，模型并入 Workers AI【媒】（Cloudflare 10-Q，访问 2026-11-02）。

产品线

- 公共模型：5 万+ 社区与官方模型，按次调用。
- 私有模型：专属硬件部署。
- 快速启动微调（只收处理时间）。
- Cog：开源模型打包工具。

定价（replicate.com/pricing，访问 2026-11-02）

项目	价格
硬件（按秒）	CPU 0.09–0.36、T4 0.81、L40S 3.51、A100 80G 5.04、H100 5.49、H200 5.49 /小时；8×H100 43.92 /小时
官方模型按输出	flux-1.1-pro 0.04 /张；flux-schnell 3 美元/千张；ideogram-v3-quality 0.09 /张；wan-2.1 i2v 480p 0.09、720p 0.25 /秒视频；deepseek-r1 输入 3.75 /M、输出 0.01 /千 Token
私有模型	按在线时长收费，含启动和空闲
企业	承诺消费换多卡 A100/H100、H200 容量；量折；性能 SLA

解决方案：原型验证、图像/视频生成、模型作者发布与变现。

销路：开发者社区（模型作者上传带来长尾流量）；现在加上 Cloudflare 的开发者与企业渠道。

数字：收购价 5,740 万美元【官】，远低于其历史估值——说明”纯托管市场”单独估值有限【判断】。

---

9. Modal

定位： Serverless AI 计算平台（Python 原生），不按模型卖 Token，按秒卖算力；Agent 沙箱是增长最快的业务。

产品线

- Serverless Functions（GPU / CPU，按秒，自动扩缩）。
- **Sandboxes**：给 AI Agent 跑代码的隔离环境，自称累计创建近 30 亿个、可并行 100 万个。
- 推理服务、多节点训练（无需容量承诺）、Batch、Notebooks、HTTP 服务。

定价（modal.com/pricing，访问 2026-11-02）

项目	价格
套餐	Starter 0 月费、含 30 美元/月额度；Team 250 美元/月、含 100 美元额度；Enterprise 定制
GPU（官网按秒）	H100 0.001097/秒 ≈ 3.95；H200 ≈ 4.54；B200 ≈ 6.25；B300 ≈ 7.10；A100 80G ≈ 2.50；L4 ≈ 0.80 /卡时【算】
CPU / 内存	0.0000131 /物理核·秒；0.00000222 /GiB·秒
倍率	指定区域 1.15–1.75×；不可抢占 3×；Sandbox 的 CPU/内存按 3× 计
额度	创业公司免费额度（金额未写）；学术最高 1 万美元

解决方案：编码 Agent（Cognition、Ramp、Linear）、视频/音乐生成（Runway、Suno）、机器人（Physical Intelligence、1X）、药物发现（Chai Discovery）。

销路：开发者自助为主（Python SDK、文档、口碑），Team / Enterprise 销售；不自建机房，从 20 多家云聚合 GPU 再转售【媒】。

数字：D 轮 7.5 亿美元、投后 157.5 亿美元（2026-10-14，Accel 领投）；年化收入超过 10 亿美元，其中 Sandboxes 约 3 亿；5 月 C 轮时为 3 亿美元、估值 46.5 亿【官/媒】（cloudnews.tech、Pillsbury 新闻稿，访问 2026-11-02）。

---

10. Cerebras（Nasdaq: CBRS）

定位： 晶圆级芯片公司，推理云已成最大收入来源。

产品线

- **Inference Cloud**：共享推理（Developer 档）+ 专属推理（企业，预留容量、更多模型、SLA）。
- Training Cloud；微调与训练服务（按协议）。
- CS-3 / CS-4 系统销售；Wafer Scale Engine。

定价（cerebras.ai/pricing 页面源码，访问 2026-11-02）

项目	价格
GPT OSS 120B	0.35 / 0.75（约 3,000 Token/秒）
Qwen 3.8 27B	0.99 / 1.49（约 1,850 Token/秒）
Developer 档	自助按量，绑卡送一次性 5 美元（30 天有效）；社区 Discord 支持
Enterprise	报价；全部模型、优先级、更高限流、可定制权重

共享推理目前只剩 2 个模型；此前的 Cerebras Code（Pro 50 / Max 200 美元/月）未出现在当前价格页【待核实是否停售】。

解决方案：极速推理——编码、Agent、实时应用；为 OpenAI 建专属推理容量。

销路：自助 + 企业；AWS Marketplace、OpenRouter、Hugging Face、Vercel，OCI 计划上架【官】；大客户合同（OpenAI 750 MW，已上调到 200 亿美元以上【媒】）。

数字

- 2026-05-14 上市，募资约 55.5 亿美元，发行价 185 美元【媒】。
- 2025 年收入 5.10 亿美元【媒】。
- 2026 Q2：GAAP 收入 1.801 亿美元；**云（推理）收入 1.26 亿美元，同比 +281%**；GAAP 毛利率 14%、core 毛利率 41%；剩余履约义务 254 亿美元；已签约数据中心容量 600 MW；全年 core 收入指引 8.8—8.9 亿美元【官·8-K】（SEC 8-K，访问 2026-11-02）。
- 客户集中度高（此前 G42 / MBZUAI 占大头）【媒】。

---

11. SambaNova

定位： 自研 RDU 芯片，主攻本地/主权部署和”交钥匙推理机架”，云 API 是展示窗。

产品线（sambanova.ai，访问 2026-11-02）

- **SambaCloud**：OpenAI 兼容的托管推理 API。
- **SambaStack**：软件栈，支持自带权重（BYOC checkpoint）、SambaOrchestrator 调度监控。
- **SambaRack SN40-16 / SN50**：整机柜；SN40-16 主打低功耗、多模型并行（官网称平均约 20 kWh），SN50 主打大模型 Agent 推理。
- RDU 芯片（数据流架构、三级内存）。

定价（cloud.sambanova.ai/plans/pricing，访问 2026-11-02）

模型	输入 / 输出（缓存）
MiniMax-M3.1-Flash	0.30 / 1.20（0.03）
gpt-oss-120b	0.22 / 0.59
gemma-4-31B-it	0.38 / 1.15
Llama-3.3-70B	0.60 / 1.20
DeepSeek-V3.1 / V3.2	3.00 / 4.50

硬件与本地部署按合同，不公开。

解决方案：主权 AI、Neocloud 交钥匙（官网称 6 个月回本，属厂商口径）、美国公共部门、金融（JPMorgan 用 SN40L/SN50 做本地推理【媒】）、**电力行业（TEPCO Systems，官网案例）**、“能效 AI 基础设施 for power utilities”。

销路：企业直销 + 硬件；与 Intel 联合销售（与 Xeon 打包）【媒】；OpenRouter、Hugging Face 供应商。

数字：2026-07-08 Series F 首轮交割 10 亿美元、估值 110 亿美元（General Atlantic 领投）【官】（General Atlantic，访问 2026-11-02）；此前 Intel 约 16 亿美元收购谈判于 2026-01 搁浅，2026-02 E 轮 3.5 亿美元【媒】。收入未公开。

---

12. fal

定位： 生成媒体（图像、视频、音频）专用推理平台。

产品线（fal.ai/pricing，访问 2026-11-02）

- **Model APIs**：图像、视频、音频、3D 等生成模型端点，按输出计价，从预付额度扣；服务器错误和排队时间不收费。
- **Serverless GPUs**：按小时定价、按秒计费；排队和拉镜像不计费。
- 企业定制部署（销售）。

定价

项目	价格
图像	FLUX 2 0.012、FLUX.1 dev 0.025、schnell 0.003 /百万像素；Nano Banana 0.0398、Nano Banana 2 0.08、Pro 0.15 /张
视频	Kling v2.6 Pro 0.07 /秒；Kling v3 Pro / O3 Pro 0.14 /秒；FLUX 3 Max 0.085 /秒；Seedance 2.0 Mini 0.007、Fast 0.0112 /千 Token；Seedance 1.5 Pro 1.20 /M Token
GPU	H100 列表 4.50、最低 2.49；H200 6.00 / 2.99；B200 7.99 / 5.49 / 卡时

解决方案：广告与电商素材、游戏、影视、创意工具。

销路：自助预付 + 企业销售；模型厂首发合作（Black Forest Labs、字节 Seedance、可灵）；开发者社区（2025 年自称 200 万+ 开发者、300+ 企业客户【媒】）。

数字

- 2025-12 D 轮 1.4 亿美元、估值 45 亿美元（红杉领投）【媒·Bloomberg】。
- 年化收入：2025-10 超过 2 亿美元 → 2026-03 约 4 亿 → The Information 报道约 8 亿美元【媒·转述】；在谈 150 亿美元以上估值【传】（Bloomberg、dealroom，访问 2026-11-02）。

---

13. 横向规律【判断】

13.1 同模型同价，差异在”档位”

- GLM-5.3 在 Together、Fireworks、Baseten、Novita 都是 1.40/4.40；DeepSeek V4 Pro 在 Together、Baseten 都是 1.32/3.96（Novita 1.60/3.20 是唯一的不同结构）。单价由模型厂标价锁定。
- 拉开差距的是**服务档**：
  - 速度档：Fireworks Fast 1.5×、Baseten “Fast” 版 1.5×、DeepInfra Priority 1.5×。
  - 区域/合规档：Fireworks US-only 1.5×、Modal 指定区域 1.15–1.75×、OpenRouter Business 才有欧盟/美国境内路由。
  - 降级档：DeepInfra Flex 0.8×、Groq Flex（同价、限流 10 倍、可能失败）、各家 Batch 5 折。

- 即”同一模型按 SLA 分层卖”已是通行做法。沐仞的”绿电时段价”可以直接套进这个框架：做一个 **Green / Flex 档**（价格更低、在电站出力高时优先处理、可能排队），再做一个正常档。

13.2 承诺阶梯是主收入来源

几乎每家都有一条从按量到长约的阶梯：

承诺强度	代表产品	例
无承诺	Serverless 按 Token	全部
时间弹性	Batch / Flex	Together、Fireworks、Novita 5 折；DeepInfra 0.8×
月度	预留吞吐	Together（1 个月起、SLA 99%）、Fireworks
独占	专属部署	H100 2.90（DeepInfra）—8.00（Fireworks）/卡时
天/月	预留集群	Together 3—180 天阶梯
多年	长约集群 / AI Factory	DeepInfra DeepCluster 5 年 B300 1.98；Together AI Factory；Cerebras 对 OpenAI 750 MW

Together 的收入里 GPU 出租估计占六到七成【三方】；Cerebras 剩余履约义务 254 亿美元来自少数大合同。**Token 是获客入口，长约容量才是收入主体。**

13.3 托管溢价：同一张 H100，1.70 到 8.00 美元

- 裸卡 / Spot：Novita Spot 1.70【三方】、Together 可抢占 1.99、DeepInfra 专属 2.90。
- 托管推理：Modal 3.95、fal 列表 4.50、Replicate 5.49、Together 专属 5.49、Baseten 约 6.50、Fireworks 8.00。
- 差价买的是推理优化、自动扩缩、运维和 SLA。沐仞一体机如果对外提供”专属推理”，定价可以对标中间段，而不是裸卡价。

13.4 产品线扩张的四个方向

1. **向上做”让模型留下来”**：训练/RL/Post-training（Together、Fireworks、Baseten、Cerebras）、自有模型（Baseten Model Labs、Fireworks Ember-1、Together 研究）。
2. **向旁做 Agent 基础设施**：沙箱（Modal 年化 3 亿、Together Code Sandbox、Novita Agent Sandbox）、搜索转售（Novita 卖 Exa/Tavily）、编码工具接入（Together Link、Fireworks Nexus）。
3. **向下做容量和机房**：Groq 转成 NVIDIA 集群运营商、DeepInfra 自建 8 个机房、Together AI Factory、SambaNova 卖整机柜给 Neocloud 和电力公司。
4. **向外做分发**：Marketplace（AWS/GCP/Azure Foundry）、聚合器（OpenRouter 上的供应商位）、模型厂首发合同（Together×月之暗面、fal×字节/可灵）。

13.5 GTM 的共同骨架

- **自助预付 → 销售转化**：Together、Fireworks、Novita 都取消了免费额度或改成预付，免费改为”创业计划”按融资阶段发额度并附 FDE 工时。
- **FDE 驻场**：Together、Baseten、OpenRouter Enterprise、Fireworks 都在招 FDE；企业大单靠工程师陪跑。
- **抵扣云承诺消费**：Together 走 AWS Marketplace、Baseten Enterprise 可用客户已有云承诺消费——帮客户的采购部门省流程。
- **首发 + 测速榜单**：新模型首日上线 + Artificial Analysis / OpenRouter 份额当广告。

13.6 资本市场在为”非 Token”收入付溢价

- 估值 / 收入倍数【算，口径不一，仅作量级参考】：Fireworks 约 17.5×、Modal 约 15.75×、Baseten 约 22×（对 6 亿年化），Together 约 7×（GPU 出租占比高）。

- 纯托管市场 Replicate 被以 5,740 万美元收购；纯路由 OpenRouter 因”Token 是货币”的支付叙事被 Stripe 高价收购——**两端（结算层、专用模型层）都值钱，中间的通用托管不值钱。**

---

14. 对沐仞产品线的启示【判断】

1. **把”绿电时段”做成服务档，而不是单纯打折。** 参照 Groq Flex / DeepInfra Flex / Batch 5 折：推出“Green Flex”档（电站出力高时优先、允许排队、价更低）和”Green Priority”档（保证延迟、附绿电产地证明）。这比”公开价 4 折起”更能讲清楚折扣从哪来，也天然和世界模型调度挂钩。
2. **补齐承诺阶梯。** 现在沐仞只有按量 Token 和私有化两端。中间缺”月度预留吞吐”（参照 Together 1 个月起、SLA 99%）和”电站侧专属推理”（按卡时，对标 3–6 美元/卡时的托管段）。电站合作方的一体机产能可以直接打包成这类产品卖。
3. **长约产品要对准电站的特性。** DeepInfra 用 5 年期 B300 1.98 美元/卡时锁客户；沐仞的电站算力天然是长期资产，可以给大客户卖”多年绿电算力包”，价格挂钩电价，这正是 Groq、Cerebras 这类公司在做的”容量合同”。
4. **出海走”供应商位 + 中国模型首发”，别和美国平台拼美国托管。** OpenRouter 上中国开源模型占 50% 以上用量，Together 一家就承接了 DeepSeek V4.1 Flash 四成。沐仞可以作为 OpenRouter 供应商上架（注意 OpenRouter 现属 Stripe，付款端支持支付宝），并主打亚洲节点和价格；若能拿到国内模型厂的海外首发或独家时段，就有 Together×月之暗面式的筹码。
5. **Agent 基础设施是低成本的第二条线。** Modal 沙箱一年做到 3 亿美元年化；Novita 已经把沙箱和搜索转售打包。沐仞可以在 Token 平台上加”沙箱 + 搜索”组合，按秒/按次计费，复用同一个 API Key 和钱包。
6. **能源行业本身是一个客户行业。** SambaNova 把 TEPCO Systems 和”电力公司能效 AI”放在官网首页。沐仞已经在和电站谈合作，可以顺势做”电力行业私有推理”（调度、巡检、客服）这条解决方案线，客户与供给方重合。
7. **定制训练是留住大客户的方式，但不必自建。** Fireworks、Baseten 都靠”微调后同价推理”把客户锁在平台上。沐仞可以先做轻量微调（LoRA）+ 同价推理，作为企业套餐的附加项。

---

15. 待核实

项目	情况
Novita AI 是否为 PPIO 派欧云海外品牌	常见说法，本次未找到一手出处；需查 PPIO 港股招股书
Novita GPU 实例官方价格	官网动态加载，本次只有第三方追踪价（H100 按需 3.39 / Spot 1.70）
Baseten 专属部署价格单位	页面列未标单位，按”每分钟”换算；与 Baseten 过往公开价一致，但应再截图确认
Groq Batch / 缓存折扣	只见于第三方
Cerebras Code 订阅是否停售	当前价格页未列
Groq、DeepInfra、Novita、SambaNova、Replicate 收入	未公开；Groq 约 1 亿美元只是媒体转述
OpenRouter 收购价	70–80 亿美元以上为媒体报道，双方未确认
fal 8 亿美元 ARR、Baseten 260 亿美元估值谈判、Fireworks 300–400 亿美元估值谈判	均为二手报道
所有价格	各家频繁调价（Together 10 月就改了 5 次以上），引用前重新抓取

来源汇总（访问日期 2026-11-02，除非另注）

- **本地已有资料**：`../全部竞品_产品收费与定价_2026-10-21.qmd`（Together、Fireworks、OpenRouter 价格，10-14/10-21 快照）；`../硅基流动与海外同类/硅基流动与海外同类_业务市场营销调研_2026-10-14.qmd` 及 `sources/`（Together、Fireworks 时间线、融资、GTM）。
- Together：pricingsaas 价格变动追踪

- Fireworks：aiweekly 新一轮融资报道
- OpenRouter：价格页、Stripe 新闻稿、Orrick、The Next Web、Sacra、B 轮汇总
- Groq：模型与价格文档、Flex 文档、A 轮新闻稿、ai2.work 汇总
- Baseten：价格页、Series F 公告、dealroom
- DeepInfra：首页、价格页、SDxCentral B 轮
- Novita：价格页、GPU 页、usagepricing H100 追踪
- Replicate：价格页、Cloudflare 10-Q、Cloudflare 收购公告
- Modal：价格页、cloudnews.tech D 轮、Pillsbury
- Cerebras：价格页、模型文档、Q2 2026 8-K、DCD 上市报道
- SambaNova：官网、价格页、General Atlantic 公告、DCD：Intel 谈判搁浅
- fal：价格页、Bloomberg D 轮、dealroom

C 能源与算力结合：产品线、收费与销路

整理日期：2026-11-02。所有网页访问日期均为 2026-11-02，另注明的除外。 标记说明：【未核】= 只在二手或转载来源见到，原文没打开；【算】= 本文用公开数字自己算的，不是对方披露；“未公开” = 查过但没找到。

本篇覆盖 18 家，按和沐仞的可比程度排序。海外 9 家，国内 9 家。

总表

公司	业务线	收费 / 收入模式	代表数字	卖给谁	销路	可借鉴点
共绩科技（北京）	闲时算力调度：弹性部署、Job 批处理、大模型 API、云主机、裸金属	按秒计费的卡时价；批处理分按需价和抢占价	4090 1.98 元/卡时，抢占价 1.19 元（约 6 折）；H100 22.50 元；2025 营收”数千万”【未核】；Pre-A 近 1 亿元，投后 3.5 亿元【未核】	AI 应用公司、模型厂商	自助 + 销售；参与京津冀、长三角、深圳、青海省级算力调度平台	“抢占价”就是现成的”绿电窗口价”模板；论文 + 客户降本案例做背书
Emerald AI（美）	Conductor：让数据中心负荷随电网调节的软件	价格不公开；卖点是”用可核验的灵活性换更快并网”	2026-08 A 轮 1.5 亿美元，估值 10.5 亿；Phoenix 实测 3 小时降负荷 25%；Manassas 约 96 MW 参考设计	数据中心开发商、电力公司、AI 公司、云厂商	NVIDIA、Oracle、Digital Realty 背书；和电力公司签灵活负荷并网计划	沐仞世界模型可单独做软件卖；灵活性先换”并网/扩容”，再换钱
特锐德（青岛，上市）	“算电岛”预制舱供电站 + PowerBrain OS 算电协同系统	卖设备 + 软件（订单金额未公开）	宣称 Token 用电成本降 30%【未核】；最快 150 天送电	GW 级 AI 数据中心、能源企业	电力设备老客户、海外 EPC	最像”整套系统私有化给能源企业”的国内对手
Soluna（美，上市）	风电场旁的数据中心：托管、自营挖矿、电网需求响应、AI 园区（在建）	托管费为主；需求响应补偿；挖矿收益	2026Q1 收入 940 万美元，其中需求响应 54 万；Q2 收入 1,506 万，托管 1,265 万；Q2 净亏 2,071 万	比特币矿企、AI/HPC 租户	和风电场共址；ERCOT 需求响应	弃电消纳 + 需求响应是副业，主收入靠租户托管
Crusoe（美）	能源优先的 AI 数据中心 + Crusoe Cloud（GPU、托管推理、微调）	GPU 小时、Token、专属部署按卡时、大园区长约	按需 GPU 1.50–8.96 美元/卡时；2025 收入约 10 亿、2026 预计约 20 亿【未核】	AI 实验室、Oracle/OpenAI、Microsoft	超大客户长约；2025-03 把挖矿和弃气业务卖给 NYDIG	“先找电，再建算力”的叙事；云和园区两条线并行
Lancium（美）	Clean Campus 园区：并网、输电、选址、行为表后风光储	当”电力房东”：地 + 电 + 并网卖给运营商【未核】	园区起步 1 GW、可到 5 GW+；Abilene 租给 Crusoe	超大规模数据中心运营商	和 ERCOT 规则绑定，可控负荷资质	电站侧”出地出电、别人运营”的合作结构
国网上海 / 国网扬州（电网侧）	上海：数据中心接入虚拟电厂调用；扬州：城市级算电协同平台	上海：计划给容量激励（金额未公开）；扬州：撮合交易 + 碳溯源凭证	上海 16 家 2 小时压减 97.8 MW，VPP 接入 162.1 MW；扬州 24 个资源池、1.6 万 PFLOPS、5,000+ 用户、试运行撮合超 100 万元	数据中心、用算企业	地方经信委组织生态圈；电网公司牵头	沐仞一体机和世界模型可接入 VPP 拿调节收益；按单出具碳凭证

公司	业务线	收费 / 收入模式	代表数字	卖给谁	销路	可借鉴点
大唐中卫 / 中卫市	风光电场物理直供 + 双边交易虚拟直供数据中心	卖电（直供 + 市场化交易）	一期 200 万 kW（光伏 50 万 + 风电 150 万）；数据中心用电价稳定在 0.36 元/kWh【未核】；二期规划 460 万 kW、近 200 亿元	中卫云基地数据中心	地方政府 + 发电央企	发电企业自己做”电一算”打包，是沐仞潜在合作方也是潜在客户
晶科科技（上市）	光伏运营商转绿色算力 + 储能；与商汤战略合作	先机柜租赁，再延伸算力租赁	中卫 1 GW 算电协同项目约 245 亿元、约 5 万架机柜（框架协议）；八大枢纽省份 2.8 GW+ 新能源、22 GWh+ 储能	AI 公司（商汤）	地方政府招商；AI 大厂结盟	新能源业主需要”算力运营能力”，沐仞可做其运营方或系统供应商
远景（戈壁使命）	风光储 + 电网 + AI 数据中心一体的”AI 电力系统”	未公开；提到用 AI 能量预测提升电力交易收益	2030 年 5 GW 目标；乌兰察布星河基地规划 2 GW+	头部科技 / AI 公司	自有新能源 + 海外	和沐仞”世界模型”同一叙事，但做重资产
中国联通三江源（青海）	风光储充 + 智算中心，“青海绿算云”	一体机、私有化、云三种交付（价格未公开）	22,204 架机架、1.7 万 PFLOPS；园区电费降 20%；国产卡 1 万+	全国客户	运营商渠道	一体机 / 私有化 / 云三种交付形态，和沐仞产品线同构
甘肃电投庆阳 / 中国能建庆阳	分散风光”绿电聚合”就近供数据中心；中能建零碳产业园	卖电 + 园区投资运营	甘肃电投 1–5 月帮园区降电费 1,300 万元+；中国移动庆阳到户电价比东部低 0.25–0.4 元/度	庆阳园区数据中心	省属能源企业 + 央企	绿电聚合 + 调度平台，可作为沐仞世界模型的私有化客户
中国电信 息壤	全国一体化智算服务 / 算力分发平台	未公开	纳管算力超 100 EFLOPS	政企、AI 公司	运营商	倡议”统一算力计量交易体系”，沐仞绿色 Token 交易可对接
IREN（美，上市，原矿企）	AI Cloud（GPU 租赁）+ 数据中心	按 GPU 小时长约，按年化收入计	Microsoft 5 年约 97 亿美元；2026 年底 AI Cloud ARR 目标 40 亿+	Microsoft、NVIDIA、Perplexity、Together AI	超大客户长约 + 客户预付 20%	电力资产 → 长约 GPU 云，客户预付解决融资
Hut 8（美，上市，原矿企）	数据中心土建 + 长期租赁	15 年三净租约	River Bend 245 MW 约 70 亿美元，年均 NOI 约 4.54 亿；约 190 万美元/MW/年【算】	Fluidstack（Anthropic），Google 兜底	大厂兜底长约	有大厂兜底的长租约是融资关键
Core Scientific（美，上市，原矿企）	给 CoreWeave 做托管	托管按 MW 计费	约 590 MW，合同期总收入 100 亿美元+；年化约 8.5 亿，约 144 万美元/MW/年【算】	CoreWeave	单一大客户	托管单价的海外参照
Nscale（英 / 挪威水电）	垂直一体 AI 云：自有数据中心、GPU 租赁、云软件	GPU 租赁长约	2026H1 收入 1.406 亿美元、净亏 10.2 亿；合同总值 1,034 亿美元，生效 26 亿；已交付 55 MW	Microsoft、Anthropic	大客户合同；2026-09 递交 S-1	清洁能源 + 主权 AI 叙事能拿大单，但交付风险高

公司	业务线	收费 / 收入模式	代表数字	卖给谁	销路	可借鉴点
Google（功能，不是公司产品）	碳感知计算平台；数据中心需求响应	内部功能；和电力公司签灵活负荷协议	需求响应能力累计约 1 GW【未核】	自用；电力公司	和 I&M、TVA 等签协议	“按次日碳强度预测排程”是最早的工程样板
Phaidra（美）	数据中心冷却 AI 代理 Alfred	未公开	B 轮 5,000 万美元+（2025–10）；冷却节能 25%【未核】	数据中心运营商	NVIDIA、CoreWeave、Applied Digital 合作	机房侧节能软件可做沐仞附加模块

一、几个共同规律

1. **主收入都是”容量”，不是 Token。** 海外原矿企转型后，收入几乎全是按 MW 托管或按 GPU 小时的长约：Core Scientific 约 144 万美元/MW/年【算】，Hut 8 约 190 万美元/MW/年【算】，IREN 和 Nscale 是数十亿美元的多年 GPU 合同。Token 只是 Crusoe 云业务里的一个入口。
2. **“灵活性”单独卖的钱不多，但能换来并网和扩容。** Soluna 2026Q1 需求响应收入 54 万美元，只占总收入约 6%【算】。Emerald 的核心卖点不是需求响应补贴，而是让数据中心”用可核验的灵活性换更快并网”（和 Silicon Valley Power 的灵活负荷并网计划）。国内上海已把数据中心纳入虚拟电厂，下一步是容量激励，金额还没公布。
3. **国内发电企业正在自己往算力走。** 大唐（中卫）、晶科（中卫 1 GW）、甘肃电投（庆阳）、中能建（庆阳）、远景（乌兰察布）都在做”电 + 机柜 / 算力”打包。他们缺的是算力运营、调度和市场化交易能力，这是沐仞”联合运营 / 整套系统私有化”的直接买方。
4. **电网侧在建”算电协同平台”，碳凭证开始按单出具。** 扬州平台按单核算碳排放并出具溯源凭证；上海建了 15 家的生态圈。沐仞的绿色 Token 交易平台可以对接这些平台，而不是另起炉灶。
5. **最直接的国内对手是共绩科技和特锐德。** 共绩做”需求侧”：聚合别人的闲置卡，按秒计费、抢占价打 6 折；特锐德做”设备侧”：卖供电舱 + PowerBrain OS。沐仞的位置在两者之间：电站侧自有一体机 + 调度模型。

二、对沐仞产品线和定价的具体建议

方向	参照	沐仞可以怎么做
绿电窗口价	共绩 Job 批处理抢占价（约 6 折）	Token 和卡时分三档：实时价、可延迟价（绿电窗口内执行）、可中断价（弃电时段执行）。可延迟、可中断两档的折扣幅度由世界模型按弃电预测定
电站侧托管 / 联合运营	Lancium（电力房东）、Soluna（风电场共址）、Core Scientific（按 MW 托管）	和电站签”出地出电、沐仞出设备和运营”的分成；参照按 kW·月计费，或按算力收入分成
世界模型软件授权	Emerald Conductor、特锐德 PowerBrain OS、Phaidra	给发电企业、园区、数据中心卖调度软件：一次性私有化部署费 + 按纳管 MW 的年费；价格要自己定，对手都没公开
电网调节收益	国网上海 VPP、Soluna ERCOT 需求响应、Google 需求响应协议	一体机集群申报虚拟电厂调节能力；收益和电站或客户分成
碳 / 绿电凭证	扬州按单碳溯源凭证	每笔 Token 订单出具绿电比例和碳排放凭证，可做付费增值项，服务出海客户
交付形态	联通三江源（一体机 / 私有化 / 云）	沐仞产品线也按这三种形态排，各自定价
融资结构	IREN 客户预付 20%、Hut 8 由 Google 兜底租约	大客户长约要求预付或第三方兜底，用于一体机采购融资

三、分公司详情

3.1 共绩科技（ComNergy，北京）

1. **产品线**（suanli.cn 官网）：弹性服务部署、Job 批处理、大模型云服务（按量计费、无订阅费）、云主机、裸金属（按 8 卡时 / 24 小时 / 7 天 / 30 天打包）。官网自述用”算电协同”技术和闲时算力调度，没有展开。
2. **收费**（价格页）：
   - 弹性部署和云主机按秒计费，挂牌卡时价举例：4090（24G）1.98 元、5090 3.25 元、H20-96G 12.00 元、H100 22.50 元、H200 35.00 元、昇腾 910C 13.20 元。
   - Job 批处理分按需价和抢占价，抢占价约为按需价的 6 折：4090 1.98 / 1.19 元，H800 25.00 / 15.00 元，A800 7.80 / 4.68 元。
   - 页面没有专门的”闲时 / 绿电”价格。
3. **经营数字**：
   - 2025 年”数千万营收”，Pre-A 投后估值 3.5 亿元（快科技转极客公园，2026-04-08）【未核】；另一转述称”2025 年营收近 3,000 万元并实现盈利，2026 年目标亿级”【未核】。
   - 2026-05 近亿元 Pre-A，春华创投、彼岸时代领投（36氪，2026-05-07）。
   - 论文口径：42 个智算中心、9 省、70 万+ 节点、1.8 万用户（见本地笔记 `算电协同论文_清华共绩_2026-10-25/论文阅读笔记_2026-10-25.md`）。
4. **卖给谁**：AI 应用和模型公司，案例有面壁智能（成本降 68%）、LiblibAI（降 50%）、Tripo（降 40%）、Remy（96 小时内扩到近 2,000 卡）（官网、36氪）。
5. **销路**：自助平台 + 销售；参与京津冀、长三角、深圳、青海省级算力调度平台，在谈国家算力中心合作（快科技）。36氪报道称其在和风光电场、虚拟电厂合作做算力调度和电价联合优化，并计划把夜间闲置算力换成 Token 卖到海外。
6. **对沐仞**：抢占价是”绿电窗口价”的现成样板；他们在电侧只有电价信号，沐仞在电站侧有实测出力和弃电数据，这是差异。他们也在说”夜间算力换 Token 出海”，和沐仞”词元出海”撞题，需要在对外材料里写清区别。

3.2 Emerald AI（美国）

1. **产品**：Emerald Conductor。四项功能：实时连接电网和数据中心、编排 AI 负载和现场能源、跨数据中心机群优化、用可审计的计量数据核验表现。灵活性分三类：时间（暂停或放慢可批处理任务）、空间（跨区迁移）、资源（调用电池和现场电源）（官网）。
2. **收费**：官网和公开资料都没有价格。官网说法是把用电变成”可变现资产”、延后昂贵的电网升级。
3. **数字**：
   - 2026-08-25 A 轮 1.5 亿美元，估值 10.5 亿美元，Energize Capital、DCVC 领投，NVIDIA、Samsung、Siemens、GE Vernova、RWE、JERA 等跟投（Pulse 2.0）。另有报道称申报文件显示 1.5 亿中已售 9,020 万（Runtime Wire）【未核】。
   - 演示：Phoenix Oracle 数据中心高峰期 3 小时降负荷 25%（官网称已发表于 *Nature Energy*）；伦敦 National Grid 演示 200 个功率目标 100% 达成；弗吉尼亚到芝加哥毫秒级推理迁移；加州首个整座数据中心多 MW 部署；Manassas 约 96 MW NVIDIA Vera Rubin 参考设计（官网）。
4. **卖给谁**：数据中心开发运营商、电力公司和电网运营商、AI 公司和云厂商、监管方（官网）。
5. **销路**：NVIDIA、Oracle、Digital Realty 等技术伙伴背书；电力伙伴有 National Grid、NextEra、Dominion、PJM、Silicon Valley Power 等；和 Silicon Valley Power 的灵活负荷并网计划用”可核验、可调度的灵活性”换更大的并网额度（Pulse 2.0）。
6. **对沐仞**：最接近”世界模型 + 调度软件”单独售卖的海外样本。它说明灵活性的第一价值是”换并网 / 扩容”，其次才是补贴。沐仞对电站和园区的话术可以照搬：一体机集群是可核验的灵活负荷。

3.3 特锐德（300001，青岛）

1. **产品**：2026-06-06 首发高压交直流预制舱供电站”算电岛”，工厂预制变压器、开关柜、固态变压器，直连 110/220 kV，800V 直流母线供机房；配套 PowerBrain OS 算电协同操作系统，感知风光出力、电网负荷、储能状态，按算力任务优先级调配负荷（新华网，2026-06-08；证券时报转同花顺，2026-09-15）。
2. **收费**：卖设备 + 系统，订单金额未公开。
3. **数字**：宣称 Token 用电成本降 30%、土建量降约 70%、最快 150 天送电（同花顺，2026-10-16）【未核，宣传稿】。
4. **卖给谁 / 销路**：GW 级 AI 数据中心和能源企业；依托原有电力设备客户和海外订单（中东 400 kV 预制舱变电站，中国日报，2026-09-04）。
5. **对沐仞**：沐仞”整套系统私有化给能源企业”的国内最直接对手。差别在于特锐德从供电硬件切入，沐仞从推理一体机 + 调度模型切入；可考虑和这类设备商合作而不是正面竞争。

3.4 Soluna Holdings（SLNH，美国）

1. **业务线**：在风电场等新能源旁建数据中心（Project Dorothy 1A/1B/2 在德州风电场旁，Kati、Cynthia 为 ERCOT 行为表后选址），收入分数据托管、自营挖矿、电网需求响应，AI 园区在建。
2. **收费 / 数字**：
   - 2026Q1：总收入 940 万美元，托管 669 万、挖矿 217 万、需求响应 54 万、AI 0（沐仞 10–21 竞品稿，来源为季报）。
   - 2026Q2：总收入 1,506 万美元（同比 +145%，扣除会计口径变化 +73%），托管 1,265 万，挖矿 172 万；净亏 2,071 万（The Energy Mag 转季报）。
   - 2023 年加入 ERCOT 需求响应时预计在 Dorothy 增加 10 美元/MWh 以上收入、电价可压到 20 美元/MWh 以下（公司早期预测，Soluna 新闻）。
   - Kati 1 与 Bitdeer 签 28 MW 协议（2026–08–13）【未核】（TipRanks）。
   - 托管单价未公开。
3. **卖给谁 / 销路**：比特币矿企租户（Bitdeer 等）、AI/HPC 租户；和风电场业主共址，消纳弃风；参加 ERCOT 需求响应。
4. **对沐仞**：模式最像”电站旁算力”，但主营仍是租户托管，需求响应只是小头。可借鉴的是”和电站共址 + 弃电时段多跑负荷 + 需求响应额外收入”的三层收入结构；风险提示是该公司持续亏损。

3.5 Crusoe（美国）

1. **业务线**：能源优先的 AI 数据中心园区（Abilene 1.2 GW 给 Oracle/OpenAI，另一 900 MW 给 Microsoft）+ Crusoe Cloud（GPU 实例、托管推理、Serverless 微调、专属部署）。2025–03 把比特币挖矿和弃气发电业务卖给 NYDIG，专注 AI（DCD）。
2. **收费**（价格页，2026–11–02 抓取）：
   - GPU 按需和现货价挂牌 1.50—8.96 美元/卡时（页面表格逐行对应关系抓取时没能拆清，需在页面上核对），长约”找销售拿最低价”。
   - CPU 0.04 美元/vCPU 小时；托管 K8s 0.10 美元/集群小时；存储 0.06—0.10 美元/GiB/月。
   - 自助专属部署：B200 9.65、H200 6.00、H100 5.50、MI355X 7.70 美元/卡时（10–21 抓取时 H100 是 6.30，已下调）。
   - 微调每百万 Token 0.40—10 美元。
3. **数字**：2025 收入约 10 亿美元、2026 预计约 20 亿美元（Sacra 等第三方）【未核，非公司披露】。
4. **卖给谁 / 销路**：AI 实验室和超大客户（Oracle/OpenAI、Microsoft）长约；自助云面向开发者。
5. **对沐仞**：同时做”园区”和”云”两条线，园区靠长约、云靠价格页。它已经不再强调弃电，叙事转向”能源 + 速度”，说明弃电消纳本身撑不起大规模算力，需要电网电兜底。

3.6 Lancium（美国）

1. **业务**：Clean Campus 园区（Abilene、Childress County、Hall County），提供电力编排、并网与高压输电、选址工程、土地、可再生能源接入；园区起步 1 GW、可到 5 GW+，行为表后配光伏和储能（官网）。
2. **收费**：官网无价格。媒体描述为”电力房东”，自己不运营数据中心，Crusoe 是 Abilene 租户；早期给 CleanSpark 托管按”用电量 + 托管费”收费（GovTech 等转述）【未核】。Smart Response 软件宣称可把电费降 50% 以上（2022 新闻稿，公司说法）。
3. **销路**：靠 ERCOT 可控负荷资源（CLR）资质和并网能力拿超大客户。
4. **对沐仞**：电站侧”出地出电、别人运营”的结构可直接搬到”电源合作模式”里；也说明”能拿到并网和调节资质”本身可定价。

3.7 国网上海 / 国网扬州（电网侧平台）

1. **上海**（澎湃，2026–07–15）：
   - 16 家数据中心 2 小时最大压减 9.78 万 kW（97.8 MW），参与方有上海电信、万国数据、上海仪电、阿里巴巴。
   - 三条路径：“一调”柔性负荷 13 户次、“一切”柴发切换 3 户次、“一转”算力跨域转移 1 户次。
   - 跨省现货价格测试中算力用电成本降约 31%。
   - VPP 接入数据中心申报调节能力 16.21 万 kW。
   - 计划把优质算电资源纳入备用体系并给容量激励，金额未公布。
   - 上海市经信委组建算电协同生态圈，首批 15 家。
2. **扬州**（科技日报，2026–10–28）：
   - 国网扬州供电公司与扬州大数据集团研发，全国首个城市级算电协同平台。
   - 接入 24 个资源池、1.6 万 PFLOPS、5,000+ 注册用户，9 月试运行以来撮合交易超 100 万元。
   - 功能：电价引导错峰、逐小时碳排放数据、跨区调度到西部、出具算力碳排放溯源凭证；企业用能成本降约 15%。
   - 平台收费方式未公开。
3. **对沐仞**：电网公司是”调节需求方”和”平台方”，不是竞争者。沐仞可把一体机集群申报进 VPP，并把订单级碳凭证对齐扬州口径。

3.8 大唐中卫 / 宁夏中卫

1. **业务**：大唐中卫云基地绿电供应一期 200 万 kW（光伏 50 万 + 风电 150 万），新增负荷走专线物理直供，存量负荷走市场化双边交易做”虚拟直供”；光伏 2026-02-05 开始直供（pv magazine；新华网，2026-03-18）。二期由大唐宁夏分公司竞得，规划 460 万 kW、总投资近 200 亿元。
2. **价格**：中卫市通过市场化机制把数据中心用电价稳定在 0.36 元/kWh，新建数据中心绿电比例超 80%（人民日报海外版，经搜索摘要转述）【未核】。
3. **对沐仞**：发电央企 + 地方政府的打包模式，客户是数据中心，产品是电。沐仞可以给这类发电方提供”把电直接卖成算力 / Token”的运营层。

3.9 晶科科技（601778）

1. **业务**：光伏电站运营商转向绿色算力与综合能源服务；轻资产（2025 年新增装机 0.4 GW、出售 1.4 GW）；算力中心先做机柜租赁，再择机延伸到算力租赁，计划引入战略方共投（开源证券研报，格隆汇转载）。
2. **数字**：宁夏中卫 1 GW 算电协同项目总投资约 245 亿元、约 5 万架机柜、分三期（框架协议，规模和投资尚不构成承诺）；在八大算力枢纽省份有 2.8 GW+ 新能源、22 GWh+ 储能资源（同上）。2026H1 营收 14.03 亿元（同比 −33.94%），归母净利 −1.87 亿元（经搜索摘要转述东方财富）【未核】。
3. **销路**：2026-07-19 WAIC 与商汤签战略合作（绿电直连、算电协同、资本联动、新能源 + AI 出海）（财闻【未核】；证券时报）；与中卫、和林格尔、乌兰察布政府有算力中心合作意向。
4. **对沐仞**：新能源业主有电、有地、有储能，缺算力运营。这是”联合运营”和”整套系统私有化”的目标客户画像。

3.10 远景（戈壁使命）

1. **业务**：2026-06 发布”戈壁使命”，计划 2030 年在全球戈壁荒漠建成 5 GW 绿色 AI 算力中心；首个旗舰乌兰察布星河基地规划 2 GW+，高比例绿电直连、不依赖现有电网（新华网，2026-10-02）。
2. **收费**：未公开。报道提到用 AI 能量预测提升新能源市场化交易收益。
3. **对沐仞**：远景把新能源、电网、储能、算力统一到一个调度系统，叙事和沐仞世界模型高度重合，但走重资产、GW 级。对外材料要强调沐仞是轻资产、电站侧、可私有化的软件 + 一体机。

3.11 中国联通三江源绿电智算融合示范园（青海）

1. **业务**：风光储充 + 智算中心，微电网动态匹配风光波动；推出”青海绿算云”，提供一体机、私有化、云三种部署方式（新华网，2026-07-22）。
2. **数字**：22,204 架标准机架、1.7 万 PFLOPS；园区年发绿电约 1,000 万度、100% 园区消纳；储能峰谷优化后电费降 20%；国产 GPU 7 个品牌、1 万卡以上（同上）。对外价格未公开。
3. **对沐仞**：交付形态和沐仞产品线一致，可作为定价分层参照（一体机买断 / 私有化 / 云按量）。

3.12 甘肃电投庆阳 / 中国能建庆阳

1. 甘肃电投庆阳”绿电聚合”试点：规划 200 万 kW，首批 100 万 kW，聚合分散风光就近直供数据中心并配储能，由智慧调度平台监控；1–5 月帮园区企业降用电成本 1,300 万元以上（新华网，2026-01；中国能源报）。
2. 中国移动庆阳数据中心靠绿电聚合 + 市场化交易，到户电价比东部工业电价每度低 0.25–0.4 元（新华网，2026-04，经搜索摘要转述）【未核】。
3. 中国能建庆阳”东数西算”智慧零碳大数据产业园：源网荷储一体化供电，新能源消纳率目标不低于 90%；股权和收益结构未公开（环球网）。
4. **对沐仞**：省属能源企业已经在跑”绿电聚合 + 调度平台”，世界模型可以作为其调度平台的升级件出售。

3.13 中国电信 息壤

1. 全国一体化智算服务平台与算力分发网络，纳管算力超 100 EFLOPS（2026-07 WAIC 发布，经搜索摘要转述）【未核】。
2. 中国电信总经理在 2026 中国算力大会提出共建统一算力标识与计量交易体系、推动绿电直供和源网荷储（新华网，2026-05-10）。收费标准未查到。
3. **对沐仞**：运营商在推统一计量交易，沐仞绿色 Token 交易平台应尽早对齐其计量口径，争取作为绿电算力供给方接入。

3.14 IREN（美国，上市，原比特币矿企）

1. **业务**：AI Cloud（GPU 租赁）+ 自建数据中心（Childress、Sweetwater 2 GW、加拿大 Mackenzie、Canal Flats）。
2. **收费 / 数字**：

- Microsoft 5 年专属 GPU 服务合同约 97 亿美元，年化约 19.4 亿，客户预付 20%（IREN 8-K；Pulse 2.0）。
- 2026-07 与 Prometheus、Perplexity、Together AI 签合计约 28 亿美元多年合同；2026-05 与 NVIDIA 签 5 年约 34 亿美元；2026 年底 AI Cloud ARR 目标 40 亿美元以上（同上）。
- ARR = 合同 GPU 加权平均卡时价 × 8,760 小时，具体卡时价未公开。
- 电力净成本曾报 0.035 美元/kWh（财报电话会转述）【未核】。公司历来宣称使用可再生能源，本次没有找到可核的比例。

3. **对沐仞**：长约 + 客户预付是 GPU 资产融资的关键结构。

3.15 Hut 8 与 Core Scientific（美国，原比特币矿企）

1. **Hut 8**：River Bend 园区给 Fluidstack（Anthropic 体系）15 年三净租约，初始 245 MW、约 70 亿美元，Google 为租金兜底，预计年均 NOI 约 4.54 亿美元；Fluidstack 还有后续最多 1,000 MW 的优先权（DCD）。折合约 190 万美元/MW/年【算】。
2. **Core Scientific**：给 CoreWeave 托管约 590 MW、六个站点，合同期总收入 100 亿美元以上，年化约 8.5 亿美元；2026Q1 可计费 243 MW，Q1 总收入 1.152 亿美元，其中托管 7,750 万（Core Scientific 投资者资料；Quartr）。折合约 144 万美元/MW/年【算】。
3. **对沐仞**：两家都是”手里有电和场地 → 转型做 AI 托管”。这是海外”电站 + 算力”最主流的变现方式，单价可作为沐仞联合运营谈判的参照上限（国内电价和机柜价差别大，不能直接换算）。

3.16 Nscale（英国，挪威水电）

1. **业务**：垂直一体 AI 云：控股数据中心（挪威 Glomfjord、Narvik/Kvandal 等）、NVIDIA GPU 租赁、自有云软件。
2. **数字**：2026-09-18 递交 S-1 拟在纽交所上市；2026H1 收入 1.406 亿美元、净亏 10.2 亿；截至 2026-08-31 合同总值 1,034 亿美元，其中生效 26 亿；Microsoft 合同最多约 438 亿、Anthropic 约 446 亿；已交付 55 MW；最大客户占 H1 收入 52%（SEC S-1 封面；W.Media）【财务数字来自二手报道，未逐条对 S-1 正文】。Microsoft 在挪威约 62 亿美元、5 年的算力租赁（DCD）。
3. **对沐仞**：清洁水电 + 主权 AI 叙事能拿到超大合同，但交付能力（55 MW 对约 10 GW 需求）是主要风险。沐仞出海讲”绿电算力”时可以用它做对标，同时提示交付风险。

3.17 Google（碳感知计算 + 需求响应）

1. 2020-04-22 公布碳感知计算平台：每天对比次日电网碳强度预测（Electricity Maps 提供）和自身逐小时用电预测，把视频处理等非紧急任务挪到低碳时段；第一版只做时间平移，计划扩展到跨数据中心（Google 博客）。
2. 2025-08 与 Indiana Michigan Power、TVA 签需求响应协议，高峰时把机器学习等非紧急负载挪走（DCD）；之后累计约 1 GW 需求响应能力写入电力合同（DCD）【日期未核】。
3. **对沐仞**：不是对外产品，但”次日碳强度预测 × 负荷预测 → 逐小时排程”是世界模型最早的工程样板，可在 BP 中引用。

3.18 Phaidra（美国）

1. **产品**：数据中心冷却 AI 代理 Alfred，像虚拟运行员一样调温度、压力、流量。
2. **数字**：2025-10 B 轮 5,000 万美元以上，Collaborative Fund 领投、NVIDIA 跟投；合作方有 CoreWeave、Applied Digital；冷却节能约 25%（GeekWire）【未核】。价格未公开。
3. **对沐仞**：机房侧节能是另一个可卖的软件模块，但离沐仞主线较远。

四、没查到或需要后续核实的

项目	状态
Emerald、特锐德、Phaidra、Lancium 的软件 / 系统价格	均未公开
Soluna 托管单价、Q2 需求响应收入	未公开；Q1 54 万美元来自 10-21 稿
共绩科技营收（“数千万”vs”近 3,000 万并盈利”）	只有媒体转述
上海容量激励标准（元/kW）	尚未公布
中卫 0.36 元/kWh 数据中心电价	只见搜索摘要

项目	状态
国家电投、三峡、中核、中电建的算力项目	本次搜索没有找到具体项目报道，需单独查
中科曙光 / 中科可控算力服务定价	本次未查
Crusoe GPU 按需价逐行对应	页面抓取时表格错位，需人工核对

D｜私有化部署 / 大模型一体机 / 企业智能体 竞品：产品线、定价、方案、销路

- 调研日期：2026-11-02（下文所有来源的访问日期均为 2026-11-02，不再逐条重复）
- 范围：国内一体机硬件厂商（华为昇腾生态、浪潮、联想、新华三、曙光）、模型或云厂商的私有化业务（智谱、百度千帆、阿里百炼专属版、讯飞星火）、智能体平台软件（Dify、FastGPT、实在智能，无问芯穹引用已有调研），海外参照（NVIDIA AI Enterprise、HPE Private Cloud AI）
- 标注规则：【官方】厂商官网、官方文档或云市场挂牌；【公告】中标或候选人公示（多数经媒体转引，原公告未逐一打开核对的写明）；【媒体】新闻报道；【估算】本文按公开数字做的粗算；【未核实】只有单一二手来源或厂商自述
- 关键结论：国内一体机厂商没有一家公开标价。能拿到的真实价格只有三种来源：中标公告、云市场挂牌、少数软件厂商的官网价目

0. 总表

公司	产品线	计费方式	代表价格	解决方案	销路
华为昇腾（含伙伴）	Atlas 800I A2 推理一体机、FusionCube A3000 训推超融合、伙伴贴牌 DeepSeek 一体机	硬件一次性买断 + 伙伴实施服务	推理 32B 约 30–50 万元，671B 约 300–500 万元；训推 200 万到 1000 万元以上【媒体，非官方】	政务、金融、运营商、能源、教育	几乎全走伙伴：100 多家伙伴发布了昇腾 DeepSeek 一体机；鲲鹏加昇腾共 8800 多家伙伴【媒体转华为口径】
浪潮信息 元脑	元脑企智 EPAI 一体机（基础、标准、创新、高级、集群 5 档）、NF5698A7 双模版、R1 推理服务器	硬件买断，捆绑 EPAI 平台软件	不公开；整体市场”几十万到数百万”	制造、金融、政务、教育	元脑生态：ISV 和集成商做增值渠道，宣称行业伙伴 2000 多家
联想	问天 WA7780 G3、WA7785a G3（单机 671B）；与沐曦合作的智能体一体机（ThinkStation PX）和训推一体机（WA5480 G3 + 8×C500）	硬件买断	不公开；工作站方案据称”万元级起步”【未核实】	医疗科室级、教育、企业	联想分销体系，加国产 GPU 联合方案
新华三	灵犀 Cube 一体机：纯享版、使能版，共 6 款型 12 款产品，覆盖 14B–671B；LinSeer Hub、RT、Copilot	硬件加平台分档，使能版另收专家服务	不公开	政企、运营商、教育	H3C 渠道和集成商
中科曙光 / 海光	曙光云全国产 DeepSeek 超融合一体机（国产 x86 + 国产 GPGPU）	硬件买断	不公开	信创政务、科研	信创渠道
智谱	GLM 本地化部署套餐、行业大模型平台建设、MaaS API、GLM Coding Plan 团队版	本地化部署按项目定价（模型、算力、实施）；API 按量；团队按席位	2024 年本地化客户平均约 215 万元/家【估算】；中标 1058 万、1090 万、9390 万（候选）【公告】；团队席位 598 元/月【媒体】	政务、气象、医疗、科创情报、运营商	直接投标央国企和政府，云端开放平台

公司	产品线	计费方式	代表价格	解决方案	销路
百度智能云 千帆	千帆 DeepSeek 一体机（昆仑芯 P800 OAM/PCIe、昇腾 Atlas 800）、百舸一体机、千帆平台私有化	软件授权、软硬一体、租赁三种	不公开；2025 年 1–11 月中标 95 个、7.1 亿元【媒体统计】	政务、金融、能源、工业	直接投标，在云厂商里中标项目数和金额都居首
阿里云 百炼专属版	百炼专属版 AI 训推一体机（单机 16 卡，分训推、智能体、高性能三种配置）；公有云 Token Plan 团队版	一体机报价不公开；团队版按席位包月	团队席位 198、698、1398 元/月【二手，控制台未核】	金融、政企、数据不出域行业	直销加生态伙伴
科大讯飞 星火	星火一体机（与华为合作）、星火医疗和办公一体机、行业大模型项目	项目制（软硬加应用）	某银行 2 套一体机报价 968 万元，预算 1658 万元【公告候选，媒体转引】；2025 年大模型中标额 23.16 亿元【公司口径】	教育、政务、医疗、金融、工业	直接投标，连续两年大模型中标金额第一
Dify（LangGenius）	社区版（开源）、Enterprise 私有化授权	年度授权，加付费咨询、定制和 SLA	AWS 全球 15 万美元/年；AWS 中国区 50 万元/年（西云数据）【官方挂牌】	通用企业智能体、知识库	云市场、Dify Partners、阿里云 DMS 托管
FastGPT（环界云）	SaaS 免费、基础、高级、定制；商业版：Sealos 全托管、自有服务器部署	SaaS 按月；托管版按月或按年；技术服务按人天	托管单节点 1 万元/月或 12 万元/年；多节点 2.2 万元/月或 26.4 万元/年；人天 2000–3000 元【官方】	知识库问答、客服、企业内部智能体	官网直销，Sealos 云
实在智能	实在 Agent（RPA + 智能体）、昇腾一体机版	按数字员工或流程（厂商自述）	私有化”几万到几十万”、企业定制平台 30–200 万元以上【未核实，厂商自家站点】	金融、制造、政务流程自动化	直销加伙伴
NVIDIA AI Enterprise（海外参照）	AI Enterprise 软件栈（NIM、NeMo 等），DGX 和认证系统	按 GPU 订阅或永久授权	4,500 美元/GPU/年；5 年 18,000 美元；永久 22,500 美元；教育和 Inception 75% 折扣；云上 1 美元/GPU/小时【官方】	通用	NVIDIA 伙伴网络（NPN）、OEM、云市场
HPE Private Cloud AI（海外参照）	与 NVIDIA 联合设计的交钥匙私有 AI 云：Developer、Small 到 Large、Air-Gapped Large	GreenLake 订阅或买断，经销商定价	不公开（商城显示”Login for pricing”）	通用企业	渠道商、GreenLake、Unleash AI 伙伴计划

1. 一体机价格锚：中标与候选公示样本

这是目前能拿到的最硬价格数据。全部是 DeepSeek 或大模型一体机及配套服务项目。

时间	采购方	标的	预算	中标或候选报价	中标方（品牌）	备注与来源
2025-03-18	紫金山实验室	DeepSeek-R1 671B 满血版私有化部署系统	198 万元	195.2 万元	南京易平方网络科技	【公告，媒体转引】网易

时间	采购方	标的	预算	中标或候选报价	中标方（品牌）	备注与来源
2025-03	中远海运科技（上海）	DeepSeek 一体机及配套服务	—	413.6 万元（第一候选）	上海集聿信息技术	【公告候选，未打开原文】chinamae
2025-03 意向	浙江师范大学	DeepSeek 一体机 2 台 + 网络存储 + 智能体开发平台 + 3 年 7×24 服务	350 万元	意向，无结果	—	【采购意向】网易
2025-04	甘肃省农业农村厅（项目）	本地化部署 DeepSeek 并适配业务子系统	88.0 万元	83.2 万元	北京中科江南信息技术	【公告，原页打开失败，数字取自搜索摘要】甘肃经济信息网
2025-05	国信证券	DeepSeek 一体机 2 台 + 高速组网	619 万元	第一候选 568.2 万元；13 家候选报价 385–600.08 万元	深圳华云信息系统	【公告候选，媒体转引】新浪。【估算】约 284 万元/台（含组网）
2025-06-26	深圳宝建投智能科技	DeepSeek AI 智能应用一体机 1 套	77.14 万元	68.6 万元	四川科瑞软件（超聚变 G5500 V7）	【公告，媒体转引】网易
2025-07-03	广西北部湾银行	DeepSeek 大模型一体机：≥32 张互联卡、单卡显存 ≥64GB、671B BF16/FP16 满血、16K 上下文、15 并发、10 token/s；CPU 海光或鲲鹏	—	358 万元（第二 318.98 万元，第三中国移动广西 296 万元）	润建股份	【公告，媒体转引】移动支付网。【估算】约 11.2 万元/卡（含整机和服务）
2025	合肥工业大学智能制造技术研究院	DeepSeek-R1 671B 服务器 + 集群管理软件	—	171.835 万元	安徽瑞涛信息技术	【公告，搜索摘要，原页未加载】edudigital123
2026-04-03	某银行（未具名）	AI 大模型一体机 2 套，签约 10 天到货、3 天部署	1658 万元	讯飞智元 968 万元（第一）；中关村科金 831.1 万元；神州数码融信 1420 万元	讯飞智元	【公告候选，媒体转引】新浪

价格带归纳（媒体口径）： – 推理一体机内置 R1 32B、70B 或 671B，价格从几十万到数百万元。训推一体机仅 32B 机型就要数百万元。超过 60 家企业推出了 DeepSeek 一体机（不完全统计）。出处：财联社/科创板日报 2025-02-27 – 中国电信息壤智算一体机 DeepSeek 版基于昇腾，有 8、16、32 卡规格，分入门、通用、增强三型。最高配满血推理机优惠价近 600 万元。京东云一体机几十万到几百万元。出处：财联社 2025-02 – 方案价格从十万元到数百万元，单机一般配 8 颗或 12 颗 AI 芯片。浙商证券预测央国企 DeepSeek 一体机销售额 2025–2027 年为 1236、2937、5208 亿元【券商预测，偏乐观】。出处：第一财经 2025-02-24 – 行云集成电路”褐蚁 HY90”标价 14.9 万元，宣称跑 671B FP8 原版（量子位 2025-04 报道，转自搜索摘要【未核实】） – 10 万元级的”满血”机有的只能单并发；部分产品是量化或蒸馏版却宣称满血。出处：澎湃 2025-05（本次 403，内容取自搜索摘要【未核实】） – 某政企云服务商大模型产品 2024 年起步价百万级，2025 年初基础版落地价降到 25 万元起。出处：界面（取自搜索摘要【未核实】） – 京东云负责人称全尺寸满血一体机采购成本约百万级。优刻得架构师称 32B、70B 蒸馏版预算三四十万即可满足需求，满血与蒸馏交付约各占一半。出处：第一财经（取自搜索摘要【未核实】） – IDC 称接近百家厂商推出 AI 一体机（2025-05 报告，原文未见，转自商汤稿件）。出处：量子位

2. 一体机硬件厂商

2.1 华为昇腾（含伙伴生态）

1. **产品线**
   - Atlas 800I A2 推理服务器和一体机，FusionCube A3000 训推超融合一体机（2023-07 发布，集成 OceanStor A300 存储节点、训推节点、交换、AI 平台软件，宣称 2 小时部署）【官方新闻】华为
   - 媒体称有支持 DeepSeek V3 671B 和 R1 的“FusionCube A300 DS Edition”（型号命名待核）
2. **定价**：华为不公开报价。TrendForce 转 TechNews 和 53AI 的数字：推理 Atlas 32B 版 30–50 万元，671B 版 300–500 万元；训推 FusionCube 200 万起，最高超 1000 万元；对比约 2000 万元的 H100 方案节省 60–70%。【媒体，二手】TrendForce 2025-04-29
3. **解决方案**：政务、金融、运营商、电力能源，信创替代场景

4. **销路**
    - 两种商业模式：华为昇腾一站式，或开放计算、网络、AI 平台软件的第三方伙伴一站式【官方】
    - 2025-05-24 鲲鹏昇腾开发者大会公布：开发者超 665 万，鲲鹏加昇腾伙伴 8800 多家，100 多家伙伴基于昇腾发布 DeepSeek 一体机方案【媒体转华为口径】IT之家
    - 代表伙伴：华鲲振宇、神州鲲泰（KunTai R624 K2 DeepSeek 一体机、KunTai Cube）神州鲲泰；运营商中国电信”息壤智算一体机”
5. **差异化**：国产全栈加信创资质，伙伴贴牌铺量。华为本身不赚一体机集成差价，赚芯片和整机

2.2 浪潮信息（元脑）

1. **产品线**
    - 元脑企智 EPAI 一体机，5 档：基础版、标准版、创新版、高级版、集群版【媒体】cnyes
    - 元脑企智 DeepSeek 一体机”双模版”（NF5698A7，1536GB HBM3，单机同时跑 R1 671B 和 V3，宣称 2000 以上并发，单用户 44 token/s；2025-03-25 发布）【官方】浪潮信息
    - 元脑 R1 推理服务器（NF5688G7，1128GB HBM3e）【媒体】IT之家
    - 浪潮云另有”海若”一体机和云帆超融合一体机
2. **定价**：不公开。捆绑 EPAI 平台（RAG、插件、低代码工作流、零代码微调）
3. **解决方案**：制造、金融、政务、教育
4. **销路**：2017 年起与 ISV 和集成商合作做增值渠道，后升级为”元脑生态”，行业伙伴超 2000 家【券商研报】；2025 年推“EPAI 种子计划”，签约 166 家种子伙伴【研报转述，年报原文未核】
5. **数字**：2025 年营收 1647.82 亿元，服务器收入 1546.05 亿元，服务器毛利率 4.52%【媒体转年报】每经。硬件毛利极薄，所以要靠 EPAI 软件和一体机做附加值

2.3 联想

1. **产品线**
    - 问天 WA7780 G3（训推）、WA7785a G3（推理）：单机跑 DeepSeek-R1 671B，超 1TB HBM3e，宣称实测 100 并发【媒体】爱范儿
    - 与沐曦联合方案（2025-02-05）：基于 ThinkStation PX 工作站加曦思 N260 的智能体一体机，以及问天 WA5480 G3 加 8 张曦云 C500 的训推一体机【媒体】
2. **定价**：不公开。工作站方案”万元级起步、科室级部署”【未核实】；“40 天千台交付、近万卡出货”【媒体，未核实】凤凰科技
3. **解决方案**：医疗科室、教育、中小企业
4. **销路**：联想分销加 OEM 渠道，国产 GPU 联合品牌
5. **差异化**：从工作站到整机柜全覆盖，是唯一把”桌边一体机”做成低价入口的大厂

2.4 新华三（H3C）

1. **产品线**：灵犀 Cube 大模型一体机 DeepSeek 版（2025-02-20 发布），2 个系列、6 款型、12 款产品，覆盖 14B—671B【官方】新华三
    - 纯享版：旗舰 671B、经济 32B、标准（32B 高并发加知识库，可选 70B）；开箱即用，提供对话界面和 API
    - 使能版：在纯享版上加多模型推理、知识库、应用编排、蒸馏、微调；捆绑 LinSeer Hub、RT、Copilot
    - 性能宣称：671B 单机 32 以上并发、15 token/s；32B 单机 16 以上并发、10 token/s
2. **定价**：不公开。使能版加收”专家服务”（AIGC 应用定制、知识库构建）
3. **方案**：政企、运营商、教育。2026-04 已适配 DeepSeek-V4-Pro 和 V4-Flash【官方】新华三
4. **销路**：H3C 渠道和集成商
5. **可借鉴**：“纯享、使能”两档就是”硬件加模型”与”硬件加平台加服务”的分层，SKU 设计最清楚

2.5 中科曙光 / 海光

- 2025-02 曙光云推出全国产 DeepSeek 大模型超融合一体机（国产 x86 CPU 加国产 GPGPU，宣称符合信创要求）【券商研报转述】新浪；海光 DCU 已适配 DeepSeek V3 和 R1【媒体】凤凰科技
- 价格不公开。主攻信创政务和科研
- 海光与曙光的换股吸收合并已于 2025-12 公告终止【研报摘要，未核原公告】

2.6 其他一体机供给（只列证据）

- 超聚变：G5500 V7 一体机 68.6 万元中标（见第 1 节）

- 京东云、中国电信、优刻得、商汤、行云（褐蚁 HY90 14.9 万元）等：见第 1 节价格带

---

3. 模型 / 云厂商的私有化业务

3.1 智谱（02513.HK）

1. **产品线**：GLM 系列本地化部署套餐、行业大模型平台建设项目、MaaS 开放平台 API、GLM Coding Plan（个人和团队）、清言 C 端
2. **定价**
   - 招股书称本地化部署”以套餐形式提供，按模型类型与规模、算力资源量、实施成本定价”，单项目价高，但更像一次性收入【媒体转招股书】华尔街见闻
   - 2024 年本地化部署客户 123 家（云端 5457 家），本地化收入占 84.5%，总收入约 3.124 亿元【媒体转招股书】。【估算】本地化客户平均约 215 万元/家
   - 中标样本【公告，媒体转引】
     - 中国气象局公共气象服务中心大模型项目 1090 万元（2026-02-11）
     - 中国联通”广东产互中试基地深圳 AI+ 眼镜”979 万元（2026-06-02）
     - 深圳智慧城市科技发展集团”全球科创分析服务”9390 万元（第一候选，控制价 9395 万元，2026-06-16）智东西
     - 厦门市健康医疗大数据中心”医疗大模型底座与应用工程一期”1058 万元（预算 1080 万元，2026-10-21）新浪
   - 团队席位：GLM Coding Plan 团队版标准席位 598 元/月（含 66000 积分，2 席起）【媒体，未核官网】
3. **方案**：政务、气象、医疗、科创情报、运营商、金融
4. **销路**：直接投标央国企和政府，同时做云端开放平台
5. **关键趋势**：2025 年收入 7.24 亿元，本地化部署 5.34 亿元，占 73.7%【媒体转年报】。2026 年上半年收入 9.54 亿元，开放平台和 API 收入 8.25 亿元，占 86.5%，本地化占比降到约 13.5%；API 毛利率从 −0.4% 升到 24.6%；MaaS ARR 按月度口径 16 亿美元【媒体转中报，各家口径不一】同花顺
   - 解读：私有化收入是项目制、成长慢；量起来要靠 API。智谱用私有化大单换政企背书，再转向 MaaS

3.2 百度智能云 千帆

1. **产品线**
   - 千帆 DeepSeek 一体机 4 款，均为单机 8 卡：昆仑芯 P800 OAM、P800 PCIe、昇腾 Atlas 800 两款【媒体转载】CSDN
   - 百舸 DeepSeek 一体机（昆仑芯 P800，宣称半天上线）
   - 更早的千帆大模型一体机（通用、昇腾、昆仑芯三版，预置文心和开源模型）凤凰科技
2. **定价**：私有化分软件授权、软硬一体、租赁服务三种交付方式【媒体】蓝鲸，金额不公开
3. **方案**：政务、金融、能源、工业
4. **销路**：直接投标。2025 年 1–11 月主流云厂商大模型中标 291 个、超 21 亿元，其中百度 95 个、7.1 亿元，居首【媒体统计】Albase；全年 109 个、9 亿元【媒体，未核】
5. **差异化**：自研昆仑芯加文心，国产化加模型一家打包

3.3 阿里云 百炼专属版

1. **产品线**
   - “百炼专属版 AI 训推一体机”：软硬一体私有化、数据不出域；单机 16 卡支持 DeepSeek-R1、V3 满血（16、8、4bit）；三种配置：训推一体机、智能体一体机、高性能一体机；内置百炼专属版训推平台和 OpenTrek-LLM 推理引擎【阿里云开发者社区】阿里云
   - 公有云：Token Plan 团队版，按坐席包月，Credits 计量
2. **定价**
   - 一体机：不公开
   - Token Plan 团队版：标准 198 元/席/月（25,000 Credits）、高级 698 元（100,000）、尊享 1398 元（250,000）；不退款；超额买共享用量包【开发者社区文章，非官方文档】阿里云
   - AI 通用节省计划按承诺月消费和 3–24 个月周期，最低 5.3 折【同上，二手】
3. **方案**：金融、政企、对数据合规要求高的行业
4. **销路**：直销加生态伙伴；云上用”坐席订阅”把企业智能体做成 SaaS
5. **可借鉴**：同一家公司同时卖”一体机私有化”和”按坐席订阅”，私有化客户也能走订阅制

3.4 科大讯飞 星火

1. **产品线**：星火一体机（与华为昇腾合作）、星火医疗一体机（讯飞医疗与华为）、星火办公一体机（宣称 2240 TOPS）、星火 X1 全国产算力推理模型（2025-01-15）【媒体】
2. **定价**：项目制，不公开
   - 某银行 2 套 AI 大模型一体机，讯飞智元报价 968 万元（约 484 万元/套，【估算】），预算 1658 万元【公告候选，媒体转引】
3. **方案**：教育、政务、医疗、金融、工业
4. **销路**：直接投标，覆盖央国企和地方政府
   - 2025 年大模型相关中标金额 23.16 亿元【公司口径】新浪
   - 第三方统计 2025 年 210 个项目、23.16 亿元，通用大模型厂商第一；2024 年 91 个项目、8.48 亿元【媒体】
   - 刘庆峰称央国企招投标"只看技术和应用成效"
5. **差异化**：行业应用（教育、医疗）加全国产训练，一体机只是交付载体

---

4. 智能体平台软件（私有化授权）

4.1 Dify（LangGenius）

- **产品线**：Community（开源，单工作空间）、Enterprise（私有化授权：多工作空间、SSO、RBAC、审计、去品牌、SOC 2 Type II）
- **定价**
  - 官网"Contact Sales"，附加服务、定制集成、专属支持另报价【官方】Dify
  - AWS Marketplace（全球）：Dify Enterprise 每单位 15 万美元/12 个月，不退款，可私人报价【官方挂牌】AWS
  - AWS 中国区（西云数据）：50 万元/12 个月，基础设施另计【官方挂牌】AWS 中国
- **方案**：通用企业智能体、RAG 知识库、工作流
- **销路**：云市场（AWS、阿里云 DMS 托管，阿里云不卖授权）、Dify Partners 签 SLA 并做实施
- **启示**：开源做漏斗，授权年费做收入，实施和 SLA 交给伙伴

4.2 FastGPT（环界云 / Sealos）

- **定价【官方】**
  - SaaS：免费、基础 99 元/月、高级 599 元/月、定制；年付按 10 个月计 FastGPT
  - 商业版【官方】文档
    - Sealos 全托管单节点：1 万元/月（3 个月起）或 12 万元/年，含 8C32G
    - 多节点：2.2 万元/月或 26.4 万元/年，含 32C128G
    - 自有服务器部署：询价，含 6 个版本的升级支持，14 天上线
    - 所有档位含商业授权、首次免费部署、优先工单
    - 技术服务（定开、维护、迁移、三方接入）2000—3000 元/人/天
- **销路**：官网直销加 Sealos 云
- **启示**：这是国内少有的公开"托管私有化"月费和人天单价，可直接拿来做沐仞远程运维和实施报价的锚

4.3 实在智能

- 实在 Agent（RPA 加智能体），宣称有昇腾一体机版、开箱 30 分钟部署
- 自家站点称：私有化"几万到几十万"，企业级定制智能体平台 30—200 万元以上；计费"按数字员工或流程，不按人头"【未核实，厂商自家站点，标注 AI 生成】实在智能
- 方案：金融、制造、政务流程自动化

4.4 无问芯穹（引用已有调研）

- 智能体服务平台按积分计费，1 元 = 100 积分；包并发 1600—3580 元/并发/月；2026-07-22 起停止个人实名用户服务
- 详见 `04_调研与测试/无问芯穹/无问芯穹_产品与收费定价_2026-10-21.qmd`（本次未重新抓取）
- 2025-11 起公开的智能体平台定位：5 类以上能力模板（代码、研究、多模态）【媒体】量子位

4.5 补充：扣子（Coze）

- 开源版 Coze Studio（Apache-2.0）可免费自部署
- 企业版定制报价；海外 Premium 9—39 美元/月【第三方站点，未核实】
- 国内私有化价格未找到

---

5. 海外参照

5.1 NVIDIA AI Enterprise

- **定价**（自管系统，经 NPN 伙伴销售）【官方】NVIDIA 文档
  - 1 年 4,500 美元/GPU，2 年 9,000，3 年 13,500，4 年和 5 年均 18,000（5 年按 4 年价）
  - 永久授权 22,500 美元/GPU（含 5 年支持）
  - 教育和 Inception 价为 25%（1 年 1,125 美元）；Inception 12 个月内最多 64 份
  - 云上按需 1 美元/GPU/小时，加云实例费
  - 5 年期随 H100、H200 NVL、A800 PCIe 附送
- 【估算】一台 8 卡机 1 年订阅约 3.6 万美元；5 年约 14.4 万美元
- 2026-10-22 GTC Berlin 黄仁勋以”约 2000 美元/GPU/年”举例智能体软件授权，无产品和价目【媒体】
- **硬件参考**：DGX B200 无官方标价；经销商挂牌约 36.8 万—51.5 万美元【经销商，未核实】

5.2 HPE Private Cloud AI（与 NVIDIA 联合）

- 2024 年推出，4 种配置（L40S 到 GH200）；2025 年加 Developer 系统（RTX Pro 6000 Blackwell）、Large 和 Air-Gapped Large；Medium 和 Large 升级到 DL380a Gen12 加 H200【媒体】SiliconANGLE
- **定价**：HPE 商城为”indicative pricing”，最终价由经销商定，Small Bundle（S5Q48A）需登录看价【官方商城】HPE
- **销路**：渠道商加 GreenLake 订阅；Unleash AI 伙伴计划新增 26 家伙伴、75 个以上验证用例
- **启示**：用 T 恤尺码（S、M、L、Air-gapped）标准化交钥匙私有云，用订阅制降低首付

---

6. 模式归纳（给沐仞的对照）

1. **价格结构基本是三段**：硬件买断（几十万到数百万元），加平台或授权（一体机多为捆绑，独立软件如 Dify 50 万元/年、NVIDIA 4500 美元/GPU/年），加实施和运维（人天 2000—3000 元，或”3 年 7×24”写进标书）。没有一家国内一体机厂商公开标价，价格都在标书里定。
2. **标书写的是性能，不是卡**：北部湾银行要求”671B BF16 满血、16K 上下文、15 并发、10 token/s、≥32 卡 64GB”。沐仞 FPTM 报价单应直接用”模型 × 精度 × 并发 × token/s”做 SKU。
3. **中标方多是集成商，不是原厂**：润建、华云、科瑞软件、易平方、瑞涛、中科江南都是集成商，中国移动和神州数码也来投标。一体机的钱主要通过集成商和运营商流转，原厂供货。沐仞要么做集成商的供货方，要么自己拿集成资质投标。
4. **价格在快速下探，市场鱼龙混杂**：从 2024 年”百万起步”到 2025 年”25 万起”、14.9 万元满血机。满血、量化、蒸馏混卖，并发虚标。可信的并发和 token/s 实测报告本身就是差异化卖点。
5. **分档模板**：新华三”纯享、使能”，浪潮 EPAI 5 档，阿里”训推、智能体、高性能”，HPE S、M、L、Air-gapped。共识是：入门款（小模型、开箱即用）、主力款（满血加知识库）、使能款（加微调和智能体平台和专家服务）。
6. **私有化是背书，不是增长引擎**：智谱本地化收入占比从 2025 年 73.7% 降到 2026 年上半年约 13.5%，API 占 86.5%。沐仞的”一体机加远程运维加 Token 出海”组合，正好把一次性硬件收入接到持续的运维订阅和 Token 消耗上。
7. **订阅化私有部署是空白**：国内只有 FastGPT 公开”托管私有化按月”（1 万元/月起），阿里有坐席订阅（198—1398 元/席/月），HPE 有 GreenLake。电站侧或机房侧”一体机租赁加按 Token 或按月运维”在国内公开报价里几乎没有，可作为沐仞的定价切口。
8. **渠道**：华为靠 100 多家贴牌伙伴，浪潮靠元脑生态 2000 多家 ISV 和 SI，讯飞、智谱、百度直接投标，Dify 靠云市场加伙伴 SLA。沐仞的现实路径是：信创和国产卡方案加入昇腾或其他国产芯片伙伴计划；投标找集成商联合体；海外 Token 走云市场挂牌。

7. 数据缺口

- 华为、浪潮、联想、新华三、曙光的一体机官方价目和渠道折扣都不公开，需要通过伙伴询价或买标书获取
- 智能超参数《2025 年中国大模型中标项目监测报告》全年原文未取得，一体机类项目占比未知

- 阿里百炼专属版、百度千帆一体机、讯飞星火一体机没有任何可查单价
- 多数中标数字来自媒体转引，正式使用前应到中国政府采购网或各省交易平台核对原公告